

Aprendizaje y Clasificación Automática con R

Un enfoque práctico con datos abiertos reales

MI Jesús Gilberto Rodríguez Escobedo

2026-07-10

Índice general

Presentación	1
Aprendizaje y Clasificación Automática con R	1
Un enfoque práctico con datos abiertos reales	1
Objetivo general	1
Público al que va dirigido	1
Software utilizado	1
Estructura actual del libro	2
Nota para el lector	2
Licencia, autoría y forma de citar	3
Autor	3
Licencia	3
Cita sugerida	3
Uso educativo	3
1. ¿Qué es el aprendizaje automático?	5
1.1. Objetivos del capítulo	5
1.2. Introducción	5
1.3. Programación tradicional contra aprendizaje automático	5
1.4. Variables predictoras y variable respuesta	6
1.5. Tipos principales de aprendizaje automático	6
1.6. Notación básica	6
1.7. Primer ejemplo visual en R	6
1.8. División entre entrenamiento y prueba	6
1.9. Primer clasificador basado en una regla	7
1.10. Conclusión	7
2. Preparación de datos reales	9
2.1. Objetivos del capítulo	9
2.2. Introducción	9
2.3. Cargar paquetes	9
2.4. Leer el archivo CSV	9
2.5. Primer vistazo a los datos	9
2.6. Variables de interés	10
2.7. Crear variable respuesta	10
2.8. Preparar variables finales	10

2.9. Guardar base preparada	10
2.10. Resumen del capítulo	10
3. Análisis exploratorio de datos	11
3.1. Objetivos del capítulo	11
3.2. Cargar paquetes y base	11
3.3. Preparar variables	11
3.4. Distribución de la variable respuesta	11
3.5. Accidentes por mes	12
3.6. Accidentes por hora del día	13
3.7. Tipos de accidente más frecuentes	14
3.8. Proporción por tipo de accidente	15
3.9. Conclusión	15
4. Regresión logística para clasificación	17
4.1. Objetivos del capítulo	17
4.2. Fundamento matemático	17
4.3. Visualización de la función logística	18
4.4. Cargar paquetes y datos	18
4.5. Preparar y dividir datos	18
4.6. Ajustar modelo	18
4.7. Predicción y matriz de confusión	19
4.8. Métricas	19
4.9. Distribución de probabilidades	19
4.10. Conclusión	19
5. k vecinos más cercanos, k-NN	21
5.1. Objetivos del capítulo	21
5.2. Idea intuitiva	21
5.3. Distancia euclidiana	22
5.4. Cargar y preparar datos	22
5.5. Modelo k-NN	22
5.6. Comparación de valores de k	22
5.7. Conclusión	23
6. Árboles de decisión para clasificación	25
6.1. Objetivos del capítulo	25
6.2. Introducción	25
6.3. Fundamento matemático	25
6.4. Cargar paquetes y datos	25
6.5. Usar la base completa	25
6.6. División y entrenamiento	25
6.7. Complejidad e importancia	25
6.8. Gráfica opcional del árbol	26
6.9. Predicción y métricas	26
6.10. Conclusión	26
7. Random Forest para clasificación	27
7.1. Objetivos del capítulo	27

7.2. Introducción	27
7.3. Fundamento matemático	27
7.4. Cargar paquetes y datos	27
7.5. Muestra de trabajo	27
7.6. División en entrenamiento y prueba	28
7.7. Ajustar Random Forest	28
7.8. Importancia de variables	29
7.9. Predicción y métricas	29
7.10. Distribución de probabilidades predichas	30
7.11. Conclusión	30

Presentación

Aprendizaje y Clasificación Automática con R

Un enfoque práctico con datos abiertos reales

Autor: MI Jesús Gilberto Rodríguez Escobedo

Versión: 0.5

Modalidad: Libro abierto, práctico e interactivo

R · Quarto · Machine Learning · Datos abiertos · GitHub Pages

Este libro introduce el aprendizaje automático (*Machine Learning*) mediante ejemplos claros, didácticos y prácticos desarrollados principalmente en R.

La intención no es escribir un tratado matemático extenso, sino construir una guía aplicada para aprender haciendo con datos abiertos reales. En esta versión trabajamos con datos de accidentes de tránsito de México y los usamos como hilo conductor para explicar preparación de datos, análisis exploratorio y modelos de clasificación.

Enfoque del libro

El libro combina fundamento conceptual, código reproducible en R, interpretación didáctica de resultados y visualizaciones profesionales.

Objetivo general

Desarrollar competencias básicas e intermedias en aprendizaje automático mediante el análisis, modelado e interpretación de datos reales.

Público al que va dirigido

Este libro está dirigido a estudiantes de ingeniería, ciencias, ciencia de datos, estadística aplicada y áreas afines que desean iniciar en aprendizaje automático con un enfoque práctico.

Software utilizado

Los ejemplos se desarrollan principalmente en R, usando RStudio y Quarto. También se mencionan herramientas útiles para publicar y compartir resultados:

- RStudio
- Consola de R
- Google Colab
- GitHub
- GitHub Pages
- Quarto Pub

Estructura actual del libro

1. Introducción al aprendizaje automático.
2. Preparación de datos reales.
3. Análisis exploratorio de datos.
4. Regresión logística.
5. k vecinos más cercanos.
6. Árboles de decisión.
7. Random Forest.

Nota para el lector

Los capítulos están diseñados para leerse y ejecutarse paso a paso. Cada bloque de código busca responder una pregunta concreta y cada resultado se acompaña de una interpretación didáctica.

Licencia, autoría y forma de citar

Autor

MI Jesús Gilberto Rodríguez Escobedo

Licencia

Este libro se distribuye bajo la licencia **Creative Commons Atribución-NoComercial-CompartirIgual 4.0 Internacional (CC BY-NC-SA 4.0)**.

Esto significa que el material puede compartirse y adaptarse con fines educativos y no comerciales, siempre que se otorgue el crédito correspondiente al autor y las obras derivadas se compartan bajo una licencia compatible.

Cita sugerida

Rodríguez Escobedo, J. G. (2026). *Aprendizaje y Clasificación Automática con R: Un enfoque práctico con datos abiertos reales*. Libro web publicado con Quarto y GitHub Pages.

Uso educativo

El propósito de este libro es apoyar la enseñanza y el aprendizaje de técnicas de aprendizaje automático con R, usando datos reales y un enfoque didáctico, reproducible y aplicado.

Capítulo 1

¿Qué es el aprendizaje automático?

1.1 Objetivos del capítulo

Al finalizar este capítulo, el lector será capaz de explicar qué es el aprendizaje automático, diferenciarlo de la programación tradicional e identificar problemas de clasificación, regresión y agrupamiento.

1.2 Introducción

El aprendizaje automático, también conocido como *Machine Learning*, es una rama de la inteligencia artificial que permite construir modelos capaces de aprender patrones a partir de datos.

En la programación tradicional, una persona define reglas. En aprendizaje automático, proporcionamos ejemplos para que un algoritmo aprenda una relación entre variables de entrada y una salida esperada.

1.3 Programación tradicional contra aprendizaje automático

[1] "Contaminación alta"

Interpretación. Este ejemplo muestra programación tradicional: la decisión depende de una regla escrita manualmente.

	dia	pm10	temperatura	humedad	clase
1	1	42	25	40	Baja
2	2	88	28	35	Alta
3	3	55	22	60	Baja
4	4	120	30	30	Alta
5	5	63	24	55	Baja
6	6	95	29	33	Alta
7	7	38	21	65	Baja
8	8	110	31	29	Alta
9	9	72	27	42	Baja
10	10	130	32	28	Alta
11	11	47	23	62	Baja
12	12	99	30	34	Alta

1.4 Variables predictoras y variable respuesta

La **variable respuesta** es la variable que queremos predecir. Las **variables predictoras** son las variables que usamos como entrada para el modelo.

1.5 Tipos principales de aprendizaje automático

1. Aprendizaje supervisado.
2. Aprendizaje no supervisado.
3. Aprendizaje por refuerzo.

1.6 Notación básica


Supongamos que tenemos n observaciones y p variables predictoras. Podemos representar los datos mediante una matriz X y una variable respuesta Y .

$$\hat{y} = f(x_1, x_2, \dots, x_p)$$

1.7 Primer ejemplo visual en R

Ejemplo inicial de clasificación

Clasificación de contaminación alta o baja



1.8 División entre entrenamiento y prueba

```
dia pm10 temperatura humedad clase
```

3	3	55	22	60	Baja
12	12	99	30	34	Alta
10	10	130	32	28	Alta
2	2	88	28	35	Alta
6	6	95	29	33	Alta
11	11	47	23	62	Baja
5	5	63	24	55	Baja
4	4	120	30	30	Alta

	dia	pm10	temperatura	humedad	clase
1	1	42	25	40	Baja
7	7	38	21	65	Baja
8	8	110	31	29	Alta
9	9	72	27	42	Baja

1.9 Primer clasificador basado en una regla

	Predicho	
Real	Alta	Baja
Alta	6	0
Baja	0	6

[1] 1

1.10 Conclusión

El aprendizaje automático permite construir modelos que aprenden patrones a partir de datos. En este capítulo vimos la diferencia entre reglas manuales y aprendizaje a partir de ejemplos.

Capítulo 2

Preparación de datos reales

2.1 Objetivos del capítulo

Al finalizar este capítulo, el lector será capaz de leer una base real, seleccionar variables, construir una variable respuesta y guardar una base preparada para modelado.

2.2 Introducción

En la práctica profesional, los datos reales casi nunca vienen preparados. Antes de aplicar un algoritmo necesitamos revisar, limpiar, transformar y documentar los datos.

2.3 Cargar paquetes

2.4 Leer el archivo CSV

```
[1] TRUE
```

```
[1] "Archivo leído correctamente."
```

2.5 Primer vistazo a los datos

```
# A tibble: 6 x 45
  COBERTURA ID_ENTIDAD ID_MUNICIPIO ANIO MES ID_HORA ID_MINUTO ID_DIA
  <chr>      <chr>      <chr>      <dbl> <chr> <chr>      <chr>      <chr>
1 Municipal 01          001          2024 01    02        25        01
2 Municipal 01          001          2024 01    03        40        01
3 Municipal 01          001          2024 01    04        37        01
4 Municipal 01          001          2024 01    05         0        01
5 Municipal 01          001          2024 01    06        45        01
6 Municipal 01          001          2024 01    07        30        01
# i 37 more variables: DIASEMANA <chr>, URBANA <chr>, SUBURBANA <chr>,
#   TIPACCID <chr>, AUTOMOVIL <dbl>, CAMPASAJ <dbl>, MICROBUS <dbl>,
#   PASCAMION <dbl>, OMNIBUS <dbl>, TRANVIA <dbl>, CAMIONETA <dbl>,
```

```
# CAMION <dbl>, TRACTOR <dbl>, FERROCARRI <dbl>, MOTOCICLET <dbl>,
# BICICLETA <dbl>, OTROVEHIC <dbl>, CAUSAACCI <chr>, CAPAROD <chr>,
# SEXO <chr>, ALIENTO <chr>, CINTURON <chr>, ID_EDAD <dbl>, CONDMUERTO <dbl>,
# CONDHERIDO <dbl>, PASAMUERTO <dbl>, PASAHERIDO <dbl>, PEATMUERTO <dbl>, ...
```

2.6 Variables de interés

```
# A tibble: 6 x 10
  ANIO MES ID_ENTIDAD ID_MUNICIPIO ID_HORA ID_DIA DIASEMANA TIPACCID
  <dbl> <chr> <chr>      <chr>      <chr>  <chr>  <chr>      <chr>
1  2024  01    01          001        02    01    lunes    Colisión con veh~
2  2024  01    01          001        03    01    lunes    Colisión con obj~
3  2024  01    01          001        04    01    lunes    Colisión con pea~
4  2024  01    01          001        05    01    lunes    Colisión con obj~
5  2024  01    01          001        06    01    lunes    Colisión con obj~
6  2024  01    01          001        07    01    lunes    Colisión con veh~
# i 2 more variables: CAUSAACCI <chr>, CLASACC <chr>
```

2.7 Crear variable respuesta

Con víctimas	Solo daños
68108	322519

2.8 Preparar variables finales

	filas	columnas
1	390627	6

2.9 Guardar base preparada

2.10 Resumen del capítulo

En este capítulo leímos una base real, seleccionamos variables, construimos una variable respuesta y guardamos una base preparada para aprendizaje automático.

Capítulo 3

Análisis exploratorio de datos

3.1 Objetivos del capítulo

Al finalizar este capítulo, el lector será capaz de cargar una base preparada, revisar su estructura, calcular frecuencias, construir gráficas e interpretar patrones iniciales.


3.2 Cargar paquetes y base

```
[1] "Base preparada cargada correctamente."
```

3.3 Preparar variables


3.4 Distribución de la variable respuesta

Con víctimas	Solo daños
17.44	82.56




3.5 Accidentes por mes


```
# A tibble: 12 x 2
  MES_FACTOR      n
  <fct>      <int>
1 01        31600
2 02        32208
3 03        33237
4 04        32666
5 05        34665
6 06        31737
7 07        30062
8 08        31800
9 09        31351
10 10        33771
11 11        34047
12 12        33483
```




3.6 Accidentes por hora del día



3.7 Tipos de accidente más frecuentes



3.8 Proporción por tipo de accidente



3.9 Conclusión

El análisis exploratorio permite detectar patrones iniciales, revisar el desbalance de clases e identificar variables útiles para modelar.

Capítulo 4

Regresión logística para clasificación

4.1 Objetivos del capítulo

Al finalizar este capítulo, el lector será capaz de ajustar una regresión logística, predecir probabilidades y evaluar el desempeño.


4.2 Fundamento matemático

La regresión logística utiliza la función:

$$p = \frac{1}{1 + e^{-z}}$$

donde $z = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p$.

4.3 Visualización de la función logística



4.4 Cargar paquetes y datos

```
[1] "Base preparada cargada correctamente."
```

4.5 Preparar y dividir datos

4.6 Ajustar modelo

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	18.107257168	101.84719297	0.17778848	8.588891e-01
MES02	-0.045765700	0.02975556	-1.53805548	1.240350e-01
MES03	-0.032191364	0.02927313	-1.09968980	2.714673e-01
MES04	-0.002838049	0.02945462	-0.09635327	9.232400e-01
MES05	-0.015408552	0.02906672	-0.53010979	5.960358e-01
MES06	-0.054753129	0.02983667	-1.83509526	6.649158e-02
MES07	-0.076296781	0.03035194	-2.51373620	1.194598e-02
MES08	-0.094049541	0.02997105	-3.13801278	1.700975e-03
MES09	-0.077109438	0.03015044	-2.55748998	1.054306e-02
MES10	-0.154152374	0.02979697	-5.17342485	2.298416e-07
MES11	-0.106385033	0.02950811	-3.60528073	3.118157e-04
MES12	-0.111888509	0.02959338	-3.78086333	1.562855e-04


4.7 Predicción y matriz de confusión

Real	Predicho	
	Con víctimas	Solo daños
Con víctimas	13765	6739
Solo daños	14302	82382

4.8 Métricas

	exactitud	sensibilidad	especificidad
1	0.8204509	0.6713324	0.8520748

4.9 Distribución de probabilidades



4.10 Conclusión

La regresión logística es un modelo interpretable para clasificación binaria. El punto de corte permite ajustar el balance entre sensibilidad y especificidad.

Capítulo 5

k vecinos más cercanos, k-NN


5.1 Objetivos del capítulo

Al finalizar este capítulo, el lector será capaz de explicar k-NN, preparar datos para este método, estandarizar variables y evaluar el desempeño.

5.2 Idea intuitiva

k-NN clasifica una nueva observación según la clase más común entre sus vecinos más cercanos.

Ejemplo intuitivo de k-NN



5.3 Distancia euclidiana

$$d(A, B) = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$$

[1] 2.236068

5.4 Cargar y preparar datos


5.5 Modelo k-NN

Real	Predicho	
	Con víctimas	Solo daños
Con víctimas	211	399
Solo daños	144	2846

5.6 Comparación de valores de k

	k	exactitud	sensibilidad	especificidad
1	3	0.8433333	0.3770492	0.9384615
2	5	0.8480556	0.3491803	0.9498328
3	11	0.8558333	0.3377049	0.9615385

Comparación de métricas para distintos valores de k



5.7 Conclusión

k-NN es un método intuitivo basado en similitud. Su desempeño depende del valor de k , del escalamiento y de la calidad de las variables predictoras.

Capítulo 6

Árboles de decisión para clasificación

6.1 Objetivos del capítulo

Al finalizar este capítulo, el lector será capaz de explicar la idea básica de un árbol de decisión, entrenarlo en R y evaluar su desempeño.

6.2 Introducción

Los árboles de decisión clasifican observaciones mediante una secuencia de preguntas. Son interpretables y pueden expresarse como reglas tipo si-entonces.

6.3 Fundamento matemático

Una medida común de impureza es el índice de Gini:

$$Gini = 1 - \sum_{k=1}^K p_k^2$$

6.4 Cargar paquetes y datos

```
[1] "Base preparada cargada correctamente."
```

6.5 Usar la base completa

```
      filas columnas
1 390627          6
```

6.6 División y entrenamiento

6.7 Complejidad e importancia

Classification tree:

```
rpart(formula = accidente_con_victimas ~ MES + ID_HORA + DIASEMANA +
      TIPACCID + CAUSAACCI, data = entrenamiento, method = "class",
      control = rpart.control(cp = 0.005, minsplit = 1000, minbucket = 300,
                              maxdepth = 5))
```

Variables actually used in tree construction:

```
[1] TIPACCID
```

Root node error: 47604/273439 = 0.17409

n= 273439

	CP	nsplit	rel error	xerror	xstd
1	0.097051	0	1.0000	1.0000	0.0041653
2	0.005000	2	0.8059	0.8059	0.0038150

	variable	importancia
1	TIPACCID	22919.330
2	CAUSAACCI	1093.984

6.8 Gráfica opcional del árbol

La gráfica completa del árbol puede ser pesada en PDF. El lector puede ejecutarla manualmente en RStudio.

6.9 Predicción y métricas

Real	Predicho	
	Con víctimas	Solo daños
Con víctimas	3965	16539
Solo daños	0	96684

	exactitud	sensibilidad	especificidad
1	0.8588678	0.1933769	1

6.10 Conclusión

Los árboles de decisión son modelos intuitivos, visuales e interpretables. Este capítulo prepara el camino para modelos basados en muchos árboles, como Random Forest.

Capítulo 7

Random Forest para clasificación

7.1 Objetivos del capítulo

Al finalizar este capítulo, el lector será capaz de explicar Random Forest, entrenar un modelo en R, interpretar importancia de variables y evaluar desempeño.

7.2 Introducción

Random Forest combina muchos árboles de decisión. Cada árbol aprende sobre una muestra aleatoria de los datos y la predicción final se obtiene por votación mayoritaria.

7.3 Fundamento matemático

Si se construyen B árboles, la predicción final es:


$$\hat{y}(x) = \text{moda}\{\hat{y}^{(1)}(x), \hat{y}^{(2)}(x), \dots, \hat{y}^{(B)}(x)\}$$

7.4 Cargar paquetes y datos

```
[1] "Base preparada cargada correctamente."
```

7.5 Muestra de trabajo

```
      filas columnas
1 30000          6
```



7.6 División en entrenamiento y prueba

```
conjunto registros
1 Entrenamiento    21000
2      Prueba      9000
```

7.7 Ajustar Random Forest

Ranger result


Call:

```
ranger(accidente_con_victimas ~ MES + ID_HORA + DIASEMANA + TIPACCID + CAUSAACCI, data =
```

```
Type:                                Probability estimation
Number of trees:                      200
Sample size:                         21000
Number of independent variables:      5
Mtry:                                3
Target node size:                    20
Variable importance mode:             impurity
Splitrule:                           gini
OOB prediction error (Brier s.):      0.1066668
```

7.8 Importancia de variables

	variable	importancia
1	TIPACCID	1608.8347
2	ID_HORA	416.7870
3	MES	324.9780
4	DIASEMANA	234.4944
5	CAUSAACCI	220.5923




7.9 Predicción y métricas

Real	Predicho	
	Con víctimas	Solo daños
Con víctimas	475	991
Solo daños	265	7269

	exactitud	sensibilidad	especificidad
1	0.8604444	0.3240109	0.9648261

7.10 Distribución de probabilidades predichas



7.11 Conclusión

Random Forest mejora la estabilidad y la capacidad predictiva de un solo árbol al combinar muchos árboles. Es uno de los métodos más útiles para clasificación aplicada.