

Random Forest para Clasificación

**Prediciendo la Gravedad de
Accidentes de Tránsito en México con R**


Análisis de la base ATUS (INEGI) mediante Aprendizaje Automático

El Experto Solitario



Un solo árbol es propenso a memorizar el ruido (sobreajuste) y tomar decisiones inestables.

El Tribunal de Sabios



Un bosque ensambla cientos de árboles entrenados con muestras aleatorias. Un comité diverso rara vez se equivoca en la misma dirección.

$$\hat{y}(x) = \text{moda} \{ \hat{y}^{(1)}(x), \dots, \hat{y}^{(B)}(x) \}$$

El Veredicto Final.

El Escrutinio. La función matemática que elige la clase con mayor frecuencia.

Votos Individuales. Cada árbol evalúa la evidencia de forma independiente.



Víctimas



Víctimas



Daños

=

Víctimas

Contexto del Problema



30,000 registros
(muestra representativa).




5 variables clave
(MES, ID_HORA,
DIASEMANA, TIPACCID,
CAUSAACCI).




Clasificación binaria de
accidente_con_victimas.

El Desbalance



Desafío Analítico: El 82% de los accidentes solo reportan daños materiales. Identificar la minoría crítica (18%) requiere un modelo altamente sensible a patrones sutiles.



Entrenando el Modelo: El Paquete ranger en R



`num.trees = 200`

Tamaño del Comité

Construimos 200 árboles de decisión independientes.

`mtry = 3`

Diversidad de Variables

En cada nodo, el modelo solo evalúa 3 variables aleatorias, forzando perspectivas diferentes.


`min.node.size = 20`

Control de Complejidad

Evita que los árboles crezcan demasiado y memoricen casos aislados (previene sobreajuste).

Error predictivo fuera de bolsa (OOB Error): ~10.6%

Abriendo la Caja Negra: Importancia de Variables



La Anatomía del Veredicto: Matriz de Confusión

Predicción del Modelo (Con víctimas / Solo daños)

Verdaderos Positivos

475

Víctimas detectadas correctamente.

Falsos Negativos

991

Área Crítica: Accidentes con víctimas que el modelo asumió como solo daños.

Falsos Positivos

265

Falsas alarmas.

Verdaderos Negativos

7,269

Daños clasificados con precisión.

Realidad (Con víctimas / Solo daños)

Cuadro de Mando Predictivo (Métricas de Desempeño)

86.0%

Exactitud

Aciertos globales.
Engañosamente alta
debido al volumen de
accidentes sin víctimas.

32.4%

Sensibilidad


Habilidad de detectar
víctimas reales.

Baja por diseño. El desbalance
extremo hace que el modelo
apueste a la clase mayoritaria.
Requiere ajuste de umbral.

96.5%

Especificidad

Habilidad de descartar
falsas alarmas.
Extremadamente robusta.



Separando el Ruido

Random Forest no solo emite un veredicto binario; calcula un nivel de confianza.



Al observar estas distribuciones superpuestas, las políticas públicas pueden mover el umbral de decisión (ej. de 50% a 20%) para capturar más víctimas (aumentar sensibilidad) a costa de procesar más alertas falsas.

El Veredicto: ¿Por qué Random Forest Triunfa?

Atributos	Árbol Único	Random Forest
Estabilidad & Precisión	Baja (muy variable según la muestra)	Altamente robusto gracias al ensamblaje y voto mayoritario.
Riesgo de Sobreajuste	Alto (memoriza el ruido)	Mitigado por el remuestreo (mtry).
Interpretabilidad	Reglas visuales directas (Alta)	Caja negra matemática (Media), pero compensada con gráficos claros de importancia de variables.

Sacrificamos reglas visuales simples a cambio de una arquitectura algorítmica capaz de encontrar patrones estables en datos reales y desbalanceados.