



Mecánica Probabilística: Desmitificando el Clasificador Naive Bayes


Del teorema fundamental a la clasificación predictiva con datos ATUS.

El triunfo de una premisa "incorrecta"


El algoritmo Naive Bayes asume que todas las variables son estadísticamente independientes entre sí. En el mundo real, esto casi nunca es cierto. Sin embargo, es uno de los clasificadores probabilísticos más eficientes y robustos (Domingos y Pazzani, 1997).

La Realidad vs. La "Ingenuidad"

La Realidad



Naive Bayes



La balanza de la evidencia

El teorema de Bayes no es solo una ecuación; es un mecanismo para actualizar nuestras creencias frente a nuevos datos.

Nuestra creencia inicial.

Probabilidad Previa
 $P(C)$

Probabilidad Posterior
 $P(C|X)$

Nuestra creencia actualizada.

Verosimilitud
 $P(X|C)$


El peso de la nueva evidencia.

Para clasificar, la constante $P(X)$ se ignora. Solo comparamos qué platillo de la balanza pesa más: $P(C|X) \propto P(X|C)$  NotebookLM

El atajo matemático: Multiplicación encadenada

Para múltiples variables ($X_1, X_2, \dots, X_p$), el supuesto de independencia permite calcular el puntaje de una clase multiplicando sus probabilidades individuales.


Caja de Multiplicación



El colapso del producto y el Suavizado de Laplace

¿Qué ocurre si una combinación específica de datos nunca apareció en el entrenamiento?
Su probabilidad es 0.

El Colapso




La Solución: Laplace



Adaptación a los datos: Categórico vs. Gaussiano

El mecanismo interno de Naive Bayes cambia dependiendo de la naturaleza de las variables predictoras.

Naive Bayes Categórico	Naive Bayes Gaussiano
• Tipo de Dato: Variables cualitativas (texto, factores, clases). • Mecanismo: Conteo de frecuencias relativas (tablas cruzadas). • Protección: Suavizado de Laplace (evita probabilidades cero).	• Tipo de Dato: Variables numéricas continuas. • Mecanismo: Curva de campana (Distribución Normal). Se estima la media y desviación estándar por cada clase.  Valor de la variable continua Clasificación por Intersección

El desafío práctico: Datos ATUS

Aplicamos el modelo a la Estadística de Accidentes de Tránsito (ATUS) para predecir probabilísticamente la gravedad de un siniestro basándonos en variables categóricas.



[MES]

[ID_HORA]

[DIASEMANA]

[TIPACCID]

[CAUSAACCI]

Inspeccionando el aprendizaje del modelo

El modelo no crea reglas complejas; simplemente construye un diccionario exhaustivo de probabilidades previas y condicionales.

Probabilidades Previas Aprendidas

Solo daños: 11,592 casos

Con víctimas: 2,407 casos

Probabilidades Condicionales (Variable: CAUSAACCI)

Cuando la causa es Conductor:

$P(\text{Solo daños}) = 0.917$

$P(\text{Con víctimas}) = 0.927$

Cuando la causa es Peatón o pasajero:

$P(\text{Con víctimas}) = 0.029$

$P(\text{Solo daños}) = 0.001$

Tablero de Impacto: Del modelo a la realidad

Al evaluar el modelo con los datos de prueba, cruzamos la predicción ingenua con la realidad del accidente.

4,900

Verdadero Negativo (VN)

Era "Solo daños" y se predijo correctamente.
(Gran volumen).

69

Falso Positivo (FP)

Era "Solo daños" pero se alarmó como "Con víctimas". (Falsa Alarma).

775

Falso Negativo (FN)

Era "Con víctimas", pero el modelo lo minimizó a "Solo daños". (El error más costoso).


257

Verdadero Positivo (VP)

Era "Con víctimas" y se detectó exitosamente.

El espejismo de la Exactitud

En datos desbalanceados, una exactitud alta no significa un modelo útil.
Debemos mirar la **imagen completa**.



Síntesis: El valor real de una premisa ingenua

Naive Bayes sacrifica captura total a cambio de ser una línea base probabilística **ultrarrápida**.

El Costo

- Asume independencia irreal
- Baja Sensibilidad en datos desbalanceados
- Probabilidades a veces mal calibradas



El Valor

- Extremadamente rápido computacionalmente
- Funciona con alta dimensionalidad
- Combina datos mixtos sin esfuerzo
- Produce probabilidades (no solo clases rígidas)

EL VEREDICTO DE LA LÍNEA BASE: Un excelente punto de partida. Si un modelo complejo (como Random Forest o SVM) no logra superar significativamente el puntaje F1 (0.378) de Naive Bayes en este problema, **el costo computacional adicional no está justificado.**

Veredicto Final: Cuándo confiar en la ingenuidad

El Clasificador Naive Bayes demuestra que un modelo simple puede construir aproximaciones altamente útiles.

- 1 Úselo como Primera Línea**
Siempre corra un Naive Bayes antes de modelos costosos. Establece el “piso” predictivo del proyecto.
- 2 Cuidado con la Correlación Severa**
Si dos variables miden exactamente lo mismo, su ‘voto’ probabilístico se contará doble. Reduzca la redundancia.
- 3 Mire más allá de la Exactitud**
En escenarios desbalanceados como ATUS (donde las víctimas son minoría), juzgue el modelo por Sensibilidad, Especificidad y F1. La exactitud es un espejismo.