

# Aprendizaje y Clasificación Automática con R

## Un enfoque práctico con datos abiertos reales

MI. Gilberto Rodríguez

2026-07-07



# Table of contents

|                                                                       |          |
|-----------------------------------------------------------------------|----------|
| <b>Presentación</b>                                                   | <b>1</b> |
| Objetivo general . . . . .                                            | 1        |
| Público al que va dirigido . . . . .                                  | 1        |
| Software utilizado . . . . .                                          | 1        |
| Estructura inicial del libro . . . . .                                | 1        |
| <b>1 ¿Qué es el aprendizaje automático?</b>                           | <b>3</b> |
| 1.1 Objetivos del capítulo . . . . .                                  | 3        |
| 1.2 Introducción . . . . .                                            | 3        |
| 1.3 Programación tradicional contra aprendizaje automático . . . . .  | 3        |
| 1.4 Variables predictoras y variable respuesta . . . . .              | 4        |
| 1.5 Notación básica para aprendizaje automático . . . . .             | 4        |
| 1.6 Algoritmo general de aprendizaje supervisado . . . . .            | 5        |
| 1.7 Aprendizaje supervisado . . . . .                                 | 5        |
| 1.8 Clasificación . . . . .                                           | 5        |
| 1.9 Regresión . . . . .                                               | 5        |
| 1.10 Aprendizaje no supervisado . . . . .                             | 6        |
| 1.11 Flujo general de un proyecto de aprendizaje automático . . . . . | 6        |
| 1.12 Primer ejemplo visual en R . . . . .                             | 6        |
| 1.13 División entre entrenamiento y prueba . . . . .                  | 6        |
| 1.14 Primer clasificador sencillo basado en una regla . . . . .       | 7        |
| 1.15 Conclusión . . . . .                                             | 7        |
| <b>2 Preparación de datos reales</b>                                  | <b>9</b> |
| 2.1 Objetivos del capítulo . . . . .                                  | 9        |
| 2.2 Introducción . . . . .                                            | 9        |
| 2.3 Datos crudos y datos preparados . . . . .                         | 9        |
| 2.4 Representación matemática de una base preparada . . . . .         | 9        |
| 2.5 Algoritmo general de preparación de datos . . . . .               | 10       |
| 2.6 Conjunto de datos de trabajo: ATUS . . . . .                      | 10       |
| 2.7 Crear la carpeta de datos . . . . .                               | 10       |
| 2.8 Cargar paquetes . . . . .                                         | 11       |
| 2.9 Leer el archivo CSV . . . . .                                     | 11       |
| 2.10 Primer vistazo a los datos . . . . .                             | 11       |
| 2.11 Estandarizar nombres de variables . . . . .                      | 11       |
| 2.12 Variables de interés . . . . .                                   | 12       |

|          |                                                                    |           |
|----------|--------------------------------------------------------------------|-----------|
| 2.13     | Diccionario inicial de variables . . . . .                         | 12        |
| 2.14     | Revisión de la variable <b>CLASACC</b> . . . . .                   | 12        |
| 2.15     | Crear una variable respuesta . . . . .                             | 12        |
| 2.16     | Eliminar registros sin variable respuesta . . . . .                | 13        |
| 2.17     | Convertir variables categóricas . . . . .                          | 13        |
| 2.18     | Revisión de datos faltantes . . . . .                              | 14        |
| 2.19     | Selección final de variables para el primer modelo . . . . .       | 14        |
| 2.20     | Guardar la base preparada . . . . .                                | 14        |
| 2.21     | Resumen del capítulo . . . . .                                     | 14        |
| <b>3</b> | <b>Análisis exploratorio de datos</b>                              | <b>15</b> |
| 3.1      | Objetivos del capítulo . . . . .                                   | 15        |
| 3.2      | Introducción . . . . .                                             | 15        |
| 3.3      | Fundamento matemático del análisis exploratorio . . . . .          | 15        |
| 3.4      | Proporciones condicionales . . . . .                               | 16        |
| 3.5      | Algoritmo general del análisis exploratorio . . . . .              | 16        |
| 3.6      | Cargar paquetes . . . . .                                          | 17        |
| 3.7      | Cargar la base preparada . . . . .                                 | 17        |
| 3.8      | Preparar variables para el análisis exploratorio . . . . .         | 17        |
| 3.9      | Primer vistazo a la base . . . . .                                 | 17        |
| 3.10     | Estructura de los datos . . . . .                                  | 18        |
| 3.11     | Distribución de la variable respuesta . . . . .                    | 18        |
| 3.12     | Interpretación de la variable respuesta . . . . .                  | 18        |
| 3.13     | Gráfica de la variable respuesta . . . . .                         | 18        |
| 3.14     | Accidentes por mes . . . . .                                       | 18        |
| 3.15     | Accidentes por hora del día . . . . .                              | 19        |
| 3.16     | Accidentes por día de la semana . . . . .                          | 19        |
| 3.17     | Accidentes por tipo de accidente . . . . .                         | 20        |
| 3.18     | Accidentes por causa presunta . . . . .                            | 20        |
| 3.19     | Relación entre tipo de accidente y presencia de víctimas . . . . . | 21        |
| 3.20     | Relación entre hora y presencia de víctimas . . . . .              | 21        |
| 3.21     | Relación entre día de la semana y presencia de víctimas . . . . .  | 22        |
| 3.22     | Tabla resumen por clase . . . . .                                  | 22        |
| 3.23     | Conclusión . . . . .                                               | 22        |
| <b>4</b> | <b>Regresión logística para clasificación</b>                      | <b>23</b> |
| 4.1      | Objetivos del capítulo . . . . .                                   | 23        |
| 4.2      | Introducción . . . . .                                             | 23        |
| 4.3      | La función logística . . . . .                                     | 23        |
| 4.4      | Fundamento matemático de la regresión logística . . . . .          | 23        |
| 4.5      | Logit y razón de momios . . . . .                                  | 24        |
| 4.6      | Regla de clasificación . . . . .                                   | 24        |
| 4.7      | Algoritmo de regresión logística . . . . .                         | 24        |
| 4.8      | Visualización de la función logística . . . . .                    | 25        |
| 4.9      | Cargar paquetes . . . . .                                          | 25        |
| 4.10     | Cargar la base preparada . . . . .                                 | 25        |
| 4.11     | Preparar variables para el modelo . . . . .                        | 26        |
| 4.12     | División en entrenamiento y prueba . . . . .                       | 26        |

|          |                                                             |           |
|----------|-------------------------------------------------------------|-----------|
| 4.13     | Ajustar el modelo de regresión logística . . . . .          | 27        |
| 4.14     | Predicción de probabilidades . . . . .                      | 27        |
| 4.15     | De probabilidades a clases . . . . .                        | 27        |
| 4.16     | Matriz de confusión . . . . .                               | 27        |
| 4.17     | Métricas de evaluación . . . . .                            | 28        |
| 4.18     | Fórmulas de evaluación para clasificación binaria . . . . . | 28        |
| 4.19     | Clasificación con punto de corte 0.3 . . . . .              | 29        |
| 4.20     | Comparación de puntos de corte . . . . .                    | 30        |
| 4.21     | Distribución de probabilidades predichas . . . . .          | 30        |
| 4.22     | Odds ratios . . . . .                                       | 30        |
| 4.23     | Conclusión . . . . .                                        | 30        |
| <b>5</b> | <b>k vecinos más cercanos, k-NN</b>                         | <b>31</b> |
| 5.1      | Objetivos del capítulo . . . . .                            | 31        |
| 5.2      | Introducción . . . . .                                      | 31        |
| 5.3      | Idea intuitiva del método . . . . .                         | 31        |
| 5.4      | ¿Qué significa k? . . . . .                                 | 31        |
| 5.5      | Ejemplo sencillo con puntos . . . . .                       | 32        |
| 5.6      | Distancia euclidiana . . . . .                              | 32        |
| 5.7      | Fundamento matemático de k-NN . . . . .                     | 32        |
| 5.8      | Ejemplo de cálculo de distancia . . . . .                   | 33        |
| 5.9      | Estandarización de variables . . . . .                      | 33        |
| 5.10     | Algoritmo k-NN . . . . .                                    | 34        |
| 5.11     | Cargar paquetes . . . . .                                   | 34        |
| 5.12     | Cargar la base preparada . . . . .                          | 34        |
| 5.13     | Selección de una muestra para k-NN . . . . .                | 35        |
| 5.14     | Preparar variables para k-NN . . . . .                      | 35        |
| 5.15     | Crear variables dummy . . . . .                             | 35        |
| 5.16     | División en entrenamiento y prueba . . . . .                | 36        |
| 5.17     | Estandarización de variables . . . . .                      | 36        |
| 5.18     | Ajuste del modelo k-NN con $k = 5$ . . . . .                | 36        |
| 5.19     | Matriz de confusión . . . . .                               | 37        |
| 5.20     | Métricas de evaluación . . . . .                            | 37        |
| 5.21     | Comparación con distintos valores de k . . . . .            | 37        |
| 5.22     | Comparación conceptual con regresión logística . . . . .    | 39        |
| 5.23     | Conclusión . . . . .                                        | 39        |



# Presentación

Este libro introduce el aprendizaje automático (*Machine Learning*) mediante ejemplos claros, didácticos y prácticos desarrollados principalmente en R.

El propósito no es presentar un tratado matemático extenso, sino construir una guía aplicada que permita aprender haciendo con datos abiertos reales.

## Objetivo general

Desarrollar competencias básicas e intermedias en aprendizaje automático mediante el análisis, modelado e interpretación de datos reales.

## Público al que va dirigido

Este libro está dirigido a estudiantes de ingeniería, ciencias, ciencia de datos, estadística aplicada y áreas afines.

## Software utilizado

Los ejemplos se desarrollan principalmente en R, utilizando RStudio y Quarto.

También se podrán utilizar herramientas como:

- RStudio
- Consola de R
- Google Colab
- GitHub
- GitHub Pages
- Quarto Pub

## Estructura inicial del libro

1. Introducción al aprendizaje automático.
2. Preparación de datos reales.
3. Análisis exploratorio de datos.
4. Regresión logística.
5. k vecinos más cercanos.





# Chapter 1

## ¿Qué es el aprendizaje automático?

### 1.1 Objetivos del capítulo

Al finalizar este capítulo, el lector será capaz de:

- Explicar qué es el aprendizaje automático.
- Diferenciar entre programación tradicional y aprendizaje automático.
- Identificar problemas de clasificación, regresión y agrupamiento.
- Reconocer las etapas principales de un proyecto de aprendizaje automático.
- Reconocer la notación matemática básica usada en aprendizaje automático.

### 1.2 Introducción

El aprendizaje automático, también conocido como *Machine Learning*, es una rama de la inteligencia artificial que permite construir modelos capaces de aprender patrones a partir de datos.

La idea central será:

Aprender Machine Learning haciendo proyectos con datos reales.

### 1.3 Programación tradicional contra aprendizaje automático

En la programación tradicional, una persona escribe reglas explícitas.

```
pm10 <- 85

if (pm10 > 75) {
  print("Contaminación alta")
} else {
  print("Contaminación baja")
}
```

En aprendizaje automático no le damos al sistema una regla fija. Le damos datos.

```
datos <- data.frame(
  dia = 1:12,
```



## 1.6 Algoritmo general de aprendizaje supervisado

Algoritmo: Aprendizaje supervisado

Entrada:

- Matriz de datos X
- Variable respuesta Y
- Algoritmo de aprendizaje

Proceso:

1. Dividir los datos en entrenamiento y prueba.
2. Usar los datos de entrenamiento para aprender una función  $f$ .
3. Usar la función  $f$  para predecir nuevas respuestas.
4. Comparar las predicciones contra los valores reales.
5. Calcular métricas de desempeño.
6. Interpretar los resultados.

Salida:

- Modelo entrenado
- Predicciones
- Métricas de evaluación

## 1.7 Aprendizaje supervisado

El aprendizaje supervisado se utiliza cuando tenemos una variable respuesta conocida.

Dentro del aprendizaje supervisado hay dos tareas muy importantes:

- clasificación;
- regresión.

## 1.8 Clasificación

La clasificación se utiliza cuando la variable respuesta es categórica.

Ejemplos:

- Alta o baja contaminación.
- Accidente con víctimas o solo daños.
- Tumor benigno o maligno.

## 1.9 Regresión

La regresión se utiliza cuando la variable respuesta es numérica.

Ejemplos:

- Predecir concentración de PM10.
- Predecir temperatura.
- Predecir ventas.

## 1.10 Aprendizaje no supervisado

El aprendizaje no supervisado se utiliza cuando no tenemos una variable respuesta conocida. En lugar de predecir una etiqueta, buscamos patrones ocultos en los datos.

## 1.11 Flujo general de un proyecto de aprendizaje automático

1. Plantear el problema
2. Conseguir los datos
3. Entender las variables
4. Limpiar los datos
5. Explorar los datos
6. Dividir en entrenamiento y prueba
7. Entrenar el modelo
8. Evaluar el modelo
9. Interpretar los resultados
10. Comunicar hallazgos

## 1.12 Primer ejemplo visual en R

```
library(ggplot2)

ggplot(datos, aes(x = pm10, y = temperatura, color = clase)) +
  geom_point(size = 4) +
  labs(
    title = "Ejemplo inicial de clasificación",
    subtitle = "Clasificación de contaminación alta o baja",
    x = "PM10",
    y = "Temperatura",
    color = "Clase"
  )
```

## 1.13 División entre entrenamiento y prueba

```
set.seed(123)

n <- nrow(datos)
indices_entrenamiento <- sample(1:n, size = round(0.7 * n))

entrenamiento <- datos[indices_entrenamiento, ]
prueba <- datos[-indices_entrenamiento, ]

entrenamiento
prueba
```

## 1.14 Primer clasificador sencillo basado en una regla

```
datos$prediccion_regla <- ifelse(datos$pm10 > 75, "Alta", "Baja")
datos[, c("pm10", "clase", "prediccion_regla")]
```

```
tabla_confusion <- table(
  Real = datos$clase,
  Predicho = datos$prediccion_regla
)
```

```
tabla_confusion
```

```
exactitud <- mean(datos$clase == datos$prediccion_regla)
exactitud
```

## 1.15 Conclusión

El aprendizaje automático permite construir modelos capaces de aprender patrones a partir de datos. En el siguiente capítulo comenzaremos con una parte fundamental: la preparación de datos reales.



## Chapter 2

# Preparación de datos reales

### 2.1 Objetivos del capítulo

Al finalizar este capítulo, el lector será capaz de:

- Comprender por qué la preparación de datos es una etapa fundamental en aprendizaje automático.
- Leer un conjunto de datos real en R.
- Seleccionar variables relevantes.
- Crear una variable respuesta para un problema de clasificación.
- Preparar una base lista para análisis exploratorio y modelado.

### 2.2 Introducción

En la práctica profesional, los datos reales casi nunca vienen preparados. Antes de aplicar cualquier algoritmo necesitamos revisar, limpiar, transformar y documentar.

### 2.3 Datos crudos y datos preparados

Llamaremos **datos crudos** a la base tal como se obtiene de la fuente original. Llamaremos **datos preparados** a la base que ya fue revisada, transformada y organizada para un propósito específico.

### 2.4 Representación matemática de una base preparada

Una base de datos para aprendizaje automático puede representarse como una matriz de variables predictoras  $X$  y una variable respuesta  $Y$ .

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix}$$

$$Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

En nuestro caso,  $Y$  representa la variable `accidente_con_victimas`.

Cuando convertimos esta variable en forma binaria, podemos escribir:

$$Y_i = \begin{cases} 1, & \text{si el accidente tiene víctimas} \\ 0, & \text{si el accidente es de solo daños} \end{cases}$$

## 2.5 Algoritmo general de preparación de datos

Algoritmo: Preparación de datos para aprendizaje automático

Entrada:

- Base de datos cruda
- Diccionario de variables
- Pregunta de predicción

Proceso:

1. Leer la base de datos.
2. Revisar dimensiones, nombres y tipos de variables.
3. Seleccionar variables relevantes.
4. Identificar la variable respuesta.
5. Transformar variables cuando sea necesario.
6. Revisar datos faltantes.
7. Guardar una base preparada.

Salida:

- Base limpia y lista para análisis exploratorio y modelado

## 2.6 Conjunto de datos de trabajo: ATUS

Trabajaremos con **Accidentes de Tránsito Terrestre en Zonas Urbanas y Suburbanas**, conocido como **ATUS**, publicado por INEGI.

La pregunta práctica será:

¿Podemos clasificar si un accidente tendrá víctimas o será solo de daños materiales?

## 2.7 Crear la carpeta de datos

Dentro de la carpeta del libro crea una carpeta llamada `datos`.

El archivo de datos debe llamarse:



```
datos/atus_2024.csv
```

## 2.8 Cargar paquetes

```
library(readr)
library(dplyr)
library(ggplot2)
library(stringr)
```

Si alguno no está instalado:

```
install.packages(c("readr", "dplyr", "ggplot2", "stringr"))
```

## 2.9 Leer el archivo CSV

```
ruta_atus <- "datos/atus_2024.csv"
file.exists(ruta_atus)
```

```
if (file.exists(ruta_atus)) {
  atus <- read_csv(
    file = ruta_atus,
    show_col_types = FALSE,
    locale = locale(encoding = "UTF-8")
  )
  print("Archivo leído correctamente.")
} else {
  atus <- NULL
  print("El archivo atus_2024.csv todavía no está disponible en la carpeta datos.")
}
```

## 2.10 Primer vistazo a los datos

```
if (!is.null(atus)) {
  dim(atus)
  head(atus)
  names(atus)
}
```

## 2.11 Estandarizar nombres de variables

```
if (!is.null(atus)) {
  names(atus) <- toupper(names(atus))
  names(atus)
}
```

## 2.12 Variables de interés

```
variables_interes <- c(
  "ANIO", "MES", "ID_ENTIDAD", "ID_MUNICIPIO",
  "ID_HORA", "ID_DIA", "DIASEMANA",
  "TIPACCID", "CAUSAACCI", "CLASACC"
)

if (!is.null(atus)) {
  variables_existentes <- intersect(variables_interes, names(atus))
  variables_existentes
}

if (!is.null(atus)) {
  atus_base <- atus |>
    select(all_of(variables_existentes))

  head(atus_base)
}
```

## 2.13 Diccionario inicial de variables

| Variable     | Descripción didáctica          |
|--------------|--------------------------------|
| ANIO         | Año del accidente              |
| MES          | Mes del accidente              |
| ID_ENTIDAD   | Clave de la entidad federativa |
| ID_MUNICIPIO | Clave del municipio            |
| ID_HORA      | Hora del accidente             |
| ID_DIA       | Día del mes                    |
| DIASEMANA    | Día de la semana               |
| TIPACCID     | Tipo de accidente              |
| CAUSAACCI    | Causa presunta del accidente   |
| CLASACC      | Clase del accidente            |

## 2.14 Revisión de la variable CLASACC

```
if (exists("atus_base") && "CLASACC" %in% names(atus_base)) {
  table(atus_base$CLASACC, useNA = "ifany")
}
```

## 2.15 Crear una variable respuesta

```
if (exists("atus_base") && "CLASACC" %in% names(atus_base)) {
  atus_modelo <- atus_base |>
    mutate(
```

```

CLASACC_TXT = as.character(CLASACC),
CLASACC_TXT = str_to_lower(CLASACC_TXT),
accidente_con_victimas = case_when(
  str_detect(CLASACC_TXT, "sólo daños") ~ "Solo daños",
  str_detect(CLASACC_TXT, "solo daños") ~ "Solo daños",
  str_detect(CLASACC_TXT, "daños") ~ "Solo daños",
  str_detect(CLASACC_TXT, "no fatal") ~ "Con víctimas",
  str_detect(CLASACC_TXT, "fatal") ~ "Con víctimas",
  CLASACC_TXT %in% c("1", "2") ~ "Con víctimas",
  CLASACC_TXT %in% c("3") ~ "Solo daños",
  TRUE ~ NA_character_
)
}

if (exists("atus_modelo")) {
  table(atus_modelo$accidente_con_victimas, useNA = "ifany")
}

```

## 2.16 Eliminar registros sin variable respuesta

```

if (exists("atus_modelo")) {
  atus_modelo <- atus_modelo |>
    filter(!is.na(accidente_con_victimas))

  table(atus_modelo$accidente_con_victimas)
}

```

## 2.17 Convertir variables categóricas

```

if (exists("atus_modelo")) {
  atus_modelo <- atus_modelo |>
    mutate(
      ID_ENTIDAD = as.factor(ID_ENTIDAD),
      ID_MUNICIPIO = as.factor(ID_MUNICIPIO),
      MES = as.factor(MES),
      DIASEMANA = as.factor(DIASEMANA),
      TIPACCID = as.factor(TIPACCID),
      CAUSAACCI = as.factor(CAUSAACCI),
      accidente_con_victimas = as.factor(accidente_con_victimas)
    )

  str(atus_modelo)
}

```

## 2.18 Revisión de datos faltantes

```
if (exists("atus_modelo")) {  
  colSums(is.na(atus_modelo))  
}
```

```
if (exists("atus_modelo")) {  
  round(100 * colSums(is.na(atus_modelo)) / nrow(atus_modelo), 2)  
}
```

## 2.19 Selección final de variables para el primer modelo

```
if (exists("atus_modelo")) {  
  atus_ml <- atus_modelo |>  
    select(  
      accidente_con_victimas,  
      MES,  
      ID_HORA,  
      DIASEMANA,  
      TIPACCID,  
      CAUSAACCI  
    )  
  
  head(atus_ml)  
}
```

```
if (exists("atus_ml")) {  
  atus_ml <- na.omit(atus_ml)  
  dim(atus_ml)  
}
```

## 2.20 Guardar la base preparada

```
if (exists("atus_ml")) {  
  write_csv(atus_ml, "datos/atus_ml_preparado.csv")  
}
```

## 2.21 Resumen del capítulo

En este capítulo aprendimos a leer una base CSV, seleccionar variables, construir una variable respuesta y guardar una base preparada para aprendizaje automático.

## Chapter 3

# Análisis exploratorio de datos

### 3.1 Objetivos del capítulo

Al finalizar este capítulo, el lector será capaz de:

- Explicar qué es el análisis exploratorio de datos.
- Cargar una base preparada previamente.
- Revisar la estructura de un conjunto de datos.
- Analizar la distribución de una variable respuesta.
- Construir tablas de frecuencia.
- Elaborar gráficas de barras con `ggplot2`.
- Interpretar patrones iniciales antes de construir modelos.

### 3.2 Introducción

Después de preparar los datos, el siguiente paso en un proyecto de aprendizaje automático es explorarlos.

El **análisis exploratorio de datos**, también conocido como *Exploratory Data Analysis* o **EDA**, consiste en revisar, resumir, visualizar e interpretar los datos antes de construir modelos.

### 3.3 Fundamento matemático del análisis exploratorio

Si una variable categórica tiene categorías  $c_1, c_2, \dots, c_k$ , la frecuencia absoluta de una categoría  $c_j$  se puede representar como:

$$n_j = \sum_{i=1}^n I(y_i = c_j)$$

donde  $I(y_i = c_j)$  es una función indicadora:

$$I(y_i = c_j) = \begin{cases} 1, & \text{si } y_i = c_j \\ 0, & \text{si } y_i \neq c_j \end{cases}$$

La proporción de la categoría  $c_j$  es:

$$p_j = \frac{n_j}{n}$$

En nuestro caso, una proporción importante es:

$$p_{\text{víctimas}} = \frac{\text{número de accidentes con víctimas}}{\text{número total de accidentes}}$$

### 3.4 Proporciones condicionales

Podemos estudiar la proporción de accidentes con víctimas dado un tipo de accidente:

$$P(\text{Con víctimas} \mid \text{Tipo de accidente})$$

De forma empírica, esta proporción se calcula como:

$$\hat{P}(\text{Con víctimas} \mid T = t) = \frac{\text{número de accidentes con víctimas del tipo } t}{\text{número total de accidentes del tipo } t}$$

### 3.5 Algoritmo general del análisis exploratorio

Algoritmo: Análisis exploratorio de datos

Entrada:

- Base de datos preparada
- Variable respuesta
- Variables predictoras

Proceso:

1. Revisar dimensiones de la base.
2. Revisar nombres y tipos de variables.
3. Calcular frecuencias de la variable respuesta.
4. Calcular proporciones de la variable respuesta.
5. Analizar variables temporales, categóricas y numéricas.
6. Construir gráficas exploratorias.
7. Cruzar variables predictoras con la variable respuesta.
8. Identificar patrones, desbalances y posibles problemas.

Salida:

- Tablas descriptivas
- Gráficas exploratorias
- Primeras hipótesis sobre los datos

## 3.6 Cargar paquetes

```
library(readr)
library(dplyr)
library(ggplot2)
```

## 3.7 Cargar la base preparada

```
ruta_atus_ml <- "datos/atus_ml_preparado.csv"
file.exists(ruta_atus_ml)

if (file.exists(ruta_atus_ml)) {
  atus_ml <- read_csv(ruta_atus_ml, show_col_types = FALSE)
  print("Base preparada cargada correctamente.")
} else {
  atus_ml <- NULL
  print("No se encontró el archivo datos/atus_ml_preparado.csv. Ejecuta primero el capítulo 2.")
}
```

## 3.8 Preparar variables para el análisis exploratorio

```
if (!is.null(atus_ml)) {
  atus_ml <- atus_ml |>
    mutate(
      ID_HORA_NUM = as.numeric(ID_HORA),
      DIASEMANA = factor(
        DIASEMANA,
        levels = c("lunes", "Martes", "Miercoles", "Jueves", "Viernes", "Sabado", "Domingo")
      ),
      accidente_con_victimas = factor(
        accidente_con_victimas,
        levels = c("Con víctimas", "Solo daños")
      )
    )
}
```

## 3.9 Primer vistazo a la base

```
if (!is.null(atus_ml)) {
  dim(atus_ml)
  head(atus_ml)
  names(atus_ml)
}
```

### 3.10 Estructura de los datos

```
if (!is.null(atus_ml)) {
  str(atus_ml)
}
```

### 3.11 Distribución de la variable respuesta

```
if (!is.null(atus_ml)) {
  table(atus_ml$accidente_con_victimas)
}
```

```
if (!is.null(atus_ml)) {
  round(100 * prop.table(table(atus_ml$accidente_con_victimas)), 2)
}
```

### 3.12 Interpretación de la variable respuesta

En esta base se observa un desbalance importante: aproximadamente 82.56% de los accidentes corresponden a solo daños, mientras que 17.44% corresponden a accidentes con víctimas.

### 3.13 Gráfica de la variable respuesta

```
if (!is.null(atus_ml)) {
  ggplot(atus_ml, aes(x = accidente_con_victimas)) +
    geom_bar() +
    labs(
      title = "Distribución de accidentes según presencia de víctimas",
      x = "Clase del accidente",
      y = "Número de accidentes"
    )
}
```

### 3.14 Accidentes por mes

```
if (!is.null(atus_ml)) {
  accidentes_mes <- atus_ml |>
    count(MES) |>
    arrange(as.numeric(MES))

  accidentes_mes
}
```

```
if (!is.null(atus_ml)) {
  ggplot(accidentes_mes, aes(x = factor(MES, levels = sort(unique(as.numeric(MES))))), y = n)) +
```



```
geom_col() +  
labs(  
  title = "Número de accidentes por mes",  
  x = "Mes",  
  y = "Número de accidentes"  
)  
}
```

### 3.15 Accidentes por hora del día

```
if (!is.null(atus_ml)) {  
  accidentes_hora <- atus_ml |>  
    count(ID_HORA_NUM) |>  
    arrange(ID_HORA_NUM)  
  
  accidentes_hora  
}
```

```
if (!is.null(atus_ml)) {  
  ggplot(accidentes_hora, aes(x = ID_HORA_NUM, y = n)) +  
    geom_col() +  
    scale_x_continuous(breaks = 0:23) +  
    labs(  
      title = "Número de accidentes por hora del día",  
      x = "Hora del día",  
      y = "Número de accidentes"  
    )  
}
```

### 3.16 Accidentes por día de la semana

```
if (!is.null(atus_ml)) {  
  accidentes_dia <- atus_ml |>  
    count(DIASEMANA) |>  
    arrange(DIASEMANA)  
  
  accidentes_dia  
}
```

```
if (!is.null(atus_ml)) {  
  ggplot(accidentes_dia, aes(x = DIASEMANA, y = n)) +  
    geom_col() +  
    coord_flip() +  
    labs(  
      title = "Número de accidentes por día de la semana",  
      x = "Día de la semana",
```

```
    y = "Número de accidentes"  
  )  
}
```

### 3.17 Accidentes por tipo de accidente

```
if (!is.null(atus_ml)) {  
  accidentes_tipo <- atus_ml |>  
    count(TIPACCID) |>  
    arrange(desc(n))  
  
  accidentes_tipo  
}
```

```
if (!is.null(atus_ml)) {  
  accidentes_tipo_top <- accidentes_tipo |>  
    slice_max(n, n = 10)  
  
  ggplot(accidentes_tipo_top, aes(x = reorder(TIPACCID, n), y = n)) +  
    geom_col() +  
    coord_flip() +  
    labs(  
      title = "Tipos de accidente más frecuentes",  
      x = "Tipo de accidente",  
      y = "Número de accidentes"  
    )  
}
```

### 3.18 Accidentes por causa presunta

```
if (!is.null(atus_ml)) {  
  accidentes_causa <- atus_ml |>  
    count(CAUSAACCI) |>  
    arrange(desc(n))  
  
  accidentes_causa  
}
```

```
if (!is.null(atus_ml)) {  
  accidentes_causa_top <- accidentes_causa |>  
    slice_max(n, n = 10)  
  
  ggplot(accidentes_causa_top, aes(x = reorder(CAUSAACCI, n), y = n)) +  
    geom_col() +  
    coord_flip() +  
    labs(  
      title = "Causas presuntas de accidentes más frecuentes",  
      x = "Causa presunta",  
      y = "Número de accidentes"  
    )  
}
```

```
    title = "Causas presuntas más frecuentes",  
    x = "Causa presunta",  
    y = "Número de accidentes"  
  )  
}
```

### 3.19 Relación entre tipo de accidente y presencia de víctimas

```
if (!is.null(atus_ml)) {  
  tipos_top <- atus_ml |>  
    count(TIPACCID) |>  
    slice_max(n, n = 10) |>  
    pull(TIPACCID)  
  
  atus_tipo_top <- atus_ml |>  
    filter(TIPACCID %in% tipos_top)  
  
  ggplot(atus_tipo_top, aes(x = TIPACCID, fill = accidente_con_victimas)) +  
    geom_bar(position = "fill") +  
    coord_flip() +  
    labs(  
      title = "Proporción de accidentes con víctimas según tipo de accidente",  
      x = "Tipo de accidente",  
      y = "Proporción",  
      fill = "Clase"  
    )  
}
```

### 3.20 Relación entre hora y presencia de víctimas

```
if (!is.null(atus_ml)) {  
  ggplot(atus_ml, aes(x = ID_HORA_NUM, fill = accidente_con_victimas)) +  
    geom_bar(position = "fill") +  
    scale_x_continuous(breaks = 0:23) +  
    labs(  
      title = "Proporción de accidentes con víctimas por hora",  
      x = "Hora del día",  
      y = "Proporción",  
      fill = "Clase"  
    )  
}
```

### 3.21 Relación entre día de la semana y presencia de víctimas

```
if (!is.null(atus_ml)) {
  ggplot(atus_ml, aes(x = DIASEMANA, fill = accidente_con_victimas)) +
    geom_bar(position = "fill") +
    coord_flip() +
    labs(
      title = "Proporción de accidentes con víctimas por día de la semana",
      x = "Día de la semana",
      y = "Proporción",
      fill = "Clase"
    )
}
```

### 3.22 Tabla resumen por clase

```
if (!is.null(atus_ml)) {
  resumen_clase <- atus_ml |>
    group_by(accidente_con_victimas) |>
    summarise(
      total = n(),
      hora_promedio = mean(ID_HORA_NUM, na.rm = TRUE),
      hora_minima = min(ID_HORA_NUM, na.rm = TRUE),
      hora_maxima = max(ID_HORA_NUM, na.rm = TRUE),
      .groups = "drop"
    )

  resumen_clase
}
```

### 3.23 Conclusión

En este capítulo aprendimos a cargar una base preparada, revisar dimensiones, analizar la variable respuesta, construir tablas de frecuencia, graficar accidentes por mes, hora, día, tipo y causa, e interpretar patrones iniciales.

En el siguiente capítulo construiremos nuestro primer modelo supervisado para clasificación: una **regresión logística**.

## Chapter 4

# Regresión logística para clasificación

### 4.1 Objetivos del capítulo

Al finalizar este capítulo, el lector será capaz de:

- Explicar qué es un problema de clasificación binaria.
- Comprender la idea intuitiva de la regresión logística.
- Dividir una base de datos en entrenamiento y prueba.
- Ajustar un modelo de regresión logística en R.
- Construir una matriz de confusión.
- Calcular exactitud, sensibilidad y especificidad.

### 4.2 Introducción

El problema que vamos a estudiar es:

¿Podemos estimar la probabilidad de que un accidente de tránsito tenga víctimas?

La variable que queremos predecir es `accidente_con_victimas`.

### 4.3 La función logística

La regresión logística utiliza una función especial llamada **función logística**.

$$p = \frac{1}{1 + e^{-z}}$$

donde:

$$z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p$$

### 4.4 Fundamento matemático de la regresión logística

En clasificación binaria, la variable respuesta puede representarse como:

$$Y_i = \begin{cases} 1, & \text{si el accidente tiene víctimas} \\ 0, & \text{si el accidente es de solo daños} \end{cases}$$

La regresión logística estima:

$$P(Y_i = 1 \mid X_i) = \hat{p}_i$$

La probabilidad estimada se calcula mediante:

$$\hat{p}_i = \frac{1}{1 + e^{-z_i}}$$

donde:

$$z_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip}$$

La función logística garantiza que:

$$0 \leq \hat{p}_i \leq 1$$

## 4.5 Logit y razón de momios

La regresión logística también puede escribirse mediante la función logit:

$$\log \left( \frac{p_i}{1 - p_i} \right) = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip}$$

Cuando aplicamos la función exponencial a un coeficiente, obtenemos un **odds ratio**:

$$OR_j = e^{\beta_j}$$

## 4.6 Regla de clasificación

Una vez estimada la probabilidad  $\hat{p}_i$ , se elige un punto de corte  $c$ .

$$\hat{Y}_i = \begin{cases} 1, & \text{si } \hat{p}_i \geq c \\ 0, & \text{si } \hat{p}_i < c \end{cases}$$

## 4.7 Algoritmo de regresión logística

Algoritmo: Regresión logística para clasificación binaria

Entrada:

- Matriz de variables predictoras X

- Variable respuesta binaria Y
- Punto de corte c

Proceso:

1. Codificar la variable respuesta como 0 y 1.
2. Estimar los coeficientes beta del modelo logístico.
3. Calcular  $z = \text{beta}_0 + \text{beta}_1 x_1 + \dots + \text{beta}_p x_p$ .
4. Transformar z mediante la función logística.
5. Obtener la probabilidad estimada p.
6. Comparar p contra el punto de corte c.
7. Clasificar como clase positiva o negativa.
8. Calcular matriz de confusión y métricas.

Salida:

- Probabilidades predichas
- Clases predichas
- Matriz de confusión
- Exactitud, sensibilidad y especificidad

## 4.8 Visualización de la función logística

```
z <- seq(-10, 10, length.out = 200)
p <- 1 / (1 + exp(-z))
datos_logistica <- data.frame(z = z, p = p)

library(ggplot2)

ggplot(datos_logistica, aes(x = z, y = p)) +
  geom_line(linewidth = 1) +
  labs(title = "Función logística", x = "z", y = "Probabilidad")
```

## 4.9 Cargar paquetes

```
library(readr)
library(dplyr)
library(ggplot2)
```

## 4.10 Cargar la base preparada

```
ruta_atus_ml <- "datos/atus_ml_preparado.csv"
file.exists(ruta_atus_ml)

if (file.exists(ruta_atus_ml)) {
  atus_ml <- read_csv(ruta_atus_ml, show_col_types = FALSE)
```

```

print("Base preparada cargada correctamente.")
} else {
  atus_ml <- NULL
  print("No se encontró el archivo datos/atus_ml_preparado.csv. Ejecuta primero el capítulo 2.")
}

```

## 4.11 Preparar variables para el modelo

```

if (!is.null(atus_ml)) {
  atus_modelo <- atus_ml |>
    mutate(
      victimas_binaria = ifelse(accidente_con_victimas == "Con víctimas", 1, 0),
      MES = as.factor(MES),
      DIASEMANA = as.factor(DIASEMANA),
      TIPACCID = as.factor(TIPACCID),
      CAUSAACCI = as.factor(CAUSAACCI),
      ID_HORA = as.numeric(ID_HORA),
      accidente_con_victimas = factor(accidente_con_victimas, levels = c("Con víctimas", "Solo
    )
}

```

## 4.12 División en entrenamiento y prueba

```

if (exists("atus_modelo")) {
  set.seed(123)
  n <- nrow(atus_modelo)
  indices_entrenamiento <- sample(1:n, size = round(0.7 * n))
  entrenamiento <- atus_modelo[indices_entrenamiento, ]
  prueba <- atus_modelo[-indices_entrenamiento, ]
}

if (exists("entrenamiento") && exists("prueba")) {
  data.frame(
    conjunto = c("Entrenamiento", "Prueba"),
    registros = c(nrow(entrenamiento), nrow(prueba)),
    porcentaje = c(
      round(100 * nrow(entrenamiento) / nrow(atus_modelo), 2),
      round(100 * nrow(prueba) / nrow(atus_modelo), 2)
    )
  )
}

```



## 4.13 Ajustar el modelo de regresión logística

```
if (exists("entrenamiento")) {
  modelo_logistico <- glm(
    victimas_binaria ~ MES + ID_HORA + DIASEMANA + TIPACCID + CAUSAACCI,
    data = entrenamiento,
    family = binomial
  )
}
```

```
if (exists("modelo_logistico")) {
  summary(modelo_logistico)
}
```

Nota didáctica: si aparece el mensaje “1 not defined because of singularities”, significa que una categoría no pudo estimarse de forma independiente.

## 4.14 Predicción de probabilidades

```
if (exists("modelo_logistico") && exists("prueba")) {
  prueba$probabilidad_victimas <- predict(
    modelo_logistico,
    newdata = prueba,
    type = "response"
  )
}
```

## 4.15 De probabilidades a clases

```
if (exists("prueba")) {
  prueba$prediccion_05 <- ifelse(
    prueba$probabilidad_victimas >= 0.5,
    "Con víctimas",
    "Solo daños"
  )

  prueba$prediccion_05 <- factor(prueba$prediccion_05, levels = c("Con víctimas", "Solo daños"))
}
```

## 4.16 Matriz de confusión

```
if (exists("prueba")) {
  matriz_confusion_05 <- table(
    Real = prueba$accidente_con_victimas,
    Predicho = prueba$prediccion_05
  )
}
```

```

)

matriz_confusion_05
}

```

## 4.17 Métricas de evaluación

```

if (exists("matriz_confusion_05")) {
  VP <- matriz_confusion_05["Con víctimas", "Con víctimas"]
  FN <- matriz_confusion_05["Con víctimas", "Solo daños"]
  FP <- matriz_confusion_05["Solo daños", "Con víctimas"]
  VN <- matriz_confusion_05["Solo daños", "Solo daños"]

  data.frame(
    medida = c("VP", "FN", "FP", "VN"),
    nombre = c("Verdaderos positivos", "Falsos negativos", "Falsos positivos", "Verdaderos negativos"),
    valor = c(VP, FN, FP, VN)
  )
}

```

## 4.18 Fórmulas de evaluación para clasificación binaria

La exactitud se calcula como:

$$\text{Exactitud} = \frac{VP + VN}{VP + FN + FP + VN}$$

La sensibilidad se calcula como:

$$\text{Sensibilidad} = \frac{VP}{VP + FN}$$

La especificidad se calcula como:

$$\text{Especificidad} = \frac{VN}{VN + FP}$$

La precisión se calcula como:

$$\text{Precisión} = \frac{VP}{VP + FP}$$

```

if (exists("VP")) {
  exactitud <- (VP + VN) / (VP + FN + FP + VN)
  sensibilidad <- VP / (VP + FN)
  especificidad <- VN / (VN + FP)
}

```

```
data.frame(
  punto_corte = 0.5,
  exactitud = exactitud,
  sensibilidad = sensibilidad,
  especificidad = especificidad
)
}
```

## 4.19 Clasificación con punto de corte 0.3

```
if (exists("prueba")) {
  prueba$prediccion_03 <- ifelse(
    prueba$probabilidad_victimas >= 0.3,
    "Con víctimas",
    "Solo daños"
  )
  prueba$prediccion_03 <- factor(prueba$prediccion_03, levels = c("Con víctimas", "Solo daños"))
}
```

```
if (exists("prueba")) {
  matriz_confusion_03 <- table(
    Real = prueba$accidente_con_victimas,
    Predicho = prueba$prediccion_03
  )
  matriz_confusion_03
}
```

```
if (exists("matriz_confusion_03")) {
  VP_03 <- matriz_confusion_03["Con víctimas", "Con víctimas"]
  FN_03 <- matriz_confusion_03["Con víctimas", "Solo daños"]
  FP_03 <- matriz_confusion_03["Solo daños", "Con víctimas"]
  VN_03 <- matriz_confusion_03["Solo daños", "Solo daños"]

  exactitud_03 <- (VP_03 + VN_03) / (VP_03 + FN_03 + FP_03 + VN_03)
  sensibilidad_03 <- VP_03 / (VP_03 + FN_03)
  especificidad_03 <- VN_03 / (VN_03 + FP_03)

  data.frame(
    punto_corte = 0.3,
    exactitud = exactitud_03,
    sensibilidad = sensibilidad_03,
    especificidad = especificidad_03
  )
}
```

## 4.20 Comparación de puntos de corte

```
if (exists("exactitud") && exists("exactitud_03")) {  
  data.frame(  
    punto_corte = c(0.5, 0.3),  
    exactitud = c(exactitud, exactitud_03),  
    sensibilidad = c(sensibilidad, sensibilidad_03),  
    especificidad = c(especificidad, especificidad_03)  
  )  
}
```

## 4.21 Distribución de probabilidades predichas

```
if (exists("prueba")) {  
  ggplot(prueba, aes(x = probabilidad_victimas, fill = accidente_con_victimas)) +  
    geom_histogram(bins = 30, alpha = 0.7, position = "identity") +  
    labs(  
      title = "Distribución de probabilidades predichas",  
      x = "Probabilidad predicha de accidente con víctimas",  
      y = "Frecuencia",  
      fill = "Clase real"  
    )  
}
```

## 4.22 Odds ratios

```
if (exists("modelo_logistico")) {  
  odds_ratios <- data.frame(  
    variable = names(coef(modelo_logistico)),  
    odds_ratio = exp(coef(modelo_logistico))  
  )  
  
  head(odds_ratios, 15)  
}
```

## 4.23 Conclusión

La regresión logística es uno de los modelos más importantes para clasificación binaria. En el siguiente capítulo estudiaremos **k vecinos más cercanos**, conocido como **k-NN**.

## Chapter 5

# k vecinos más cercanos, k-NN

### 5.1 Objetivos del capítulo

Al finalizar este capítulo, el lector será capaz de:

- Explicar la idea intuitiva del método k vecinos más cercanos.
- Comprender el papel de la distancia en k-NN.
- Calcular distancias entre observaciones.
- Explicar por qué es necesario escalar las variables numéricas.
- Aplicar k-NN en R para un problema de clasificación.
- Construir una matriz de confusión.
- Calcular exactitud, sensibilidad y especificidad.

### 5.2 Introducción

k-NN significa *k-Nearest Neighbors* o **k vecinos más cercanos**.

La idea básica es:

Para clasificar una nueva observación, buscamos las observaciones más parecidas a ella y le asignamos la clase más frecuente entre sus vecinos.

### 5.3 Idea intuitiva del método

El algoritmo k-NN hace lo siguiente:

1. Calcula la distancia entre la nueva observación y las observaciones históricas.
2. Encuentra los  $k$  vecinos más cercanos.
3. Revisa la clase de esos vecinos.
4. Asigna la clase más frecuente.

### 5.4 ¿Qué significa k?

La letra  $k$  indica cuántos vecinos se usarán para clasificar una observación.

Si  $k$  es muy pequeño, el modelo puede ser muy sensible al ruido. Si  $k$  es muy grande, el modelo puede volverse demasiado general.

## 5.5 Ejemplo sencillo con puntos

```
datos_ejemplo <- data.frame(
  hora = c(8, 9, 10, 18, 19, 20, 22, 23),
  mes = c(1, 1, 2, 6, 6, 7, 12, 12),
  clase = c(
    "Solo daños", "Solo daños", "Solo daños",
    "Con víctimas", "Con víctimas", "Con víctimas",
    "Con víctimas", "Con víctimas"
  )
)

datos_ejemplo
```

```
library(ggplot2)

ggplot(datos_ejemplo, aes(x = hora, y = mes, color = clase)) +
  geom_point(size = 4) +
  labs(
    title = "Ejemplo intuitivo de k-NN",
    x = "Hora",
    y = "Mes",
    color = "Clase"
  )
```

## 5.6 Distancia euclidiana

Para dos puntos:

$$A = (x_1, y_1)$$

y

$$B = (x_2, y_2)$$

la distancia euclidiana es:

$$d(A, B) = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$$

## 5.7 Fundamento matemático de k-NN

Sea  $x_0$  una nueva observación que queremos clasificar.

Sea  $x_i$  una observación del conjunto de entrenamiento.

Si tenemos  $p$  variables predictoras, podemos escribir:

$$x_0 = (x_{01}, x_{02}, \dots, x_{0p})$$

y

$$x_i = (x_{i1}, x_{i2}, \dots, x_{ip})$$

La distancia euclidiana entre  $x_0$  y  $x_i$  se define como:

$$d(x_0, x_i) = \sqrt{\sum_{j=1}^p (x_{0j} - x_{ij})^2}$$

Después se seleccionan las  $k$  observaciones con menor distancia.

Si las clases de los  $k$  vecinos más cercanos son:

$$y_{(1)}, y_{(2)}, \dots, y_{(k)}$$

entonces la clase predicha se obtiene por mayoría de votos:

$$\hat{y}_0 = \text{moda}(y_{(1)}, y_{(2)}, \dots, y_{(k)})$$

## 5.8 Ejemplo de cálculo de distancia

```
x1 <- 8
y1 <- 1
x2 <- 10
y2 <- 2

distancia <- sqrt((x1 - x2)^2 + (y1 - y2)^2)
distancia
```

## 5.9 Estandarización de variables

Como k-NN depende de distancias, es importante que las variables estén en escalas comparables.

Una forma común de estandarizar una variable  $X_j$  es:

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$$

donde  $\bar{x}_j$  es la media de la variable  $j$  y  $s_j$  es su desviación estándar.

## 5.10 Algoritmo k-NN

Algoritmo: k vecinos más cercanos

Entrada:

- Matriz de entrenamiento X
- Clases de entrenamiento Y
- Nueva observación  $x_0$
- Número de vecinos k

Proceso:

1. Estandarizar las variables predictoras.
2. Calcular la distancia entre  $x_0$  y cada observación de entrenamiento.
3. Ordenar las distancias de menor a mayor.
4. Seleccionar los k vecinos más cercanos.
5. Revisar las clases de esos k vecinos.
6. Contar cuántas veces aparece cada clase.
7. Asignar a  $x_0$  la clase más frecuente.

Salida:

- Clase predicha para  $x_0$

## 5.11 Cargar paquetes

```
library(readr)
library(dplyr)
library(ggplot2)
library(class)
library(tidyr)
```

## 5.12 Cargar la base preparada

```
ruta_atus_ml <- "datos/atus_ml_preparado.csv"
file.exists(ruta_atus_ml)
```

```
if (file.exists(ruta_atus_ml)) {
  atus_ml <- read_csv(ruta_atus_ml, show_col_types = FALSE)
  print("Base preparada cargada correctamente.")
} else {
  atus_ml <- NULL
  print("No se encontró el archivo datos/atus_ml_preparado.csv. Ejecuta primero el capítulo 2.")
}
```



## 5.13 Selección de una muestra para k-NN

```
if (!is.null(atus_ml)) {
  set.seed(123)
  tamaño_muestra <- min(12000, nrow(atus_ml))
  atus_knn_base <- atus_ml |>
    sample_n(tamaño_muestra)
  dim(atus_knn_base)
}
```

## 5.14 Preparar variables para k-NN

```
if (exists("atus_knn_base")) {
  atus_knn_base <- atus_knn_base |>
    mutate(
      accidente_con_victimas = factor(accidente_con_victimas, levels = c("Con víctimas", "Solo
      MES = as.factor(MES),
      ID_HORA = as.numeric(ID_HORA),
      DIASEMANA = as.factor(DIASEMANA),
      TIPACCID = as.factor(TIPACCID),
      CAUSAACCI = as.factor(CAUSAACCI)
    ) |>
    na.omit()
}
```

```
if (exists("atus_knn_base")) {
  table(atus_knn_base$accidente_con_victimas)
  round(100 * prop.table(table(atus_knn_base$accidente_con_victimas)), 2)
}
```

## 5.15 Crear variables dummy

```
if (exists("atus_knn_base")) {
  matriz_predictoras <- model.matrix(
    ~ ID_HORA + MES + DIASEMANA + TIPACCID + CAUSAACCI - 1,
    data = atus_knn_base
  )

  dim(matriz_predictoras)
}
```

```
if (exists("atus_knn_base")) {
  y <- atus_knn_base$accidente_con_victimas
}
```

### 5.16 División en entrenamiento y prueba

```
if (exists("matriz_predictoras") && exists("y")) {
  set.seed(123)
  n <- nrow(matriz_predictoras)
  indices_entrenamiento <- sample(1:n, size = round(0.7 * n))
  x_entrenamiento <- matriz_predictoras[indices_entrenamiento, ]
  x_prueba <- matriz_predictoras[-indices_entrenamiento, ]
  y_entrenamiento <- y[indices_entrenamiento]
  y_prueba <- y[-indices_entrenamiento]
}

if (exists("x_entrenamiento") && exists("x_prueba")) {
  data.frame(
    conjunto = c("Entrenamiento", "Prueba"),
    registros = c(nrow(x_entrenamiento), nrow(x_prueba)),
    porcentaje = c(
      round(100 * nrow(x_entrenamiento) / nrow(matriz_predictoras), 2),
      round(100 * nrow(x_prueba) / nrow(matriz_predictoras), 2)
    )
  )
}
```

### 5.17 Estandarización de variables

```
if (exists("x_entrenamiento") && exists("x_prueba")) {
  medias <- apply(x_entrenamiento, 2, mean)
  desviaciones <- apply(x_entrenamiento, 2, sd)
  desviaciones[desviaciones == 0] <- 1

  x_entrenamiento_esc <- scale(x_entrenamiento, center = medias, scale = desviaciones)
  x_prueba_esc <- scale(x_prueba, center = medias, scale = desviaciones)
}
```

### 5.18 Ajuste del modelo k-NN con $k = 5$

```
if (exists("x_entrenamiento_esc") && exists("x_prueba_esc")) {
  pred_knn_5 <- knn(
    train = x_entrenamiento_esc,
    test = x_prueba_esc,
    cl = y_entrenamiento,
    k = 5
  )
}
```

## 5.19 Matriz de confusión

```
if (exists("pred_knn_5")) {  
  pred_knn_5 <- factor(pred_knn_5, levels = c("Con víctimas", "Solo daños"))  
  y_prueba <- factor(y_prueba, levels = c("Con víctimas", "Solo daños"))  
  
  matriz_confusion_knn_5 <- table(  
    Real = y_prueba,  
    Predicho = pred_knn_5  
  )  
  
  matriz_confusion_knn_5  
}
```

## 5.20 Métricas de evaluación

```
if (exists("matriz_confusion_knn_5")) {  
  VP <- matriz_confusion_knn_5["Con víctimas", "Con víctimas"]  
  FN <- matriz_confusion_knn_5["Con víctimas", "Solo daños"]  
  FP <- matriz_confusion_knn_5["Solo daños", "Con víctimas"]  
  VN <- matriz_confusion_knn_5["Solo daños", "Solo daños"]  
  
  exactitud_knn_5 <- (VP + VN) / (VP + FN + FP + VN)  
  sensibilidad_knn_5 <- VP / (VP + FN)  
  especificidad_knn_5 <- VN / (VN + FP)  
  
  data.frame(  
    k = 5,  
    exactitud = exactitud_knn_5,  
    sensibilidad = sensibilidad_knn_5,  
    especificidad = especificidad_knn_5  
  )  
}
```

## 5.21 Comparación con distintos valores de k

```
calcular_metricas <- function(real, predicho) {  
  real <- factor(real, levels = c("Con víctimas", "Solo daños"))  
  predicho <- factor(predicho, levels = c("Con víctimas", "Solo daños"))  
  
  matriz <- table(Real = real, Predicho = predicho)  
  
  VP <- matriz["Con víctimas", "Con víctimas"]  
  FN <- matriz["Con víctimas", "Solo daños"]  
  FP <- matriz["Solo daños", "Con víctimas"]  
  VN <- matriz["Solo daños", "Solo daños"]  
}
```

```

exactitud <- (VP + VN) / (VP + FN + FP + VN)
sensibilidad <- VP / (VP + FN)
especificidad <- VN / (VN + FP)

data.frame(exactitud = exactitud, sensibilidad = sensibilidad, especificidad = especificidad)
}

if (exists("x_entrenamiento_esc") && exists("x_prueba_esc")) {
  valores_k <- c(3, 5, 11)
  resultados_knn <- data.frame()

  for (k_actual in valores_k) {
    pred_actual <- knn(
      train = x_entrenamiento_esc,
      test = x_prueba_esc,
      cl = y_entrenamiento,
      k = k_actual
    )

    metricas_actuales <- calcular_metricas(y_prueba, pred_actual)
    metricas_actuales$k <- k_actual
    resultados_knn <- rbind(resultados_knn, metricas_actuales)
  }

  resultados_knn <- resultados_knn |>
    select(k, exactitud, sensibilidad, especificidad)

  resultados_knn
}

if (exists("resultados_knn")) {
  resultados_largos <- resultados_knn |>
    pivot_longer(
      cols = c(exactitud, sensibilidad, especificidad),
      names_to = "metrica",
      values_to = "valor"
    )

  ggplot(resultados_largos, aes(x = k, y = valor, group = metrica)) +
    geom_line() +
    geom_point(size = 3) +
    scale_x_continuous(breaks = valores_k) +
    labs(
      title = "Comparación de métricas para distintos valores de k",
      x = "Valor de k",
      y = "Valor de la métrica"
    )
}

```

}

## 5.22 Comparación conceptual con regresión logística

| Aspecto                  | Regresión logística | k-NN                   |
|--------------------------|---------------------|------------------------|
| Tipo de modelo           | Paramétrico         | No paramétrico         |
| Produce modelo explícito | Sí                  | No en el mismo sentido |
| Usa distancias           | No                  | Sí                     |
| Requiere escalamiento    | No siempre          | Sí                     |
| Interpretable            | Alta                | Media o baja           |

## 5.23 Conclusión

k-NN es uno de los métodos más intuitivos del aprendizaje automático.

Aunque es sencillo de explicar, requiere cuidado en la preparación de los datos, especialmente en el escalamiento y en el tratamiento de variables categóricas.

En el siguiente capítulo estudiaremos un método muy importante por su interpretabilidad: **árboles de decisión**.

