

Aprendizaje y Clasificación Automática con R

Un enfoque práctico con datos abiertos reales

MI. Gilberto Rodríguez

2026-07-07

Table of contents

Presentación	1
Objetivo general	1
Público al que va dirigido	1
Software utilizado	1
Estructura inicial del libro	1
1 ¿Qué es el aprendizaje automático?	3
1.1 Objetivos del capítulo	3
1.2 Introducción	3
1.3 Programación tradicional contra aprendizaje automático	3
1.4 Variables predictoras y variable respuesta	4
1.5 Notación básica para aprendizaje automático	5
1.6 Algoritmo general de aprendizaje supervisado	5
1.7 Aprendizaje supervisado	6
1.8 Clasificación	6
1.9 Regresión	6
1.10 Aprendizaje no supervisado	6
1.11 Flujo general de un proyecto de aprendizaje automático	6
1.12 Primer ejemplo visual en R	7
1.13 División entre entrenamiento y prueba	8
1.14 Primer clasificador sencillo basado en una regla	8
1.15 Conclusión	9
2 Preparación de datos reales	11
2.1 Objetivos del capítulo	11
2.2 Introducción	11
2.3 Datos crudos y datos preparados	11
2.4 Representación matemática de una base preparada	11
2.5 Algoritmo general de preparación de datos	12
2.6 Conjunto de datos de trabajo: ATUS	12
2.7 Crear la carpeta de datos	13
2.8 Cargar paquetes	13
2.9 Leer el archivo CSV	13
2.10 Primer vistazo a los datos	14
2.11 Estandarizar nombres de variables	14
2.12 Variables de interés	15

2.13	Diccionario inicial de variables	16
2.14	Revisión de la variable CLASACC	16
2.15	Crear una variable respuesta	17
2.16	Eliminar registros sin variable respuesta	18
2.17	Convertir variables categóricas	18
2.18	Revisión de datos faltantes	19
2.19	Selección final de variables para el primer modelo	20
2.20	Guardar la base preparada	21
2.21	Resumen del capítulo	21
3	Análisis exploratorio de datos	23
3.1	Objetivos del capítulo	23
3.2	Introducción	23
3.3	Fundamento matemático del análisis exploratorio	23
3.4	Proporciones condicionales	24
3.5	Algoritmo general del análisis exploratorio	24
3.6	Cargar paquetes	25
3.7	Cargar la base preparada	25
3.8	Preparar variables para el análisis exploratorio	26
3.9	Primer vistazo a la base	26
3.10	Estructura de los datos	27
3.11	Distribución de la variable respuesta	27
3.12	Interpretación de la variable respuesta	28
3.13	Gráfica de la variable respuesta	28
3.14	Accidentes por mes	29
3.15	Accidentes por hora del día	31
3.16	Accidentes por día de la semana	33
3.17	Accidentes por tipo de accidente	35
3.18	Accidentes por causa presunta	37
3.19	Relación entre tipo de accidente y presencia de víctimas	38
3.20	Relación entre hora y presencia de víctimas	39
3.21	Relación entre día de la semana y presencia de víctimas	40
3.22	Tabla resumen por clase	41
3.23	Conclusión	42
4	Regresión logística para clasificación	43
4.1	Objetivos del capítulo	43
4.2	Introducción	43
4.3	La función logística	43
4.4	Fundamento matemático de la regresión logística	44
4.5	Logit y razón de momios	44
4.6	Regla de clasificación	44
4.7	Algoritmo de regresión logística	45
4.8	Visualización de la función logística	45
4.9	Cargar paquetes	46
4.10	Cargar la base preparada	47
4.11	Preparar variables para el modelo	47
4.12	División en entrenamiento y prueba	48

4.13	Ajustar el modelo de regresión logística	49
4.14	Predicción de probabilidades	51
4.15	De probabilidades a clases	52
4.16	Matriz de confusión	52
4.17	Métricas de evaluación	53
4.18	Fórmulas de evaluación para clasificación binaria	53
4.19	Clasificación con punto de corte 0.3	54
4.20	Comparación de puntos de corte	56
4.21	Distribución de probabilidades predichas	56
4.22	Odds ratios	57
4.23	Conclusión	58
5	k vecinos más cercanos, k-NN	59
5.1	Objetivos del capítulo	59
5.2	Introducción	59
5.3	Idea intuitiva del método	59
5.4	¿Qué significa k?	60
5.5	Ejemplo sencillo con puntos	60
5.6	Distancia euclidiana	61
5.7	Fundamento matemático de k-NN	62
5.8	Ejemplo de cálculo de distancia	62
5.9	Estandarización de variables	63
5.10	Algoritmo k-NN	63
5.11	Cargar paquetes	63
5.12	Cargar la base preparada	64
5.13	Selección de una muestra para k-NN	64
5.14	Preparar variables para k-NN	65
5.15	Crear variables dummy	66
5.16	División en entrenamiento y prueba	66
5.17	Estandarización de variables	67
5.18	Ajuste del modelo k-NN con $k = 5$	68
5.19	Matriz de confusión	68
5.20	Métricas de evaluación	69
5.21	Comparación con distintos valores de k	69
5.22	Comparación conceptual con regresión logística	72
5.23	Conclusión	72

Presentación

Este libro introduce el aprendizaje automático (*Machine Learning*) mediante ejemplos claros, didácticos y prácticos desarrollados principalmente en R.

El propósito no es presentar un tratado matemático extenso, sino construir una guía aplicada que permita aprender haciendo con datos abiertos reales.

Objetivo general

Desarrollar competencias básicas e intermedias en aprendizaje automático mediante el análisis, modelado e interpretación de datos reales.

Público al que va dirigido

Este libro está dirigido a estudiantes de ingeniería, ciencias, ciencia de datos, estadística aplicada y áreas afines.

Software utilizado

Los ejemplos se desarrollan principalmente en R, utilizando RStudio y Quarto.

También se podrán utilizar herramientas como:

- RStudio
- Consola de R
- Google Colab
- GitHub
- GitHub Pages
- Quarto Pub

Estructura inicial del libro

1. Introducción al aprendizaje automático.
2. Preparación de datos reales.
3. Análisis exploratorio de datos.
4. Regresión logística.
5. k vecinos más cercanos.

Chapter 1

¿Qué es el aprendizaje automático?

Explicación del código.

Este bloque muestra una operación básica en R para construir, revisar o transformar datos.

Interpretación del resultado.

La salida ayuda a verificar que el procedimiento se realizó correctamente y prepara el camino para el análisis posterior.

1.1 Objetivos del capítulo

Al finalizar este capítulo, el lector será capaz de:

- Explicar qué es el aprendizaje automático.
- Diferenciar entre programación tradicional y aprendizaje automático.
- Identificar problemas de clasificación, regresión y agrupamiento.
- Reconocer las etapas principales de un proyecto de aprendizaje automático.
- Reconocer la notación matemática básica usada en aprendizaje automático.

1.2 Introducción

El aprendizaje automático, también conocido como *Machine Learning*, es una rama de la inteligencia artificial que permite construir modelos capaces de aprender patrones a partir de datos.

La idea central será:

Aprender Machine Learning haciendo proyectos con datos reales.

1.3 Programación tradicional contra aprendizaje automático

En la programación tradicional, una persona escribe reglas explícitas.

```
pm10 <- 85

if (pm10 > 75) {
  print("Contaminación alta")
} else {
```

```
print("Contaminación baja")
}
```

```
[1] "Contaminación alta"
```

Explicación del código.

Este bloque muestra una operación básica en R para construir, revisar o transformar datos.

Interpretación del resultado.

La salida ayuda a verificar que el procedimiento se realizó correctamente y prepara el camino para el análisis posterior.

En aprendizaje automático no le damos al sistema una regla fija. Le damos datos.

```
datos <- data.frame(
  dia = 1:12,
  pm10 = c(42, 88, 55, 120, 63, 95, 38, 110, 72, 130, 47, 99),
  temperatura = c(25, 28, 22, 30, 24, 29, 21, 31, 27, 32, 23, 30),
  humedad = c(40, 35, 60, 30, 55, 33, 65, 29, 42, 28, 62, 34),
  clase = c("Baja", "Alta", "Baja", "Alta", "Baja", "Alta", "Baja", "Alta", "Baja", "Alta", "Baja", "Alta")
)

datos
```

	dia	pm10	temperatura	humedad	clase
1	1	42	25	40	Baja
2	2	88	28	35	Alta
3	3	55	22	60	Baja
4	4	120	30	30	Alta
5	5	63	24	55	Baja
6	6	95	29	33	Alta
7	7	38	21	65	Baja
8	8	110	31	29	Alta
9	9	72	27	42	Baja
10	10	130	32	28	Alta
11	11	47	23	62	Baja
12	12	99	30	34	Alta

Explicación del código.

Este bloque muestra una operación básica en R para construir, revisar o transformar datos.

Interpretación del resultado.

La salida ayuda a verificar que el procedimiento se realizó correctamente y prepara el camino para el análisis posterior.

1.4 Variables predictoras y variable respuesta

La **variable respuesta** es la variable que queremos predecir.

Las **variables predictoras** son las variables que usamos como entrada para el modelo.

En el ejemplo anterior, la variable respuesta es `clase`, y las variables predictoras son `pm10`, `temperatura` y `humedad`.

1.5 Notación básica para aprendizaje automático

Supongamos que tenemos n observaciones y p variables predictoras. Podemos representar los datos mediante una matriz:

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix}$$

donde n es el número de observaciones, p es el número de variables predictoras y x_{ij} representa el valor de la variable j en la observación i .

La variable respuesta se representa como:

$$Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

El objetivo general del aprendizaje supervisado es encontrar una función f que permita aproximar la respuesta:

$$\hat{y} = f(x_1, x_2, \dots, x_p)$$

donde $\hat{y}$ es la predicción del modelo, $x_1, x_2, \dots, x_p$ son las variables predictoras, y f es la función aprendida a partir de los datos.

1.6 Algoritmo general de aprendizaje supervisado

Algoritmo: Aprendizaje supervisado

Entrada:

- Matriz de datos X
- Variable respuesta Y
- Algoritmo de aprendizaje

Proceso:

1. Dividir los datos en entrenamiento y prueba.
2. Usar los datos de entrenamiento para aprender una función f .
3. Usar la función f para predecir nuevas respuestas.
4. Comparar las predicciones contra los valores reales.
5. Calcular métricas de desempeño.

6. Interpretar los resultados.

Salida:

- Modelo entrenado
- Predicciones
- Métricas de evaluación

1.7 Aprendizaje supervisado

El aprendizaje supervisado se utiliza cuando tenemos una variable respuesta conocida.

Dentro del aprendizaje supervisado hay dos tareas muy importantes:

- clasificación;
- regresión.

1.8 Clasificación

La clasificación se utiliza cuando la variable respuesta es categórica.

Ejemplos:

- Alta o baja contaminación.
- Accidente con víctimas o solo daños.
- Tumor benigno o maligno.

1.9 Regresión

La regresión se utiliza cuando la variable respuesta es numérica.

Ejemplos:

- Predecir concentración de PM10.
- Predecir temperatura.
- Predecir ventas.

1.10 Aprendizaje no supervisado

El aprendizaje no supervisado se utiliza cuando no tenemos una variable respuesta conocida. En lugar de predecir una etiqueta, buscamos patrones ocultos en los datos.

1.11 Flujo general de un proyecto de aprendizaje automático


1. Plantear el problema
2. Conseguir los datos
3. Entender las variables
4. Limpiar los datos
5. Explorar los datos

6. Dividir en entrenamiento y prueba
7. Entrenar el modelo
8. Evaluar el modelo
9. Interpretar los resultados
10. Comunicar hallazgos

1.12 Primer ejemplo visual en R

```
library(ggplot2)

ggplot(datos, aes(x = pm10, y = temperatura, color = clase)) +
  geom_point(size = 4) +
  labs(
    title = "Ejemplo inicial de clasificación",
    subtitle = "Clasificación de contaminación alta o baja",
    x = "PM10",
    y = "Temperatura",
    color = "Clase"
  )
```



Explicación del código.

Este bloque muestra una operación básica en R para construir, revisar o transformar datos.

Interpretación del resultado.

La salida ayuda a verificar que el procedimiento se realizó correctamente y prepara el camino para el análisis posterior.

1.13 División entre entrenamiento y prueba

```
set.seed(123)

n <- nrow(datos)
indices_entrenamiento <- sample(1:n, size = round(0.7 * n))

entrenamiento <- datos[indices_entrenamiento, ]
prueba <- datos[-indices_entrenamiento, ]

entrenamiento
```

	dia	pm10	temperatura	humedad	clase
3	3	55	22	60	Baja
12	12	99	30	34	Alta
10	10	130	32	28	Alta
2	2	88	28	35	Alta
6	6	95	29	33	Alta
11	11	47	23	62	Baja
5	5	63	24	55	Baja
4	4	120	30	30	Alta

```
prueba
```

	dia	pm10	temperatura	humedad	clase
1	1	42	25	40	Baja
7	7	38	21	65	Baja
8	8	110	31	29	Alta
9	9	72	27	42	Baja

Explicación del código.

Este bloque muestra una operación básica en R para construir, revisar o transformar datos.

Interpretación del resultado.

La salida ayuda a verificar que el procedimiento se realizó correctamente y prepara el camino para el análisis posterior.

1.14 Primer clasificador sencillo basado en una regla

```
datos$prediccion_regla <- ifelse(datos$pm10 > 75, "Alta", "Baja")
datos[, c("pm10", "clase", "prediccion_regla")]
```

	pm10	clase	prediccion_regla
1	42	Baja	Baja
2	88	Alta	Alta
3	55	Baja	Baja

4	120	Alta	Alta
5	63	Baja	Baja
6	95	Alta	Alta
7	38	Baja	Baja
8	110	Alta	Alta
9	72	Baja	Baja
10	130	Alta	Alta
11	47	Baja	Baja
12	99	Alta	Alta

Explicación del código.

Este bloque muestra una operación básica en R para construir, revisar o transformar datos.

Interpretación del resultado.

La salida ayuda a verificar que el procedimiento se realizó correctamente y prepara el camino para el análisis posterior.

```
tabla_confusion <- table(
  Real = datos$clase,
  Predicho = datos$prediccion_regla
)

tabla_confusion
```

	Predicho	
Real	Alta	Baja
Alta	6	0
Baja	0	6

Explicación del código.

Este bloque muestra una operación básica en R para construir, revisar o transformar datos.

Interpretación del resultado.

La salida ayuda a verificar que el procedimiento se realizó correctamente y prepara el camino para el análisis posterior.

```
exactitud <- mean(datos$clase == datos$prediccion_regla)
exactitud
```

```
[1] 1
```

Explicación del código.

Este bloque muestra una operación básica en R para construir, revisar o transformar datos.

Interpretación del resultado.

La salida ayuda a verificar que el procedimiento se realizó correctamente y prepara el camino para el análisis posterior.

1.15 Conclusión

El aprendizaje automático permite construir modelos capaces de aprender patrones a partir de datos. En el siguiente capítulo comenzaremos con una parte fundamental: la preparación de datos reales.

Chapter 2

Preparación de datos reales

Explicación del código.

Este bloque muestra una operación básica en R para construir, revisar o transformar datos.

Interpretación del resultado.

La salida ayuda a verificar que el procedimiento se realizó correctamente y prepara el camino para el análisis posterior.

2.1 Objetivos del capítulo

Al finalizar este capítulo, el lector será capaz de:

- Comprender por qué la preparación de datos es una etapa fundamental en aprendizaje automático.
- Leer un conjunto de datos real en R.
- Seleccionar variables relevantes.
- Crear una variable respuesta para un problema de clasificación.
- Preparar una base lista para análisis exploratorio y modelado.

2.2 Introducción

En la práctica profesional, los datos reales casi nunca vienen preparados. Antes de aplicar cualquier algoritmo necesitamos revisar, limpiar, transformar y documentar.

2.3 Datos crudos y datos preparados

Llamaremos **datos crudos** a la base tal como se obtiene de la fuente original. Llamaremos **datos preparados** a la base que ya fue revisada, transformada y organizada para un propósito específico.

2.4 Representación matemática de una base preparada

Una base de datos para aprendizaje automático puede representarse como una matriz de variables predictoras X y una variable respuesta Y .

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix}$$

$$Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

En nuestro caso, Y representa la variable `accidente_con_victimas`.

Cuando convertimos esta variable en forma binaria, podemos escribir:

$$Y_i = \begin{cases} 1, & \text{si el accidente tiene víctimas} \\ 0, & \text{si el accidente es de solo daños} \end{cases}$$

2.5 Algoritmo general de preparación de datos

Algoritmo: Preparación de datos para aprendizaje automático

Entrada:

- Base de datos cruda
- Diccionario de variables
- Pregunta de predicción

Proceso:

1. Leer la base de datos.
2. Revisar dimensiones, nombres y tipos de variables.
3. Seleccionar variables relevantes.
4. Identificar la variable respuesta.
5. Transformar variables cuando sea necesario.
6. Revisar datos faltantes.
7. Guardar una base preparada.

Salida:

- Base limpia y lista para análisis exploratorio y modelado

2.6 Conjunto de datos de trabajo: ATUS

Trabajaremos con **Accidentes de Tránsito Terrestre en Zonas Urbanas y Suburbanas**, conocido como **ATUS**, publicado por INEGI.

La pregunta práctica será:

¿Podemos clasificar si un accidente tendrá víctimas o será solo de daños materiales?

2.7 Crear la carpeta de datos

Dentro de la carpeta del libro crea una carpeta llamada **datos**.

El archivo de datos debe llamarse:

```
datos/atus_2024.csv
```

2.8 Cargar paquetes

```
library(readr)
library(dplyr)
library(ggplot2)
library(stringr)
```

Explicación del código.

Este bloque muestra una operación básica en R para construir, revisar o transformar datos.

Interpretación del resultado.

La salida ayuda a verificar que el procedimiento se realizó correctamente y prepara el camino para el análisis posterior.

Si alguno no está instalado:

```
install.packages(c("readr", "dplyr", "ggplot2", "stringr"))
```

Explicación del código.

Este bloque muestra una operación básica en R para construir, revisar o transformar datos.

Interpretación del resultado.

La salida ayuda a verificar que el procedimiento se realizó correctamente y prepara el camino para el análisis posterior.

2.9 Leer el archivo CSV

```
ruta_atus <- "datos/atus_2024.csv"
file.exists(ruta_atus)
```

```
[1] TRUE
```

Explicación del código.

Este bloque muestra una operación básica en R para construir, revisar o transformar datos.

Interpretación del resultado.

La salida ayuda a verificar que el procedimiento se realizó correctamente y prepara el camino para el análisis posterior.

```
if (file.exists(ruta_atus)) {
  atus <- read_csv(
    file = ruta_atus,
    show_col_types = FALSE,
```

```

    locale = locale(encoding = "UTF-8")
  )
  print("Archivo leído correctamente.")
} else {
  atus <- NULL
  print("El archivo atus_2024.csv todavía no está disponible en la carpeta datos.")
}

```

```
[1] "Archivo leído correctamente."
```

Explicación del código.

Este bloque muestra una operación básica en R para construir, revisar o transformar datos.

Interpretación del resultado.

La salida ayuda a verificar que el procedimiento se realizó correctamente y prepara el camino para el análisis posterior.

2.10 Primer vistazo a los datos

```

if (!is.null(atus)) {
  dim(atus)
  head(atus)
  names(atus)
}

```

```

[1] "COBERTURA"      "ID_ENTIDAD"      "ID_MUNICIPIO"    "ANIO"            "MES"
[6] "ID_HORA"         "ID_MINUTO"       "ID_DIA"          "DIASEMANA"       "URBANA"
[11] "SUBURBANA"       "TIPACCID"        "AUTOMOVIL"       "CAMPASAJ"        "MICROBUS"
[16] "PASCAMION"       "OMNIBUS"         "TRANVIA"         "CAMIONETA"       "CAMION"
[21] "TRACTOR"         "FERROCARRI"      "MOTOCICLET"      "BICICLETA"       "OTROVEHIC"
[26] "CAUSAACCI"       "CAPAROD"         "SEXO"            "ALIENTO"         "CINTURON"
[31] "ID_EDAD"         "CONDMUERTO"      "CONDHERIDO"      "PASAMUERTO"      "PASAHERIDO"
[36] "PEATMUERTO"     "PEATHERIDO"      "CICLMUERTO"      "CICLHERIDO"      "OTROMUERTO"
[41] "OTROHERIDO"     "NEMUERTO"        "NEHERIDO"        "CLASACC"         "ESTATUS"

```

Explicación del código.

Este bloque muestra una operación básica en R para construir, revisar o transformar datos.

Interpretación del resultado.

La salida ayuda a verificar que el procedimiento se realizó correctamente y prepara el camino para el análisis posterior.

2.11 Estandarizar nombres de variables

```

if (!is.null(atus)) {
  names(atus) <- toupper(names(atus))
  names(atus)
}

```

```

[1] "COBERTURA"      "ID_ENTIDAD"      "ID_MUNICIPIO"    "ANIO"            "MES"
[6] "ID_HORA"         "ID_MINUTO"       "ID_DIA"          "DIASEMANA"       "URBANA"
[11] "SUBURBANA"       "TIPACCID"        "AUTOMOVIL"       "CAMPASAJ"        "MICROBUS"
[16] "PASCAMION"       "OMNIBUS"         "TRANVIA"         "CAMIONETA"       "CAMION"
[21] "TRACTOR"         "FERROCARRI"      "MOTOCICLET"      "BICICLETA"       "OTROVEHIC"
[26] "CAUSAACCI"       "CAPAROD"         "SEXO"            "ALIENTO"         "CINTURON"
[31] "ID_EDAD"         "CONDMUERTO"      "CONDHERIDO"      "PASAMUERTO"      "PASAHERIDO"
[36] "PEATMUERTO"      "PEATHERIDO"      "CICLMUERTO"      "CICLHERIDO"      "OTROMUERTO"
[41] "OTROHERIDO"      "NEMUERTO"        "NEHERIDO"        "CLASACC"         "ESTATUS"

```

Explicación del código.

Este bloque muestra una operación básica en R para construir, revisar o transformar datos.

Interpretación del resultado.

La salida ayuda a verificar que el procedimiento se realizó correctamente y prepara el camino para el análisis posterior.

2.12 Variables de interés

```

variables_interes <- c(
  "ANIO", "MES", "ID_ENTIDAD", "ID_MUNICIPIO",
  "ID_HORA", "ID_DIA", "DIASEMANA",
  "TIPACCID", "CAUSAACCI", "CLASACC"
)

```

Explicación del código.

Este bloque muestra una operación básica en R para construir, revisar o transformar datos.

Interpretación del resultado.

La salida ayuda a verificar que el procedimiento se realizó correctamente y prepara el camino para el análisis posterior.

```

if (!is.null(atus)) {
  variables_existentes <- intersect(variables_interes, names(atus))
  variables_existentes
}

```

```

[1] "ANIO"      "MES"      "ID_ENTIDAD" "ID_MUNICIPIO" "ID_HORA"
[6] "ID_DIA"    "DIASEMANA" "TIPACCID"   "CAUSAACCI"    "CLASACC"

```

Explicación del código.

Este bloque muestra una operación básica en R para construir, revisar o transformar datos.

Interpretación del resultado.

La salida ayuda a verificar que el procedimiento se realizó correctamente y prepara el camino para el análisis posterior.

```

if (!is.null(atus)) {
  atus_base <- atus |>
  select(all_of(variables_existentes))
}

```

```

head(atus_base)
}

# A tibble: 6 x 10
  ANIO MES ID_ENTIDAD ID_MUNICIPIO ID_HORA ID_DIA DIASEMANA TIPACCID
<dbl> <chr> <chr>      <chr>      <chr>  <chr>  <chr>      <chr>
1  2024 01    01        001        02    01    lunes    Colisión con veh~
2  2024 01    01        001        03    01    lunes    Colisión con obj~
3  2024 01    01        001        04    01    lunes    Colisión con pea~
4  2024 01    01        001        05    01    lunes    Colisión con obj~
5  2024 01    01        001        06    01    lunes    Colisión con obj~
6  2024 01    01        001        07    01    lunes    Colisión con veh~
# i 2 more variables: CAUSAACCI <chr>, CLASACC <chr>

```

Explicación del código.

Este bloque muestra una operación básica en R para construir, revisar o transformar datos.

Interpretación del resultado.

La salida ayuda a verificar que el procedimiento se realizó correctamente y prepara el camino para el análisis posterior.

2.13 Diccionario inicial de variables

Variable	Descripción didáctica
ANIO	Año del accidente
MES	Mes del accidente
ID_ENTIDAD	Clave de la entidad federativa
ID_MUNICIPIO	Clave del municipio
ID_HORA	Hora del accidente
ID_DIA	Día del mes
DIASEMANA	Día de la semana
TIPACCID	Tipo de accidente
CAUSAACCI	Causa presunta del accidente
CLASACC	Clase del accidente

2.14 Revisión de la variable CLASACC

```

if (exists("atus_base") && "CLASACC" %in% names(atus_base)) {
  table(atus_base$CLASACC, useNA = "ifany")
}

```

Fatal	No fatal	Sólo daños
4188	63920	322519

Explicación del código.

Este bloque muestra una operación básica en R para construir, revisar o transformar datos.

Interpretación del resultado.

La salida ayuda a verificar que el procedimiento se realizó correctamente y prepara el camino para el análisis posterior.

2.15 Crear una variable respuesta

```
if (exists("atus_base") && "CLASACC" %in% names(atus_base)) {
  atus_modelo <- atus_base |>
  mutate(
    CLASACC_TXT = as.character(CLASACC),
    CLASACC_TXT = str_to_lower(CLASACC_TXT),
    accidente_con_victimas = case_when(
      str_detect(CLASACC_TXT, "sólo daños") ~ "Solo daños",
      str_detect(CLASACC_TXT, "solo daños") ~ "Solo daños",
      str_detect(CLASACC_TXT, "daños") ~ "Solo daños",
      str_detect(CLASACC_TXT, "no fatal") ~ "Con víctimas",
      str_detect(CLASACC_TXT, "fatal") ~ "Con víctimas",
      CLASACC_TXT %in% c("1", "2") ~ "Con víctimas",
      CLASACC_TXT %in% c("3") ~ "Solo daños",
      TRUE ~ NA_character_
    )
  )
}
```

Explicación del código.

Este bloque muestra una operación básica en R para construir, revisar o transformar datos.

Interpretación del resultado.

La salida ayuda a verificar que el procedimiento se realizó correctamente y prepara el camino para el análisis posterior.

```
if (exists("atus_modelo")) {
  table(atus_modelo$accidente_con_victimas, useNA = "ifany")
}
```

Con víctimas	Solo daños
68108	322519

Explicación del código.

Este bloque muestra una operación básica en R para construir, revisar o transformar datos.

Interpretación del resultado.

La salida ayuda a verificar que el procedimiento se realizó correctamente y prepara el camino para el análisis posterior.

2.16 Eliminar registros sin variable respuesta

```
if (exists("atus_modelo")) {
  atus_modelo <- atus_modelo |>
    filter(!is.na(accidente_con_victimas))

  table(atus_modelo$accidente_con_victimas)
}
```

Con víctimas	Solo daños
68108	322519

Explicación del código.

Este bloque muestra una operación básica en R para construir, revisar o transformar datos.

Interpretación del resultado.

La salida ayuda a verificar que el procedimiento se realizó correctamente y prepara el camino para el análisis posterior.

2.17 Convertir variables categóricas

```
if (exists("atus_modelo")) {
  atus_modelo <- atus_modelo |>
    mutate(
      ID_ENTIDAD = as.factor(ID_ENTIDAD),
      ID_MUNICIPIO = as.factor(ID_MUNICIPIO),
      MES = as.factor(MES),
      DIASEMANA = as.factor(DIASEMANA),
      TIPACCID = as.factor(TIPACCID),
      CAUSAACCI = as.factor(CAUSAACCI),
      accidente_con_victimas = as.factor(accidente_con_victimas)
    )

  str(atus_modelo)
}
```

```
tibble [390,627 x 12] (S3: tbl_df/tbl/data.frame)
 $ ANIO          : num [1:390627] 2024 2024 2024 2024 2024 ...
 $ MES           : Factor w/ 12 levels "01","02","03",...: 1 1 1 1 1 1 1 1 1 1 ...
 $ ID_ENTIDAD    : Factor w/ 32 levels "01","02","03",...: 1 1 1 1 1 1 1 1 1 1 ...
 $ ID_MUNICIPIO  : Factor w/ 570 levels "001","002","003",...: 1 1 1 1 1 1 1 1 1 1 ...
 $ ID_HORA       : chr [1:390627] "02" "03" "04" "05" ...
 $ ID_DIA        : chr [1:390627] "01" "01" "01" "01" ...
 $ DIASEMANA     : Factor w/ 7 levels "Domingo","Jueves",...: 3 3 3 3 3 3 3 3 3 3 ...
 $ TIPACCID      : Factor w/ 13 levels "Caída de pasajero",...: 9 7 8 7 7 9 7 9 7 9 ...
 $ CAUSAACCI     : Factor w/ 6 levels "Certificado cero",...: 2 2 2 2 2 2 2 2 2 2 ...
 $ CLASACC       : chr [1:390627] "Sólo daños" "Sólo daños" "No fatal" "Sólo daños" ...
```

```
$ CLASACC_TXT           : chr [1:390627] "sólo daños" "sólo daños" "no fatal" "sólo daños" ...
$ accidente_con_victimas: Factor w/ 2 levels "Con víctimas",...: 2 2 1 2 2 1 1 2 2 2 ...
```

Explicación del código.

Este bloque muestra una operación básica en R para construir, revisar o transformar datos.

Interpretación del resultado.

La salida ayuda a verificar que el procedimiento se realizó correctamente y prepara el camino para el análisis posterior.

2.18 Revisión de datos faltantes

```
if (exists("atus_modelo")) {
  colSums(is.na(atus_modelo))
}
```

ANIO	MES	ID_ENTIDAD
0	0	0
ID_MUNICIPIO	ID_HORA	ID_DIA
0	0	0
DIASEMANA	TIPACCID	CAUSAACCI
0	0	0
CLASACC	CLASACC_TXT	accidente_con_victimas
0	0	0

Explicación del código.

Este bloque muestra una operación básica en R para construir, revisar o transformar datos.

Interpretación del resultado.

La salida ayuda a verificar que el procedimiento se realizó correctamente y prepara el camino para el análisis posterior.

```
if (exists("atus_modelo")) {
  round(100 * colSums(is.na(atus_modelo)) / nrow(atus_modelo), 2)
}
```

ANIO	MES	ID_ENTIDAD
0	0	0
ID_MUNICIPIO	ID_HORA	ID_DIA
0	0	0
DIASEMANA	TIPACCID	CAUSAACCI
0	0	0
CLASACC	CLASACC_TXT	accidente_con_victimas
0	0	0

Explicación del código.

Este bloque muestra una operación básica en R para construir, revisar o transformar datos.

Interpretación del resultado.

La salida ayuda a verificar que el procedimiento se realizó correctamente y prepara el camino para el análisis posterior.

2.19 Selección final de variables para el primer modelo

```
if (exists("atus_modelo")) {
  atus_ml <- atus_modelo |>
  select(
    accidente_con_victimas,
    MES,
    ID_HORA,
    DIASEMANA,
    TIPACCID,
    CAUSAACCI
  )

  head(atus_ml)
}
```

```
# A tibble: 6 x 6
  accidente_con_victimas MES ID_HORA DIASEMANA TIPACCID CAUSAACCI
  <fct>                  <fct> <chr>   <fct>   <fct>          <fct>
1 Solo daños            01    02    lunes   Colisión con vehícul~ Conductor
2 Solo daños            01    03    lunes   Colisión con objeto ~ Conductor
3 Con víctimas          01    04    lunes   Colisión con peatón ~ Conductor
4 Solo daños            01    05    lunes   Colisión con objeto ~ Conductor
5 Solo daños            01    06    lunes   Colisión con objeto ~ Conductor
6 Con víctimas          01    07    lunes   Colisión con vehícul~ Conductor
```

Explicación del código.

Este bloque muestra una operación básica en R para construir, revisar o transformar datos.

Interpretación del resultado.

La salida ayuda a verificar que el procedimiento se realizó correctamente y prepara el camino para el análisis posterior.

```
if (exists("atus_ml")) {
  atus_ml <- na.omit(atus_ml)
  dim(atus_ml)
}
```

```
[1] 390627      6
```

Explicación del código.

Este bloque muestra una operación básica en R para construir, revisar o transformar datos.

Interpretación del resultado.

La salida ayuda a verificar que el procedimiento se realizó correctamente y prepara el camino para el análisis posterior.

2.20 Guardar la base preparada

```
if (exists("atus_ml")) {  
  write_csv(atus_ml, "datos/atus_ml_preparado.csv")  
}
```

Explicación del código.

Este bloque muestra una operación básica en R para construir, revisar o transformar datos.

Interpretación del resultado.

La salida ayuda a verificar que el procedimiento se realizó correctamente y prepara el camino para el análisis posterior.

2.21 Resumen del capítulo

En este capítulo aprendimos a leer una base CSV, seleccionar variables, construir una variable respuesta y guardar una base preparada para aprendizaje automático.

Chapter 3

Análisis exploratorio de datos

Explicación del código.

Este bloque realiza una operación de análisis exploratorio: carga datos, transforma variables, calcula frecuencias o construye una gráfica. La finalidad es conocer mejor la estructura de la base antes de modelar.

Interpretación del resultado.

La salida debe leerse como una evidencia descriptiva: ayuda a identificar patrones, desbalances, categorías frecuentes o relaciones preliminares entre variables. No implica causalidad, pero orienta el análisis posterior.

3.1 Objetivos del capítulo

Al finalizar este capítulo, el lector será capaz de:

- Explicar qué es el análisis exploratorio de datos.
- Cargar una base preparada previamente.
- Revisar la estructura de un conjunto de datos.
- Analizar la distribución de una variable respuesta.
- Construir tablas de frecuencia.
- Elaborar gráficas de barras con `ggplot2`.
- Interpretar patrones iniciales antes de construir modelos.

3.2 Introducción

Después de preparar los datos, el siguiente paso en un proyecto de aprendizaje automático es explorarlos.

El **análisis exploratorio de datos**, también conocido como *Exploratory Data Analysis* o **EDA**, consiste en revisar, resumir, visualizar e interpretar los datos antes de construir modelos.

3.3 Fundamento matemático del análisis exploratorio

Si una variable categórica tiene categorías $c_1, c_2, \dots, c_k$, la frecuencia absoluta de una categoría c_j se puede representar como:

$$n_j = \sum_{i=1}^n I(y_i = c_j)$$

donde $I(y_i = c_j)$ es una función indicadora:

$$I(y_i = c_j) = \begin{cases} 1, & \text{si } y_i = c_j \\ 0, & \text{si } y_i \neq c_j \end{cases}$$

La proporción de la categoría c_j es:

$$p_j = \frac{n_j}{n}$$

En nuestro caso, una proporción importante es:

$$p_{\text{víctimas}} = \frac{\text{número de accidentes con víctimas}}{\text{número total de accidentes}}$$

3.4 Proporciones condicionales

Podemos estudiar la proporción de accidentes con víctimas dado un tipo de accidente:

$$P(\text{Con víctimas} \mid \text{Tipo de accidente})$$

De forma empírica, esta proporción se calcula como:

$$\hat{P}(\text{Con víctimas} \mid T = t) = \frac{\text{número de accidentes con víctimas del tipo } t}{\text{número total de accidentes del tipo } t}$$

3.5 Algoritmo general del análisis exploratorio

Algoritmo: Análisis exploratorio de datos

Entrada:

- Base de datos preparada
- Variable respuesta
- Variables predictoras

Proceso:

1. Revisar dimensiones de la base.
2. Revisar nombres y tipos de variables.
3. Calcular frecuencias de la variable respuesta.
4. Calcular proporciones de la variable respuesta.
5. Analizar variables temporales, categóricas y numéricas.
6. Construir gráficas exploratorias.
7. Cruzar variables predictoras con la variable respuesta.

```
8. Identificar patrones, desbalances y posibles problemas.
```

Salida:

- Tablas descriptivas
- Gráficas exploratorias
- Primeras hipótesis sobre los datos

3.6 Cargar paquetes

```
library(readr)
library(dplyr)
library(ggplot2)
```

Explicación del código.

Este bloque realiza una operación de análisis exploratorio: carga datos, transforma variables, calcula frecuencias o construye una gráfica. La finalidad es conocer mejor la estructura de la base antes de modelar.

Interpretación del resultado.

La salida debe leerse como una evidencia descriptiva: ayuda a identificar patrones, desbalances, categorías frecuentes o relaciones preliminares entre variables. No implica causalidad, pero orienta el análisis posterior.

3.7 Cargar la base preparada

```
ruta_atus_ml <- "datos/atus_ml_preparado.csv"
file.exists(ruta_atus_ml)
```

```
[1] TRUE
```

Explicación del código.

Este bloque realiza una operación de análisis exploratorio: carga datos, transforma variables, calcula frecuencias o construye una gráfica. La finalidad es conocer mejor la estructura de la base antes de modelar.

Interpretación del resultado.

La salida debe leerse como una evidencia descriptiva: ayuda a identificar patrones, desbalances, categorías frecuentes o relaciones preliminares entre variables. No implica causalidad, pero orienta el análisis posterior.

```
if (file.exists(ruta_atus_ml)) {
  atus_ml <- read_csv(ruta_atus_ml, show_col_types = FALSE)
  print("Base preparada cargada correctamente.")
} else {
  atus_ml <- NULL
  print("No se encontró el archivo datos/atus_ml_preparado.csv. Ejecuta primero el capítulo 2.")
}
```

```
[1] "Base preparada cargada correctamente."
```

Explicación del código.

Este bloque realiza una operación de análisis exploratorio: carga datos, transforma variables, calcula frecuencias o construye una gráfica. La finalidad es conocer mejor la estructura de la base antes de modelar.

Interpretación del resultado.

La salida debe leerse como una evidencia descriptiva: ayuda a identificar patrones, desbalances, categorías frecuentes o relaciones preliminares entre variables. No implica causalidad, pero orienta el análisis posterior.

3.8 Preparar variables para el análisis exploratorio

```
if (!is.null(atus_ml)) {
  atus_ml <- atus_ml |>
  mutate(
    ID_HORA_NUM = as.numeric(ID_HORA),
    DIASEMANA = factor(
      DIASEMANA,
      levels = c("lunes", "Martes", "Miercoles", "Jueves", "Viernes", "Sabado", "Domingo")
    ),
    accidente_con_victimas = factor(
      accidente_con_victimas,
      levels = c("Con víctimas", "Solo daños")
    )
  )
}
```

Explicación del código.

Este bloque realiza una operación de análisis exploratorio: carga datos, transforma variables, calcula frecuencias o construye una gráfica. La finalidad es conocer mejor la estructura de la base antes de modelar.

Interpretación del resultado.

La salida debe leerse como una evidencia descriptiva: ayuda a identificar patrones, desbalances, categorías frecuentes o relaciones preliminares entre variables. No implica causalidad, pero orienta el análisis posterior.

3.9 Primer vistazo a la base

```
if (!is.null(atus_ml)) {
  dim(atus_ml)
  head(atus_ml)
  names(atus_ml)
}
```

```
[1] "accidente_con_victimas" "MES"
```

```
"ID_HORA"
```

```
[4] "DIASEMANA"          "TIPACCID"          "CAUSAACCI"
[7] "ID_HORA_NUM"
```

Explicación del código.

Este bloque realiza una operación de análisis exploratorio: carga datos, transforma variables, calcula frecuencias o construye una gráfica. La finalidad es conocer mejor la estructura de la base antes de modelar.

Interpretación del resultado.

La salida debe leerse como una evidencia descriptiva: ayuda a identificar patrones, desbalances, categorías frecuentes o relaciones preliminares entre variables. No implica causalidad, pero orienta el análisis posterior.

3.10 Estructura de los datos

```
if (!is.null(atus_ml)) {
  str(atus_ml)
}
```

```
tibble [390,627 x 7] (S3: tbl_df/tbl/data.frame)
 $ accidente_con_victimas: Factor w/ 2 levels "Con víctimas",...: 2 2 1 2 2 1 1 2 2 2 ...
 $ MES                   : chr [1:390627] "01" "01" "01" "01" ...
 $ ID_HORA               : chr [1:390627] "02" "03" "04" "05" ...
 $ DIASEMANA             : Factor w/ 7 levels "lunes","Martes",...: 1 1 1 1 1 1 1 1 1 1 ...
 $ TIPACCID              : chr [1:390627] "Colisión con vehículo automotor" "Colisión con objet
 $ CAUSAACCI             : chr [1:390627] "Conductor" "Conductor" "Conductor" "Conductor" ...
 $ ID_HORA_NUM           : num [1:390627] 2 3 4 5 6 7 12 13 18 20 ...
```

Explicación del código.

Este bloque realiza una operación de análisis exploratorio: carga datos, transforma variables, calcula frecuencias o construye una gráfica. La finalidad es conocer mejor la estructura de la base antes de modelar.

Interpretación del resultado.

La salida debe leerse como una evidencia descriptiva: ayuda a identificar patrones, desbalances, categorías frecuentes o relaciones preliminares entre variables. No implica causalidad, pero orienta el análisis posterior.

3.11 Distribución de la variable respuesta

```
if (!is.null(atus_ml)) {
  table(atus_ml$accidente_con_victimas)
}
```

Con víctimas	Solo daños
68108	322519

Explicación del código.

Este bloque realiza una operación de análisis exploratorio: carga datos, transforma variables, calcula frecuencias o construye una gráfica. La finalidad es conocer mejor la estructura de la base antes de modelar.

Interpretación del resultado.

La salida debe leerse como una evidencia descriptiva: ayuda a identificar patrones, desbalances, categorías frecuentes o relaciones preliminares entre variables. No implica causalidad, pero orienta el análisis posterior.

```
if (!is.null(atus_ml)) {
  round(100 * prop.table(table(atus_ml$accidente_con_victimas)), 2)
}
```

Con víctimas	Solo daños
17.44	82.56

Explicación del código.

Este bloque realiza una operación de análisis exploratorio: carga datos, transforma variables, calcula frecuencias o construye una gráfica. La finalidad es conocer mejor la estructura de la base antes de modelar.

Interpretación del resultado.


La salida debe leerse como una evidencia descriptiva: ayuda a identificar patrones, desbalances, categorías frecuentes o relaciones preliminares entre variables. No implica causalidad, pero orienta el análisis posterior.

3.12 Interpretación de la variable respuesta

En esta base se observa un desbalance importante: aproximadamente 82.56% de los accidentes corresponden a solo daños, mientras que 17.44% corresponden a accidentes con víctimas.

3.13 Gráfica de la variable respuesta

```
if (!is.null(atus_ml)) {
  ggplot(atus_ml, aes(x = accidente_con_victimas)) +
    geom_bar() +
    labs(
      title = "Distribución de accidentes según presencia de víctimas",
      x = "Clase del accidente",
      y = "Número de accidentes"
    )
}
```



Explicación del código.

Este bloque realiza una operación de análisis exploratorio: carga datos, transforma variables, calcula frecuencias o construye una gráfica. La finalidad es conocer mejor la estructura de la base antes de modelar.

Interpretación del resultado.

La salida debe leerse como una evidencia descriptiva: ayuda a identificar patrones, desbalances, categorías frecuentes o relaciones preliminares entre variables. No implica causalidad, pero orienta el análisis posterior.

3.14 Accidentes por mes

```
if (!is.null(atus_ml)) {
  accidentes_mes <- atus_ml |>
    count(MES) |>
    arrange(as.numeric(MES))

  accidentes_mes
}
```

```
# A tibble: 12 x 2
  MES      n
  <chr> <int>
1 01    31600
2 02    32208
```

3	03	33237
4	04	32666
5	05	34665
6	06	31737
7	07	30062
8	08	31800
9	09	31351
10	10	33771
11	11	34047
12	12	33483


Explicación del código.

Este bloque realiza una operación de análisis exploratorio: carga datos, transforma variables, calcula frecuencias o construye una gráfica. La finalidad es conocer mejor la estructura de la base antes de modelar.

Interpretación del resultado.

La salida debe leerse como una evidencia descriptiva: ayuda a identificar patrones, desbalances, categorías frecuentes o relaciones preliminares entre variables. No implica causalidad, pero orienta el análisis posterior.

```
if (!is.null(atus_ml)) {  
  ggplot(accidentes_mes, aes(x = factor(MES, levels = sort(unique(as.numeric(MES))))), y = n)) +  
    geom_col() +  
    labs(  
      title = "Número de accidentes por mes",  
      x = "Mes",  
      y = "Número de accidentes"  
    )  
}
```



Explicación del código.

Este bloque realiza una operación de análisis exploratorio: carga datos, transforma variables, calcula frecuencias o construye una gráfica. La finalidad es conocer mejor la estructura de la base antes de modelar.

Interpretación del resultado.

La salida debe leerse como una evidencia descriptiva: ayuda a identificar patrones, desbalances, categorías frecuentes o relaciones preliminares entre variables. No implica causalidad, pero orienta el análisis posterior.

3.15 Accidentes por hora del día

```
if (!is.null(atus_ml)) {
  accidentes_hora <- atus_ml |>
    count(ID_HORA_NUM) |>
    arrange(ID_HORA_NUM)

  accidentes_hora
}
```

```
# A tibble: 24 x 2
  ID_HORA_NUM      n
    <dbl> <int>
1         0  9143
2         1  7400
```

```
3          2  6594
4          3  5694
5          4  4880
6          5  4986
7          6  8034
8          7 15159
9          8 20666
10         9 19486
# i 14 more rows
```


Explicación del código.

Este bloque realiza una operación de análisis exploratorio: carga datos, transforma variables, calcula frecuencias o construye una gráfica. La finalidad es conocer mejor la estructura de la base antes de modelar.

Interpretación del resultado.

La salida debe leerse como una evidencia descriptiva: ayuda a identificar patrones, desbalances, categorías frecuentes o relaciones preliminares entre variables. No implica causalidad, pero orienta el análisis posterior.

```
if (!is.null(atus_ml)) {
  ggplot(accidentes_hora, aes(x = ID_HORA_NUM, y = n)) +
    geom_col() +
    scale_x_continuous(breaks = 0:23) +
    labs(
      title = "Número de accidentes por hora del día",
      x = "Hora del día",
      y = "Número de accidentes"
    )
}
```



Explicación del código.

Este bloque realiza una operación de análisis exploratorio: carga datos, transforma variables, calcula frecuencias o construye una gráfica. La finalidad es conocer mejor la estructura de la base antes de modelar.

Interpretación del resultado.

La salida debe leerse como una evidencia descriptiva: ayuda a identificar patrones, desbalances, categorías frecuentes o relaciones preliminares entre variables. No implica causalidad, pero orienta el análisis posterior.

3.16 Accidentes por día de la semana

```
if (!is.null(atus_ml)) {
  accidentes_dia <- atus_ml |>
    count(DIASEMANA) |>
    arrange(DIASEMANA)

  accidentes_dia
}
```

```
# A tibble: 7 x 2
  DIASEMANA      n
  <fct>      <int>
1 lunes     69412
2 Martes    51215
```

```
3 Miercoles 51580
4 Jueves    50954
5 Viernes   56708
6 Sabado    58321
7 Domingo   52437
```


Explicación del código.

Este bloque realiza una operación de análisis exploratorio: carga datos, transforma variables, calcula frecuencias o construye una gráfica. La finalidad es conocer mejor la estructura de la base antes de modelar.

Interpretación del resultado.

La salida debe leerse como una evidencia descriptiva: ayuda a identificar patrones, desbalances, categorías frecuentes o relaciones preliminares entre variables. No implica causalidad, pero orienta el análisis posterior.

```
if (!is.null(atus_ml)) {
  ggplot(accidentes_dia, aes(x = DIASEMANA, y = n)) +
    geom_col() +
    coord_flip() +
    labs(
      title = "Número de accidentes por día de la semana",
      x = "Día de la semana",
      y = "Número de accidentes"
    )
}
```



Explicación del código.

Este bloque realiza una operación de análisis exploratorio: carga datos, transforma variables, calcula frecuencias o construye una gráfica. La finalidad es conocer mejor la estructura de la base antes de modelar.

Interpretación del resultado.

La salida debe leerse como una evidencia descriptiva: ayuda a identificar patrones, desbalances, categorías frecuentes o relaciones preliminares entre variables. No implica causalidad, pero orienta el análisis posterior.

3.17 Accidentes por tipo de accidente

```
if (!is.null(atus_ml)) {
  accidentes_tipo <- atus_ml |>
    count(TIPACCID) |>
    arrange(desc(n))

  accidentes_tipo
}
```

```
# A tibble: 13 x 2
  TIPACCID          n
  <chr>          <int>
1 Colisión con vehículo automotor 224720
2 Colisión con motocicleta      61869
3 Colisión con objeto fijo      43119
4 Certificado cero             15678
5 Volcadura                    13371
6 Colisión con peatón (atropellamiento) 11052
7 Salida del camino            10067
8 Colisión con ciclista         4033
9 Otro                         2934
10 Caída de pasajero            2153
11 Colisión con animal           884
12 Incendio                     455
13 Colisión con ferrocarril       292
```

Explicación del código.

Este bloque realiza una operación de análisis exploratorio: carga datos, transforma variables, calcula frecuencias o construye una gráfica. La finalidad es conocer mejor la estructura de la base antes de modelar.

Interpretación del resultado.

La salida debe leerse como una evidencia descriptiva: ayuda a identificar patrones, desbalances, categorías frecuentes o relaciones preliminares entre variables. No implica causalidad, pero orienta el análisis posterior.

```
if (!is.null(atus_ml)) {
  accidentes_tipo_top <- accidentes_tipo |>
```

```

slice_max(n, n = 10)

ggplot(accidentes_tipo_top, aes(x = reorder(TIPACCID, n), y = n)) +
  geom_col() +
  coord_flip() +
  labs(
    title = "Tipos de accidente más frecuentes",
    x = "Tipo de accidente",
    y = "Número de accidentes"
  )
}

```



Explicación del código.

Este bloque realiza una operación de análisis exploratorio: carga datos, transforma variables, calcula frecuencias o construye una gráfica. La finalidad es conocer mejor la estructura de la base antes de modelar.

Interpretación del resultado.

La salida debe leerse como una evidencia descriptiva: ayuda a identificar patrones, desbalances, categorías frecuentes o relaciones preliminares entre variables. No implica causalidad, pero orienta el análisis posterior.

```

if (!is.null(atus_ml)) {
  accidentes_causa <- atus_ml |>
    count(CAUSAACCI) |>
    arrange(desc(n))

  accidentes_causa
}

```

```

# A tibble: 6 x 2
  CAUSAACCI          n
  <chr>          <int>
1 Conductor      360051
2 Certificado cero 15678
3 Mala condición del camino 5991
4 Falla del vehículo 3978
5 Otra           2639
6 Peatón o pasajero 2290

```

Explicación del código.

Este bloque realiza una operación de análisis exploratorio: carga datos, transforma variables, calcula frecuencias o construye una gráfica. La finalidad es conocer mejor la estructura de la base antes de modelar.

Interpretación del resultado.


La salida debe leerse como una evidencia descriptiva: ayuda a identificar patrones, desbalances, categorías frecuentes o relaciones preliminares entre variables. No implica causalidad, pero orienta el análisis posterior.

```

if (!is.null(atus_ml)) {
  accidentes_causa_top <- accidentes_causa |>
    slice_max(n, n = 10)

  ggplot(accidentes_causa_top, aes(x = reorder(CAUSAACCI, n), y = n)) +
    geom_col() +
    coord_flip() +
    labs(
      title = "Causas presuntas más frecuentes",
      x = "Causa presunta",
      y = "Número de accidentes"
    )
}

```



Explicación del código.

Este bloque realiza una operación de análisis exploratorio: carga datos, transforma variables, calcula frecuencias o construye una gráfica. La finalidad es conocer mejor la estructura de la base antes de modelar.

Interpretación del resultado.

La salida debe leerse como una evidencia descriptiva: ayuda a identificar patrones, desbalances, categorías frecuentes o relaciones preliminares entre variables. No implica causalidad, pero orienta el análisis posterior.


3.19 Relación entre tipo de accidente y presencia de víctimas

```
if (!is.null(atus_ml)) {
  tipos_top <- atus_ml |>
    count(TIPACCID) |>
    slice_max(n, n = 10) |>
    pull(TIPACCID)

  atus_tipo_top <- atus_ml |>
    filter(TIPACCID %in% tipos_top)

  ggplot(atus_tipo_top, aes(x = TIPACCID, fill = accidente_con_victimas)) +
    geom_bar(position = "fill") +
    coord_flip() +
```

```
labs(
  title = "Proporción de accidentes con víctimas según tipo de accidente",
  x = "Tipo de accidente",
  y = "Proporción",
  fill = "Clase"
)
```



Explicación del código.

Este bloque realiza una operación de análisis exploratorio: carga datos, transforma variables, calcula frecuencias o construye una gráfica. La finalidad es conocer mejor la estructura de la base antes de modelar.

Interpretación del resultado.


La salida debe leerse como una evidencia descriptiva: ayuda a identificar patrones, desbalances, categorías frecuentes o relaciones preliminares entre variables. No implica causalidad, pero orienta el análisis posterior.

3.20 Relación entre hora y presencia de víctimas

```
if (!is.null(atus_ml)) {
  ggplot(atus_ml, aes(x = ID_HORA_NUM, fill = accidente_con_victimas)) +
    geom_bar(position = "fill") +
    scale_x_continuous(breaks = 0:23) +

```

```
labs(
  title = "Proporción de accidentes con víctimas por hora",
  x = "Hora del día",
  y = "Proporción",
  fill = "Clase"
)
}
```



Explicación del código.

Este bloque realiza una operación de análisis exploratorio: carga datos, transforma variables, calcula frecuencias o construye una gráfica. La finalidad es conocer mejor la estructura de la base antes de modelar.


Interpretación del resultado.

La salida debe leerse como una evidencia descriptiva: ayuda a identificar patrones, desbalances, categorías frecuentes o relaciones preliminares entre variables. No implica causalidad, pero orienta el análisis posterior.

3.21 Relación entre día de la semana y presencia de víctimas

```
if (!is.null(atus_ml)) {
  ggplot(atus_ml, aes(x = DIASEMANA, fill = accidente_con_victimas)) +
    geom_bar(position = "fill") +
    coord_flip() +
}
```

```
labs(
  title = "Proporción de accidentes con víctimas por día de la semana",
  x = "Día de la semana",
  y = "Proporción",
  fill = "Clase"
)
```



Explicación del código.

Este bloque realiza una operación de análisis exploratorio: carga datos, transforma variables, calcula frecuencias o construye una gráfica. La finalidad es conocer mejor la estructura de la base antes de modelar.

Interpretación del resultado.

La salida debe leerse como una evidencia descriptiva: ayuda a identificar patrones, desbalances, categorías frecuentes o relaciones preliminares entre variables. No implica causalidad, pero orienta el análisis posterior.

3.22 Tabla resumen por clase

```
if (!is.null(atus_ml)) {
  resumen_clase <- atus_ml |>
  group_by(accidente_con_victimas) |>
  summarise(
```

```

    total = n(),
    hora_promedio = mean(ID_HORA_NUM, na.rm = TRUE),
    hora_minima = min(ID_HORA_NUM, na.rm = TRUE),
    hora_maxima = max(ID_HORA_NUM, na.rm = TRUE),
    .groups = "drop"
  )

  resumen_clase
}

```

```

# A tibble: 2 x 5
  accidente_con_victimas total hora_promedio hora_minima hora_maxima
  <fct>                <int>      <dbl>      <dbl>      <dbl>
1 Con víctimas         68108      13.6        0         23
2 Solo daños          322519      13.7        0         23

```

Explicación del código.

Este bloque realiza una operación de análisis exploratorio: carga datos, transforma variables, calcula frecuencias o construye una gráfica. La finalidad es conocer mejor la estructura de la base antes de modelar.

Interpretación del resultado.

La salida debe leerse como una evidencia descriptiva: ayuda a identificar patrones, desbalances, categorías frecuentes o relaciones preliminares entre variables. No implica causalidad, pero orienta el análisis posterior.

3.23 Conclusión

En este capítulo aprendimos a cargar una base preparada, revisar dimensiones, analizar la variable respuesta, construir tablas de frecuencia, graficar accidentes por mes, hora, día, tipo y causa, e interpretar patrones iniciales.

En el siguiente capítulo construiremos nuestro primer modelo supervisado para clasificación: una **regresión logística**.

Chapter 4

Regresión logística para clasificación

Explicación del código.

Este bloque forma parte del flujo de modelado con regresión logística: prepara variables, ajusta el modelo, predice probabilidades, convierte probabilidades en clases o calcula métricas de evaluación.

Interpretación del resultado.

El resultado debe interpretarse en función del problema de clasificación: detectar accidentes con víctimas. Por ello no basta con mirar la exactitud; también son importantes la sensibilidad, la especificidad y la matriz de confusión.

4.1 Objetivos del capítulo

Al finalizar este capítulo, el lector será capaz de:

- Explicar qué es un problema de clasificación binaria.
- Comprender la idea intuitiva de la regresión logística.
- Dividir una base de datos en entrenamiento y prueba.
- Ajustar un modelo de regresión logística en R.
- Construir una matriz de confusión.
- Calcular exactitud, sensibilidad y especificidad.

4.2 Introducción

El problema que vamos a estudiar es:

¿Podemos estimar la probabilidad de que un accidente de tránsito tenga víctimas?

La variable que queremos predecir es `accidente_con_victimas`.

4.3 La función logística

La regresión logística utiliza una función especial llamada **función logística**.

$$p = \frac{1}{1 + e^{-z}}$$

donde:

$$z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p$$

4.4 Fundamento matemático de la regresión logística

En clasificación binaria, la variable respuesta puede representarse como:

$$Y_i = \begin{cases} 1, & \text{si el accidente tiene víctimas} \\ 0, & \text{si el accidente es de solo daños} \end{cases}$$

La regresión logística estima:

$$P(Y_i = 1 \mid X_i) = \hat{p}_i$$

La probabilidad estimada se calcula mediante:

$$\hat{p}_i = \frac{1}{1 + e^{-z_i}}$$

donde:

$$z_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip}$$

La función logística garantiza que:

$$0 \leq \hat{p}_i \leq 1$$

4.5 Logit y razón de momios

La regresión logística también puede escribirse mediante la función logit:

$$\log \left(\frac{p_i}{1 - p_i} \right) = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip}$$

Cuando aplicamos la función exponencial a un coeficiente, obtenemos un **odds ratio**:

$$OR_j = e^{\beta_j}$$

4.6 Regla de clasificación

Una vez estimada la probabilidad $\hat{p}_i$, se elige un punto de corte c .

$$\hat{Y}_i = \begin{cases} 1, & \text{si } \hat{p}_i \geq c \\ 0, & \text{si } \hat{p}_i < c \end{cases}$$

Algoritmo: Regresión logística para clasificación binaria

Entrada:

- Matriz de variables predictoras X
- Variable respuesta binaria Y
- Punto de corte c

Proceso:

1. Codificar la variable respuesta como 0 y 1.
2. Estimar los coeficientes beta del modelo logístico.
3. Calcular $z = \text{beta}_0 + \text{beta}_1 x_1 + \dots + \text{beta}_p x_p$.
4. Transformar z mediante la función logística.
5. Obtener la probabilidad estimada p .
6. Comparar p contra el punto de corte c .
7. Clasificar como clase positiva o negativa.
8. Calcular matriz de confusión y métricas.


Salida:

- Probabilidades predichas
- Clases predichas
- Matriz de confusión
- Exactitud, sensibilidad y especificidad

```
z <- seq(-10, 10, length.out = 200)
p <- 1 / (1 + exp(-z))
datos_logistica <- data.frame(z = z, p = p)

library(ggplot2)

ggplot(datos_logistica, aes(x = z, y = p)) +
  geom_line(linewidth = 1) +
  labs(title = "Función logística", x = "z", y = "Probabilidad")
```

**Explicación del código.**

Este bloque forma parte del flujo de modelado con regresión logística: prepara variables, ajusta el modelo, predice probabilidades, convierte probabilidades en clases o calcula métricas de evaluación.

Interpretación del resultado.

El resultado debe interpretarse en función del problema de clasificación: detectar accidentes con víctimas. Por ello no basta con mirar la exactitud; también son importantes la sensibilidad, la especificidad y la matriz de confusión.

4.9 Cargar paquetes

```
library(readr)
library(dplyr)
library(ggplot2)
```

Explicación del código.

Este bloque forma parte del flujo de modelado con regresión logística: prepara variables, ajusta el modelo, predice probabilidades, convierte probabilidades en clases o calcula métricas de evaluación.

Interpretación del resultado.

El resultado debe interpretarse en función del problema de clasificación: detectar accidentes con víctimas. Por ello no basta con mirar la exactitud; también son importantes la sensibilidad, la especificidad y la matriz de confusión.

4.10 Cargar la base preparada

```
ruta_atus_ml <- "datos/atus_ml_preparado.csv"
file.exists(ruta_atus_ml)
```

```
[1] TRUE
```

Explicación del código.

Este bloque forma parte del flujo de modelado con regresión logística: prepara variables, ajusta el modelo, predice probabilidades, convierte probabilidades en clases o calcula métricas de evaluación.

Interpretación del resultado.

El resultado debe interpretarse en función del problema de clasificación: detectar accidentes con víctimas. Por ello no basta con mirar la exactitud; también son importantes la sensibilidad, la especificidad y la matriz de confusión.

```
if (file.exists(ruta_atus_ml)) {
  atus_ml <- read_csv(ruta_atus_ml, show_col_types = FALSE)
  print("Base preparada cargada correctamente.")
} else {
  atus_ml <- NULL
  print("No se encontró el archivo datos/atus_ml_preparado.csv. Ejecuta primero el capítulo 2.")
}
```

```
[1] "Base preparada cargada correctamente."
```

Explicación del código.

Este bloque forma parte del flujo de modelado con regresión logística: prepara variables, ajusta el modelo, predice probabilidades, convierte probabilidades en clases o calcula métricas de evaluación.

Interpretación del resultado.

El resultado debe interpretarse en función del problema de clasificación: detectar accidentes con víctimas. Por ello no basta con mirar la exactitud; también son importantes la sensibilidad, la especificidad y la matriz de confusión.

4.11 Preparar variables para el modelo

```
if (!is.null(atus_ml)) {
  atus_modelo <- atus_ml |>
  mutate(
    victimas_binaria = ifelse(accidente_con_victimas == "Con víctimas", 1, 0),
    MES = as.factor(MES),
    DIASEMANA = as.factor(DIASEMANA),
    TIPACCID = as.factor(TIPACCID),
    CAUSAACCI = as.factor(CAUSAACCI),
    ID_HORA = as.numeric(ID_HORA),
    accidente_con_victimas = factor(accidente_con_victimas, levels = c("Con víctimas", "Solo
  )
}
```

Explicación del código.

Este bloque forma parte del flujo de modelado con regresión logística: prepara variables, ajusta el modelo, predice probabilidades, convierte probabilidades en clases o calcula métricas de evaluación.

Interpretación del resultado.

El resultado debe interpretarse en función del problema de clasificación: detectar accidentes con víctimas. Por ello no basta con mirar la exactitud; también son importantes la sensibilidad, la especificidad y la matriz de confusión.

4.12 División en entrenamiento y prueba

```
if (exists("atus_modelo")) {
  set.seed(123)
  n <- nrow(atus_modelo)
  indices_entrenamiento <- sample(1:n, size = round(0.7 * n))
  entrenamiento <- atus_modelo[indices_entrenamiento, ]
  prueba <- atus_modelo[-indices_entrenamiento, ]
}
```

Explicación del código.

Este bloque forma parte del flujo de modelado con regresión logística: prepara variables, ajusta el modelo, predice probabilidades, convierte probabilidades en clases o calcula métricas de evaluación.

Interpretación del resultado.

El resultado debe interpretarse en función del problema de clasificación: detectar accidentes con víctimas. Por ello no basta con mirar la exactitud; también son importantes la sensibilidad, la especificidad y la matriz de confusión.

```
if (exists("entrenamiento") && exists("prueba")) {
  data.frame(
    conjunto = c("Entrenamiento", "Prueba"),
    registros = c(nrow(entrenamiento), nrow(prueba)),
    porcentaje = c(
      round(100 * nrow(entrenamiento) / nrow(atus_modelo), 2),
      round(100 * nrow(prueba) / nrow(atus_modelo), 2)
    )
  )
}
```

	conjunto	registros	porcentaje
1	Entrenamiento	273439	70
2	Prueba	117188	30

Explicación del código.

Este bloque forma parte del flujo de modelado con regresión logística: prepara variables, ajusta el modelo, predice probabilidades, convierte probabilidades en clases o calcula métricas de evaluación.

Interpretación del resultado.

El resultado debe interpretarse en función del problema de clasificación: detectar accidentes con víctimas. Por ello no basta con mirar la exactitud; también son importantes la sensibilidad, la

especificidad y la matriz de confusión.

4.13 Ajustar el modelo de regresión logística

```
if (exists("entrenamiento")) {
  modelo_logistico <- glm(
    victimas_binaria ~ MES + ID_HORA + DIASEMANA + TIPACCID + CAUSAACCI,
    data = entrenamiento,
    family = binomial
  )
}
```

Explicación del código.

Este bloque forma parte del flujo de modelado con regresión logística: prepara variables, ajusta el modelo, predice probabilidades, convierte probabilidades en clases o calcula métricas de evaluación.

Interpretación del resultado.

El resultado debe interpretarse en función del problema de clasificación: detectar accidentes con víctimas. Por ello no basta con mirar la exactitud; también son importantes la sensibilidad, la especificidad y la matriz de confusión.

```
if (exists("modelo_logistico")) {
  summary(modelo_logistico)
}
```

Call:

```
glm(formula = victimas_binaria ~ MES + ID_HORA + DIASEMANA +
     TIPACCID + CAUSAACCI, family = binomial, data = entrenamiento)
```

Coefficients: (1 not defined because of singularities)

	Estimate	Std. Error	z value
(Intercept)	18.107257	101.847193	0.178
MES02	-0.045766	0.029756	-1.538
MES03	-0.032191	0.029273	-1.100
MES04	-0.002838	0.029455	-0.096
MES05	-0.015409	0.029067	-0.530
MES06	-0.054753	0.029837	-1.835
MES07	-0.076297	0.030352	-2.514
MES08	-0.094050	0.029971	-3.138
MES09	-0.077109	0.030150	-2.557
MES10	-0.154152	0.029797	-5.173
MES11	-0.106385	0.029508	-3.605
MES12	-0.111889	0.029593	-3.781
ID_HORA	-0.001039	0.001025	-1.015
DIASEMANAJueves	-0.248317	0.022530	-11.022
DIASEMANAlunes	-0.219442	0.022072	-9.942
DIASEMANAMartes	-0.266295	0.022564	-11.801
DIASEMANAMiercoles	-0.297457	0.022631	-13.144

DIASEMANASabado	-0.145669	0.021142	-6.890
DIASEMANAViernes	-0.234956	0.021860	-10.748
TIPACCIDCertificado cero	-35.365952	108.599964	-0.326
TIPACCIDColisión con animal	-18.408433	101.847115	-0.181
TIPACCIDColisión con ciclista	-17.466499	101.847083	-0.171
TIPACCIDColisión con ferrocarril	-18.516007	101.847193	-0.182
TIPACCIDColisión con motocicleta	-17.993904	101.847076	-0.177
TIPACCIDColisión con objeto fijo	-19.631828	101.847078	-0.193
TIPACCIDColisión con peatón (atropellamiento)	-0.014823	111.314486	0.000
TIPACCIDColisión con vehículo automotor	-20.213142	101.847076	-0.198
TIPACCIDIncendio	-21.789442	101.848323	-0.214
TIPACCIDOtro	-19.371321	101.847096	-0.190
TIPACCIDSalida del camino	-18.895003	101.847080	-0.186
TIPACCIDVolcadura	-17.704426	101.847078	-0.174
CAUSAACCIConductor	-0.282824	0.157369	-1.797
CAUSAACCIFallla del vehículo	-0.547420	0.167821	-3.262
CAUSAACCIMala condición del camino	-0.097472	0.162233	-0.601
CAUSAACCIOtra	-0.093819	0.169144	-0.555
CAUSAACCIPeatón o pasajero	NA	NA	NA
	Pr(> z)		
(Intercept)	0.858889		
MES02	0.124035		
MES03	0.271467		
MES04	0.923240		
MES05	0.596036		
MES06	0.066492	.	
MES07	0.011946	*	
MES08	0.001701	**	
MES09	0.010543	*	
MES10	2.30e-07	***	
MES11	0.000312	***	
MES12	0.000156	***	
ID_HORA	0.310343		
DIASEMANAJueves	< 2e-16	***	
DIASEMANAlunes	< 2e-16	***	
DIASEMANAMartes	< 2e-16	***	
DIASEMANAMiercoles	< 2e-16	***	
DIASEMANASabado	5.58e-12	***	
DIASEMANAViernes	< 2e-16	***	
TIPACCIDCertificado cero	0.744687		
TIPACCIDColisión con animal	0.856567		
TIPACCIDColisión con ciclista	0.863833		
TIPACCIDColisión con ferrocarril	0.855738		
TIPACCIDColisión con motocicleta	0.859763		
TIPACCIDColisión con objeto fijo	0.847149		
TIPACCIDColisión con peatón (atropellamiento)	0.999894		
TIPACCIDColisión con vehículo automotor	0.842681		
TIPACCIDIncendio	0.830594		

```

TIPACCID0tro                0.849152
TIPACCIDSalida del camino    0.852819
TIPACCIDVolcadura            0.861996
CAUSAACCIConductor          0.072303 .
CAUSAACCIFalla del vehículo  0.001107 **
CAUSAACCIMala condición del camino 0.547964
CAUSAACCIOtra                0.579123
CAUSAACCIPeatón o pasajero   NA
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

(Dispersion parameter for binomial family taken to be 1)

```

Null deviance: 252832  on 273438  degrees of freedom
Residual deviance: 181229  on 273404  degrees of freedom
AIC: 181299

```

Number of Fisher Scoring iterations: 16

Explicación del código.

Este bloque forma parte del flujo de modelado con regresión logística: prepara variables, ajusta el modelo, predice probabilidades, convierte probabilidades en clases o calcula métricas de evaluación.

Interpretación del resultado.

El resultado debe interpretarse en función del problema de clasificación: detectar accidentes con víctimas. Por ello no basta con mirar la exactitud; también son importantes la sensibilidad, la especificidad y la matriz de confusión.

Nota didáctica: si aparece el mensaje “1 not defined because of singularities”, significa que una categoría no pudo estimarse de forma independiente.

4.14 Predicción de probabilidades

```

if (exists("modelo_logistico") && exists("prueba")) {
  prueba$probabilidad_victimas <- predict(
    modelo_logistico,
    newdata = prueba,
    type = "response"
  )
}

```

Explicación del código.

Este bloque forma parte del flujo de modelado con regresión logística: prepara variables, ajusta el modelo, predice probabilidades, convierte probabilidades en clases o calcula métricas de evaluación.

Interpretación del resultado.

El resultado debe interpretarse en función del problema de clasificación: detectar accidentes con víctimas. Por ello no basta con mirar la exactitud; también son importantes la sensibilidad, la especificidad y la matriz de confusión.

4.15 De probabilidades a clases

```
if (exists("prueba")) {
  prueba$prediccion_05 <- ifelse(
    prueba$probabilidad_victimas >= 0.5,
    "Con víctimas",
    "Solo daños"
  )

  prueba$prediccion_05 <- factor(prueba$prediccion_05, levels = c("Con víctimas", "Solo daños"))
}
```

Explicación del código.

Este bloque forma parte del flujo de modelado con regresión logística: prepara variables, ajusta el modelo, predice probabilidades, convierte probabilidades en clases o calcula métricas de evaluación.

Interpretación del resultado.

El resultado debe interpretarse en función del problema de clasificación: detectar accidentes con víctimas. Por ello no basta con mirar la exactitud; también son importantes la sensibilidad, la especificidad y la matriz de confusión.

4.16 Matriz de confusión

```
if (exists("prueba")) {
  matriz_confusion_05 <- table(
    Real = prueba$accidente_con_victimas,
    Predicho = prueba$prediccion_05
  )

  matriz_confusion_05
}
```

Real	Predicho	
	Con víctimas	Solo daños
Con víctimas	4886	15618
Solo daños	807	95877

Explicación del código.

Este bloque forma parte del flujo de modelado con regresión logística: prepara variables, ajusta el modelo, predice probabilidades, convierte probabilidades en clases o calcula métricas de evaluación.

Interpretación del resultado.

El resultado debe interpretarse en función del problema de clasificación: detectar accidentes con víctimas. Por ello no basta con mirar la exactitud; también son importantes la sensibilidad, la especificidad y la matriz de confusión.

4.17 Métricas de evaluación

```
if (exists("matriz_confusion_05")) {
  VP <- matriz_confusion_05["Con víctimas", "Con víctimas"]
  FN <- matriz_confusion_05["Con víctimas", "Solo daños"]
  FP <- matriz_confusion_05["Solo daños", "Con víctimas"]
  VN <- matriz_confusion_05["Solo daños", "Solo daños"]

  data.frame(
    medida = c("VP", "FN", "FP", "VN"),
    nombre = c("Verdaderos positivos", "Falsos negativos", "Falsos positivos", "Verdaderos negativos"),
    valor = c(VP, FN, FP, VN)
  )
}
```

	medida	nombre	valor
1	VP	Verdaderos positivos	4886
2	FN	Falsos negativos	15618
3	FP	Falsos positivos	807
4	VN	Verdaderos negativos	95877

Explicación del código.

Este bloque forma parte del flujo de modelado con regresión logística: prepara variables, ajusta el modelo, predice probabilidades, convierte probabilidades en clases o calcula métricas de evaluación.

Interpretación del resultado.

El resultado debe interpretarse en función del problema de clasificación: detectar accidentes con víctimas. Por ello no basta con mirar la exactitud; también son importantes la sensibilidad, la especificidad y la matriz de confusión.

4.18 Fórmulas de evaluación para clasificación binaria

La exactitud se calcula como:

$$\text{Exactitud} = \frac{VP + VN}{VP + FN + FP + VN}$$

La sensibilidad se calcula como:

$$\text{Sensibilidad} = \frac{VP}{VP + FN}$$

La especificidad se calcula como:

$$\text{Especificidad} = \frac{VN}{VN + FP}$$

La precisión se calcula como:

$$\text{Precisión} = \frac{VP}{VP + FP}$$

```
if (exists("VP")) {
  exactitud <- (VP + VN) / (VP + FN + FP + VN)
  sensibilidad <- VP / (VP + FN)
  especificidad <- VN / (VN + FP)

  data.frame(
    punto_corte = 0.5,
    exactitud = exactitud,
    sensibilidad = sensibilidad,
    especificidad = especificidad
  )
}
```

```
      punto_corte exactitud sensibilidad especificidad
1          0.5 0.8598406      0.238295      0.9916532
```

Explicación del código.

Este bloque forma parte del flujo de modelado con regresión logística: prepara variables, ajusta el modelo, predice probabilidades, convierte probabilidades en clases o calcula métricas de evaluación.

Interpretación del resultado.

El resultado debe interpretarse en función del problema de clasificación: detectar accidentes con víctimas. Por ello no basta con mirar la exactitud; también son importantes la sensibilidad, la especificidad y la matriz de confusión.

4.19 Clasificación con punto de corte 0.3

```
if (exists("prueba")) {
  prueba$prediccion_03 <- ifelse(
    prueba$probabilidad_victimas >= 0.3,
    "Con víctimas",
    "Solo daños"
  )
  prueba$prediccion_03 <- factor(prueba$prediccion_03, levels = c("Con víctimas", "Solo daños"))
}
```

Explicación del código.

Este bloque forma parte del flujo de modelado con regresión logística: prepara variables, ajusta el modelo, predice probabilidades, convierte probabilidades en clases o calcula métricas de evaluación.

Interpretación del resultado.

El resultado debe interpretarse en función del problema de clasificación: detectar accidentes con víctimas. Por ello no basta con mirar la exactitud; también son importantes la sensibilidad, la especificidad y la matriz de confusión.

```

if (exists("prueba")) {
  matriz_confusion_03 <- table(
    Real = prueba$accidente_con_victimas,
    Predicho = prueba$prediccion_03
  )
  matriz_confusion_03
}

```

		Predicho	
Real		Con víctimas	Solo daños
	Con víctimas	13765	6739
	Solo daños	14302	82382

Explicación del código.

Este bloque forma parte del flujo de modelado con regresión logística: prepara variables, ajusta el modelo, predice probabilidades, convierte probabilidades en clases o calcula métricas de evaluación.

Interpretación del resultado.

El resultado debe interpretarse en función del problema de clasificación: detectar accidentes con víctimas. Por ello no basta con mirar la exactitud; también son importantes la sensibilidad, la especificidad y la matriz de confusión.

```

if (exists("matriz_confusion_03")) {
  VP_03 <- matriz_confusion_03["Con víctimas", "Con víctimas"]
  FN_03 <- matriz_confusion_03["Con víctimas", "Solo daños"]
  FP_03 <- matriz_confusion_03["Solo daños", "Con víctimas"]
  VN_03 <- matriz_confusion_03["Solo daños", "Solo daños"]

  exactitud_03 <- (VP_03 + VN_03) / (VP_03 + FN_03 + FP_03 + VN_03)
  sensibilidad_03 <- VP_03 / (VP_03 + FN_03)
  especificidad_03 <- VN_03 / (VN_03 + FP_03)

  data.frame(
    punto_corte = 0.3,
    exactitud = exactitud_03,
    sensibilidad = sensibilidad_03,
    especificidad = especificidad_03
  )
}

```

	punto_corte	exactitud	sensibilidad	especificidad
1	0.3	0.8204509	0.6713324	0.8520748

Explicación del código.

Este bloque forma parte del flujo de modelado con regresión logística: prepara variables, ajusta el modelo, predice probabilidades, convierte probabilidades en clases o calcula métricas de evaluación.

Interpretación del resultado.

El resultado debe interpretarse en función del problema de clasificación: detectar accidentes con víctimas. Por ello no basta con mirar la exactitud; también son importantes la sensibilidad, la

especificidad y la matriz de confusión.

4.20 Comparación de puntos de corte

```
if (exists("exactitud") && exists("exactitud_03")) {
  data.frame(
    punto_corte = c(0.5, 0.3),
    exactitud = c(exactitud, exactitud_03),
    sensibilidad = c(sensibilidad, sensibilidad_03),
    especificidad = c(especificidad, especificidad_03)
  )
}
```

	punto_corte	exactitud	sensibilidad	especificidad
1	0.5	0.8598406	0.2382950	0.9916532
2	0.3	0.8204509	0.6713324	0.8520748

Explicación del código.


Este bloque forma parte del flujo de modelado con regresión logística: prepara variables, ajusta el modelo, predice probabilidades, convierte probabilidades en clases o calcula métricas de evaluación.

Interpretación del resultado.

El resultado debe interpretarse en función del problema de clasificación: detectar accidentes con víctimas. Por ello no basta con mirar la exactitud; también son importantes la sensibilidad, la especificidad y la matriz de confusión.

4.21 Distribución de probabilidades predichas

```
if (exists("prueba")) {
  ggplot(prueba, aes(x = probabilidad_victimas, fill = accidente_con_victimas)) +
    geom_histogram(bins = 30, alpha = 0.7, position = "identity") +
    labs(
      title = "Distribución de probabilidades predichas",
      x = "Probabilidad predicha de accidente con víctimas",
      y = "Frecuencia",
      fill = "Clase real"
    )
}
```



Explicación del código.

Este bloque forma parte del flujo de modelado con regresión logística: prepara variables, ajusta el modelo, predice probabilidades, convierte probabilidades en clases o calcula métricas de evaluación.

Interpretación del resultado.

El resultado debe interpretarse en función del problema de clasificación: detectar accidentes con víctimas. Por ello no basta con mirar la exactitud; también son importantes la sensibilidad, la especificidad y la matriz de confusión.

4.22 Odds ratios

```
if (exists("modelo_logistico")) {
  odds_ratios <- data.frame(
    variable = names(coef(modelo_logistico)),
    odds_ratio = exp(coef(modelo_logistico))
  )

  head(odds_ratios, 15)
}
```

	variable	odds_ratio
(Intercept)	(Intercept)	7.309402e+07
MES02	MES02	9.552658e-01
MES03	MES03	9.683213e-01
MES04	MES04	9.971660e-01

MES05	MES05	9.847096e-01
MES06	MES06	9.467188e-01
MES07	MES07	9.265412e-01
MES08	MES08	9.102377e-01
MES09	MES09	9.257885e-01
MES10	MES10	8.571414e-01
MES11	MES11	8.990784e-01
MES12	MES12	8.941439e-01
ID_HORA	ID_HORA	9.989611e-01
DIASEMANAJueves	DIASEMANAJueves	7.801123e-01
DIASEMANAlunes	DIASEMANAlunes	8.029666e-01

Explicación del código.

Este bloque forma parte del flujo de modelado con regresión logística: prepara variables, ajusta el modelo, predice probabilidades, convierte probabilidades en clases o calcula métricas de evaluación.

Interpretación del resultado.

El resultado debe interpretarse en función del problema de clasificación: detectar accidentes con víctimas. Por ello no basta con mirar la exactitud; también son importantes la sensibilidad, la especificidad y la matriz de confusión.

4.23 Conclusión

La regresión logística es uno de los modelos más importantes para clasificación binaria. En el siguiente capítulo estudiaremos **k vecinos más cercanos**, conocido como **k-NN**.

Chapter 5

k vecinos más cercanos, k-NN

Explicación del código.

Este bloque aplica el flujo de k-NN: prepara variables numéricas, estandariza, calcula vecinos cercanos, genera predicciones o evalúa el desempeño del clasificador.

Interpretación del resultado.

El resultado muestra cómo se comporta k-NN con los datos. En este método son clave la escala de las variables, el valor de k y el equilibrio entre exactitud, sensibilidad y especificidad.

5.1 Objetivos del capítulo

Al finalizar este capítulo, el lector será capaz de:

- Explicar la idea intuitiva del método k vecinos más cercanos.
- Comprender el papel de la distancia en k-NN.
- Calcular distancias entre observaciones.
- Explicar por qué es necesario escalar las variables numéricas.
- Aplicar k-NN en R para un problema de clasificación.
- Construir una matriz de confusión.
- Calcular exactitud, sensibilidad y especificidad.

5.2 Introducción

k-NN significa *k-Nearest Neighbors* o **k vecinos más cercanos**.

La idea básica es:

Para clasificar una nueva observación, buscamos las observaciones más parecidas a ella y le asignamos la clase más frecuente entre sus vecinos.

5.3 Idea intuitiva del método

El algoritmo k-NN hace lo siguiente:

1. Calcula la distancia entre la nueva observación y las observaciones históricas.
2. Encuentra los k vecinos más cercanos.

3. Revisa la clase de esos vecinos.
4. Asigna la clase más frecuente.

5.4 ¿Qué significa *k*?

La letra *k* indica cuántos vecinos se usarán para clasificar una observación.

Si *k* es muy pequeño, el modelo puede ser muy sensible al ruido. Si *k* es muy grande, el modelo puede volverse demasiado general.

5.5 Ejemplo sencillo con puntos

```
datos_ejemplo <- data.frame(
  hora = c(8, 9, 10, 18, 19, 20, 22, 23),
  mes = c(1, 1, 2, 6, 6, 7, 12, 12),
  clase = c(
    "Solo daños", "Solo daños", "Solo daños",
    "Con víctimas", "Con víctimas", "Con víctimas",
    "Con víctimas", "Con víctimas"
  )
)
```

datos_ejemplo

	hora	mes	clase
1	8	1	Solo daños
2	9	1	Solo daños
3	10	2	Solo daños
4	18	6	Con víctimas
5	19	6	Con víctimas
6	20	7	Con víctimas
7	22	12	Con víctimas
8	23	12	Con víctimas

Explicación del código.

Este bloque aplica el flujo de *k*-NN: prepara variables numéricas, estandariza, calcula vecinos cercanos, genera predicciones o evalúa el desempeño del clasificador.


Interpretación del resultado.

El resultado muestra cómo se comporta *k*-NN con los datos. En este método son clave la escala de las variables, el valor de *k* y el equilibrio entre exactitud, sensibilidad y especificidad.

```
library(ggplot2)

ggplot(datos_ejemplo, aes(x = hora, y = mes, color = clase)) +
  geom_point(size = 4) +
  labs(
    title = "Ejemplo intuitivo de k-NN",
    x = "Hora",
```

```
y = "Mes",
color = "Clase"
)
```



Explicación del código.

Este bloque aplica el flujo de k-NN: prepara variables numéricas, estandariza, calcula vecinos cercanos, genera predicciones o evalúa el desempeño del clasificador.

Interpretación del resultado.

El resultado muestra cómo se comporta k-NN con los datos. En este método son clave la escala de las variables, el valor de k y el equilibrio entre exactitud, sensibilidad y especificidad.

5.6 Distancia euclidiana

Para dos puntos:

$$A = (x_1, y_1)$$

y

$$B = (x_2, y_2)$$

la distancia euclidiana es:

$$d(A, B) = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$$

5.7 Fundamento matemático de k-NN

Sea x_0 una nueva observación que queremos clasificar.

Sea x_i una observación del conjunto de entrenamiento.

Si tenemos p variables predictoras, podemos escribir:

$$x_0 = (x_{01}, x_{02}, \dots, x_{0p})$$

y

$$x_i = (x_{i1}, x_{i2}, \dots, x_{ip})$$

La distancia euclidiana entre x_0 y x_i se define como:

$$d(x_0, x_i) = \sqrt{\sum_{j=1}^p (x_{0j} - x_{ij})^2}$$

Después se seleccionan las k observaciones con menor distancia.

Si las clases de los k vecinos más cercanos son:

$$y_{(1)}, y_{(2)}, \dots, y_{(k)}$$

entonces la clase predicha se obtiene por mayoría de votos:

$$\hat{y}_0 = \text{moda}(y_{(1)}, y_{(2)}, \dots, y_{(k)})$$

5.8 Ejemplo de cálculo de distancia

```
x1 <- 8
y1 <- 1
x2 <- 10
y2 <- 2

distancia <- sqrt((x1 - x2)^2 + (y1 - y2)^2)
distancia
```

```
[1] 2.236068
```

Explicación del código.

Este bloque aplica el flujo de k-NN: prepara variables numéricas, estandariza, calcula vecinos cercanos, genera predicciones o evalúa el desempeño del clasificador.

Interpretación del resultado.

El resultado muestra cómo se comporta k-NN con los datos. En este método son clave la escala de las variables, el valor de k y el equilibrio entre exactitud, sensibilidad y especificidad.

5.9 Estandarización de variables

Como k-NN depende de distancias, es importante que las variables estén en escalas comparables.

Una forma común de estandarizar una variable X_j es:

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$$

donde $\bar{x}_j$ es la media de la variable j y s_j es su desviación estándar.

5.10 Algoritmo k-NN

Algoritmo: k vecinos más cercanos

Entrada:

- Matriz de entrenamiento X
- Clases de entrenamiento Y
- Nueva observación x_0
- Número de vecinos k

Proceso:

1. Estandarizar las variables predictoras.
2. Calcular la distancia entre x_0 y cada observación de entrenamiento.
3. Ordenar las distancias de menor a mayor.
4. Seleccionar los k vecinos más cercanos.
5. Revisar las clases de esos k vecinos.
6. Contar cuántas veces aparece cada clase.
7. Asignar a x_0 la clase más frecuente.

Salida:

- Clase predicha para x_0

5.11 Cargar paquetes

```
library(readr)
library(dplyr)
library(ggplot2)
```

```
library(class)
library(tidyr)
```

Explicación del código.

Este bloque aplica el flujo de *k*-NN: prepara variables numéricas, estandariza, calcula vecinos cercanos, genera predicciones o evalúa el desempeño del clasificador.

Interpretación del resultado.

El resultado muestra cómo se comporta *k*-NN con los datos. En este método son clave la escala de las variables, el valor de *k* y el equilibrio entre exactitud, sensibilidad y especificidad.

5.12 Cargar la base preparada

```
ruta_atus_ml <- "datos/atus_ml_preparado.csv"
file.exists(ruta_atus_ml)
```

```
[1] TRUE
```

Explicación del código.

Este bloque aplica el flujo de *k*-NN: prepara variables numéricas, estandariza, calcula vecinos cercanos, genera predicciones o evalúa el desempeño del clasificador.

Interpretación del resultado.

El resultado muestra cómo se comporta *k*-NN con los datos. En este método son clave la escala de las variables, el valor de *k* y el equilibrio entre exactitud, sensibilidad y especificidad.

```
if (file.exists(ruta_atus_ml)) {
  atus_ml <- read_csv(ruta_atus_ml, show_col_types = FALSE)
  print("Base preparada cargada correctamente.")
} else {
  atus_ml <- NULL
  print("No se encontró el archivo datos/atus_ml_preparado.csv. Ejecuta primero el capítulo 2.")
}
```

```
[1] "Base preparada cargada correctamente."
```

Explicación del código.

Este bloque aplica el flujo de *k*-NN: prepara variables numéricas, estandariza, calcula vecinos cercanos, genera predicciones o evalúa el desempeño del clasificador.

Interpretación del resultado.

El resultado muestra cómo se comporta *k*-NN con los datos. En este método son clave la escala de las variables, el valor de *k* y el equilibrio entre exactitud, sensibilidad y especificidad.

5.13 Selección de una muestra para *k*-NN

```
if (!is.null(atus_ml)) {
  set.seed(123)
  tamano_muestra <- min(12000, nrow(atus_ml))
}
```

```

atus_knn_base <- atus_ml |>
  sample_n(tamano_muestra)
  dim(atus_knn_base)
}

```

```
[1] 12000      6
```

Explicación del código.

Este bloque aplica el flujo de k-NN: prepara variables numéricas, estandariza, calcula vecinos cercanos, genera predicciones o evalúa el desempeño del clasificador.

Interpretación del resultado.

El resultado muestra cómo se comporta k-NN con los datos. En este método son clave la escala de las variables, el valor de k y el equilibrio entre exactitud, sensibilidad y especificidad.

5.14 Preparar variables para k-NN

```

if (exists("atus_knn_base")) {
  atus_knn_base <- atus_knn_base |>
    mutate(
      accidente_con_victimas = factor(accidente_con_victimas, levels = c("Con víctimas", "Solo
MES = as.factor(MES),
      ID_HORA = as.numeric(ID_HORA),
      DIASEMANA = as.factor(DIASEMANA),
      TIPACCID = as.factor(TIPACCID),
      CAUSAACCI = as.factor(CAUSAACCI)
    ) |>
    na.omit()
}

```

Explicación del código.

Este bloque aplica el flujo de k-NN: prepara variables numéricas, estandariza, calcula vecinos cercanos, genera predicciones o evalúa el desempeño del clasificador.

Interpretación del resultado.

El resultado muestra cómo se comporta k-NN con los datos. En este método son clave la escala de las variables, el valor de k y el equilibrio entre exactitud, sensibilidad y especificidad.

```

if (exists("atus_knn_base")) {
  table(atus_knn_base$accidente_con_victimas)
  round(100 * prop.table(table(atus_knn_base$accidente_con_victimas)), 2)
}

```

Con víctimas	Solo daños
17.36	82.64

Explicación del código.

Este bloque aplica el flujo de k-NN: prepara variables numéricas, estandariza, calcula vecinos cercanos, genera predicciones o evalúa el desempeño del clasificador.

Interpretación del resultado.

El resultado muestra cómo se comporta k-NN con los datos. En este método son clave la escala de las variables, el valor de k y el equilibrio entre exactitud, sensibilidad y especificidad.

5.15 Crear variables dummy

```
if (exists("atus_knn_base")) {
  matriz_predictoras <- model.matrix(
    ~ ID_HORA + MES + DIASEMANA + TIPACCID + CAUSAACCI - 1,
    data = atus_knn_base
  )

  dim(matriz_predictoras)
}
```

```
[1] 12000    36
```

Explicación del código.

Este bloque aplica el flujo de k-NN: prepara variables numéricas, estandariza, calcula vecinos cercanos, genera predicciones o evalúa el desempeño del clasificador.

Interpretación del resultado.

El resultado muestra cómo se comporta k-NN con los datos. En este método son clave la escala de las variables, el valor de k y el equilibrio entre exactitud, sensibilidad y especificidad.

```
if (exists("atus_knn_base")) {
  y <- atus_knn_base$accidente_con_victimas
}
```

Explicación del código.

Este bloque aplica el flujo de k-NN: prepara variables numéricas, estandariza, calcula vecinos cercanos, genera predicciones o evalúa el desempeño del clasificador.

Interpretación del resultado.

El resultado muestra cómo se comporta k-NN con los datos. En este método son clave la escala de las variables, el valor de k y el equilibrio entre exactitud, sensibilidad y especificidad.

5.16 División en entrenamiento y prueba

```
if (exists("matriz_predictoras") && exists("y")) {
  set.seed(123)
  n <- nrow(matriz_predictoras)
  indices_entrenamiento <- sample(1:n, size = round(0.7 * n))
  x_entrenamiento <- matriz_predictoras[indices_entrenamiento, ]
  x_prueba <- matriz_predictoras[-indices_entrenamiento, ]
  y_entrenamiento <- y[indices_entrenamiento]
  y_prueba <- y[-indices_entrenamiento]
}
```

Explicación del código.

Este bloque aplica el flujo de k-NN: prepara variables numéricas, estandariza, calcula vecinos cercanos, genera predicciones o evalúa el desempeño del clasificador.

Interpretación del resultado.

El resultado muestra cómo se comporta k-NN con los datos. En este método son clave la escala de las variables, el valor de k y el equilibrio entre exactitud, sensibilidad y especificidad.

```
if (exists("x_entrenamiento") && exists("x_prueba")) {
  data.frame(
    conjunto = c("Entrenamiento", "Prueba"),
    registros = c(nrow(x_entrenamiento), nrow(x_prueba)),
    porcentaje = c(
      round(100 * nrow(x_entrenamiento) / nrow(matriz_predictoras), 2),
      round(100 * nrow(x_prueba) / nrow(matriz_predictoras), 2)
    )
  )
}
```

	conjunto	registros	porcentaje
1	Entrenamiento	8400	70
2	Prueba	3600	30

Explicación del código.

Este bloque aplica el flujo de k-NN: prepara variables numéricas, estandariza, calcula vecinos cercanos, genera predicciones o evalúa el desempeño del clasificador.

Interpretación del resultado.

El resultado muestra cómo se comporta k-NN con los datos. En este método son clave la escala de las variables, el valor de k y el equilibrio entre exactitud, sensibilidad y especificidad.

5.17 Estandarización de variables

```
if (exists("x_entrenamiento") && exists("x_prueba")) {
  medias <- apply(x_entrenamiento, 2, mean)
  desviaciones <- apply(x_entrenamiento, 2, sd)
  desviaciones[desviaciones == 0] <- 1

  x_entrenamiento_esc <- scale(x_entrenamiento, center = medias, scale = desviaciones)
  x_prueba_esc <- scale(x_prueba, center = medias, scale = desviaciones)
}
```

Explicación del código.

Este bloque aplica el flujo de k-NN: prepara variables numéricas, estandariza, calcula vecinos cercanos, genera predicciones o evalúa el desempeño del clasificador.

Interpretación del resultado.

El resultado muestra cómo se comporta k-NN con los datos. En este método son clave la escala de las variables, el valor de k y el equilibrio entre exactitud, sensibilidad y especificidad.

5.18 Ajuste del modelo k-NN con $k = 5$

```
if (exists("x_entrenamiento_esc") && exists("x_prueba_esc")) {
  pred_knn_5 <- knn(
    train = x_entrenamiento_esc,
    test = x_prueba_esc,
    cl = y_entrenamiento,
    k = 5
  )
}
```

Explicación del código.

Este bloque aplica el flujo de k-NN: prepara variables numéricas, estandariza, calcula vecinos cercanos, genera predicciones o evalúa el desempeño del clasificador.

Interpretación del resultado.

El resultado muestra cómo se comporta k-NN con los datos. En este método son clave la escala de las variables, el valor de k y el equilibrio entre exactitud, sensibilidad y especificidad.

5.19 Matriz de confusión

```
if (exists("pred_knn_5")) {
  pred_knn_5 <- factor(pred_knn_5, levels = c("Con víctimas", "Solo daños"))
  y_prueba <- factor(y_prueba, levels = c("Con víctimas", "Solo daños"))

  matriz_confusion_knn_5 <- table(
    Real = y_prueba,
    Predicho = pred_knn_5
  )

  matriz_confusion_knn_5
}
```

Real	Predicho	
	Con víctimas	Solo daños
Con víctimas	211	399
Solo daños	144	2846

Explicación del código.

Este bloque aplica el flujo de k-NN: prepara variables numéricas, estandariza, calcula vecinos cercanos, genera predicciones o evalúa el desempeño del clasificador.

Interpretación del resultado.

El resultado muestra cómo se comporta k-NN con los datos. En este método son clave la escala de las variables, el valor de k y el equilibrio entre exactitud, sensibilidad y especificidad.

5.20 Métricas de evaluación

```
if (exists("matriz_confusion_knn_5")) {
  VP <- matriz_confusion_knn_5["Con víctimas", "Con víctimas"]
  FN <- matriz_confusion_knn_5["Con víctimas", "Solo daños"]
  FP <- matriz_confusion_knn_5["Solo daños", "Con víctimas"]
  VN <- matriz_confusion_knn_5["Solo daños", "Solo daños"]

  exactitud_knn_5 <- (VP + VN) / (VP + FN + FP + VN)
  sensibilidad_knn_5 <- VP / (VP + FN)
  especificidad_knn_5 <- VN / (VN + FP)

  data.frame(
    k = 5,
    exactitud = exactitud_knn_5,
    sensibilidad = sensibilidad_knn_5,
    especificidad = especificidad_knn_5
  )
}
```

```
   k exactitud sensibilidad especificidad
1  5  0.8491667    0.3459016    0.9518395
```

Explicación del código.

Este bloque aplica el flujo de k-NN: prepara variables numéricas, estandariza, calcula vecinos cercanos, genera predicciones o evalúa el desempeño del clasificador.

Interpretación del resultado.

El resultado muestra cómo se comporta k-NN con los datos. En este método son clave la escala de las variables, el valor de k y el equilibrio entre exactitud, sensibilidad y especificidad.

5.21 Comparación con distintos valores de k

```
calcular_metricas <- function(real, predicho) {
  real <- factor(real, levels = c("Con víctimas", "Solo daños"))
  predicho <- factor(predicho, levels = c("Con víctimas", "Solo daños"))

  matriz <- table(Real = real, Predicho = predicho)

  VP <- matriz["Con víctimas", "Con víctimas"]
  FN <- matriz["Con víctimas", "Solo daños"]
  FP <- matriz["Solo daños", "Con víctimas"]
  VN <- matriz["Solo daños", "Solo daños"]

  exactitud <- (VP + VN) / (VP + FN + FP + VN)
  sensibilidad <- VP / (VP + FN)
  especificidad <- VN / (VN + FP)
```

```
data.frame(exactitud = exactitud, sensibilidad = sensibilidad, especificidad = especificidad)
}
```

Explicación del código.

Este bloque aplica el flujo de k-NN: prepara variables numéricas, estandariza, calcula vecinos cercanos, genera predicciones o evalúa el desempeño del clasificador.

Interpretación del resultado.

El resultado muestra cómo se comporta k-NN con los datos. En este método son clave la escala de las variables, el valor de k y el equilibrio entre exactitud, sensibilidad y especificidad.

```
if (exists("x_entrenamiento_esc") && exists("x_prueba_esc")) {
  valores_k <- c(3, 5, 11)
  resultados_knn <- data.frame()

  for (k_actual in valores_k) {
    pred_actual <- knn(
      train = x_entrenamiento_esc,
      test = x_prueba_esc,
      cl = y_entrenamiento,
      k = k_actual
    )

    metricas_actuales <- calcular_metricas(y_prueba, pred_actual)
    metricas_actuales$k <- k_actual
    resultados_knn <- rbind(resultados_knn, metricas_actuales)
  }

  resultados_knn <- resultados_knn |>
    select(k, exactitud, sensibilidad, especificidad)

  resultados_knn
}
```

	k	exactitud	sensibilidad	especificidad
1	3	0.8433333	0.3770492	0.9384615
2	5	0.8480556	0.3491803	0.9498328
3	11	0.8558333	0.3377049	0.9615385

Explicación del código.

Este bloque aplica el flujo de k-NN: prepara variables numéricas, estandariza, calcula vecinos cercanos, genera predicciones o evalúa el desempeño del clasificador.

Interpretación del resultado.

El resultado muestra cómo se comporta k-NN con los datos. En este método son clave la escala de las variables, el valor de k y el equilibrio entre exactitud, sensibilidad y especificidad.


```
if (exists("resultados_knn")) {
  resultados_largos <- resultados_knn |>
    pivot_longer(
```

```

    cols = c(exactitud, sensibilidad, especificidad),
    names_to = "metrica",
    values_to = "valor"
  )

ggplot(resultados_largos, aes(x = k, y = valor, group = metrica)) +
  geom_line() +
  geom_point(size = 3) +
  scale_x_continuous(breaks = valores_k) +
  labs(
    title = "Comparación de métricas para distintos valores de k",
    x = "Valor de k",
    y = "Valor de la métrica"
  )
}

```



Explicación del código.

Este bloque aplica el flujo de k-NN: prepara variables numéricas, estandariza, calcula vecinos cercanos, genera predicciones o evalúa el desempeño del clasificador.

Interpretación del resultado.

El resultado muestra cómo se comporta k-NN con los datos. En este método son clave la escala de las variables, el valor de k y el equilibrio entre exactitud, sensibilidad y especificidad.

5.22 Comparación conceptual con regresión logística

Aspecto	Regresión logística	k-NN
Tipo de modelo	Paramétrico	No paramétrico
Produce modelo explícito	Sí	No en el mismo sentido
Usa distancias	No	Sí
Requiere escalamiento	No siempre	Sí
Interpretable	Alta	Media o baja

5.23 Conclusión

k-NN es uno de los métodos más intuitivos del aprendizaje automático.

Aunque es sencillo de explicar, requiere cuidado en la preparación de los datos, especialmente en el escalamiento y en el tratamiento de variables categóricas.

En el siguiente capítulo estudiaremos un método muy importante por su interpretabilidad: **árboles de decisión**.