

Clasificación por similitud topográfica


Comprendiendo el algoritmo k-NN a través de datos reales de tráfico




Dime con quién andas y te diré qué clase eres

El algoritmo de los k vecinos más cercanos (k-NN) no busca aprender una ecuación compleja. Su motor predictivo es una suposición profundamente intuitiva: las observaciones similares tienden a compartir el mismo resultado.

Concepto Conceptual



Ancla de Datos



Nuestro vecindario de análisis: La base de datos ATUS

Para poner a prueba el algoritmo, utilizaremos la Estadística de Accidentes de Tránsito (INEGI). Nuestro objetivo es clasificar un accidente no visto basándonos en las coordenadas históricas de accidentes previos.

Leyenda de Datos



Clase Mayoritaria

Solo daños

Accidentes con daños materiales. Representa el 82% del panorama histórico.



Clase Crítica

Con víctimas

Lesionados o fallecidos. Representa el 18% del panorama histórico (Altamente desbalanceado).

Las Coordenadas (Variables Predictoras)



MES



ID_HORA



DIASEMANA



TIPACCID



CAUSAACCI

El motor del algoritmo: La Distancia Euclidiana

¿Cómo define una computadora la cercanía? Convirtiendo cada variable en una coordenada geométrica y tirando una línea recta entre ellas. Una distancia menor indica una mayor similitud.

A (10, 2)

$$d(A, B) = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$$

$$\Delta x = (8 - 10)^2$$

$$\Delta y = (1 - 2)^2$$

$$d = \sqrt{(-2)^2 + (-1)^2} = 2.236$$

(8, 1)

En un espacio de múltiples variables (hora, mes, día), esta línea se traza a través de todas las dimensiones simultáneamente.

La trampa matemática de los datos crudos

Si calculamos la **distancia euclidiana directamente sobre los datos originales**, el algoritmo sufre una **distorsión catastrófica**. La geometría del vecindario se colapsa.



WARNING DIAGNOSTICO:

Una diferencia de **10 horas** impacta la fórmula de distancia **exponencialmente** más que una diferencia de 2 meses, simplemente porque **la escala numérica es mayor**.

La variable con **rangos más amplios** silencia a las demás.


Estandarización: Nivelando el terreno de juego

Para que k-NN funcione, la estandarización es un paso no negociable. Restamos la media y dividimos por la desviación estándar en los datos de entrenamiento para asegurar que cada variable tenga exactamente el mismo peso en la votación.



Definiendo el parámetro k : El radio del consenso


Una vez calculado el mapa de distancias exactas, debemos decidir cuántos vecinos tienen derecho a votar sobre la identidad del nuevo accidente. Este es el hiperparámetro k .



El valor de k dicta la suavidad de las fronteras de decisión y determina qué tan sensible es el modelo al ruido local.

El modelo base: Estableciendo el vecindario en $k = 5$


Al aplicar el modelo k-NN con 5 vecinos sobre nuestra muestra estandarizada de entrenamiento (70%) y evaluarlo en los datos de prueba (30%), obtenemos nuestra primera matriz de confusión.



Exactitud global del ~84.8%. ¿Pero es esto suficiente en un contexto de vidas humanas?


El dilema de calibración: Ampliar o reducir el círculo

Una exactitud alta puede ser engañosa cuando las clases están fuertemente desbalanceadas (82% de accidentes sin víctimas). Debemos explorar qué sucede con las **fronteras de decisión** cuando **modificamos drásticamente el tamaño del vecindario** ($k=3$ frente a $k=11$).



El círculo cerrado ($k = 3$): Priorizando la sensibilidad

Con un vecindario de solo 3 puntos, el modelo reacciona intensamente a anomalías locales. Si un accidente nuevo cae cerca de un pequeño grupo histórico de accidentes fatales, emitirá una alerta inmediata.



Sensibilidad

0.377

(El valor más alto. Detecta la mayor proporción de accidentes con víctimas reales)

Especificidad

0.938


(Ligeramente inferior. Genera más falsas alarmas)

Exactitud

0.843

El consenso amplio ($k = 11$): Dominio de la mayoría

Al expandir el círculo a 11 vecinos, el modelo requiere una evidencia abrumadora para predecir un accidente grave. Debido a que el 82% del conjunto de datos histórico es Solo daños, el voto mayoritario aplasta las señales locales más sutiles.



Sensibilidad

0.337

(El valor más bajo. Pierde un gran número de accidentes con víctimas)

Especificidad

0.961

(El valor más alto. Extraordinariamente preciso al descartar daños menores)

Exactitud

0.855

Veredicto: Fronteras mucho más suaves, pero severamente sesgado hacia la clase dominante (Turc  NotebookLM)


Matriz comparativa: La tensión entre métricas

Comparar los modelos lado a lado revela que ajustar k no mejora el modelo de manera uniforme; simplemente transfiere el error de un tipo a otro.

	$k = 3$	$k = 5$	$k = 11$
Exactitud	0.843	0.848	0.855 ↗
Sensibilidad (Alerta Temprana)	0.377	0.349	0.337 ↘
Especificidad (Precisión en Descarte)	0.938	0.949	0.961 ↗

Síntesis: No existe un k universalmente superior

Modificar k modifica el balance estratégico. En datos desbalanceados como ATUS, buscar la máxima exactitud global empuja al modelo a ignorar la clase minoritaria crítica.



El costo estratégico: ¿Es preferible tolerar alertas falsas (baja especificidad) o **correr el riesgo de omitir accidentes graves (baja sensibilidad)**?

especificidad
exactitud
sensibilidad

Las 3 reglas de oro del modelado k-NN

El método de los vecinos más cercanos saca el aprendizaje estadístico de la caja negra, basándose puramente en la memoria espacial de los datos.



1. La intuición manda

k-NN es geométrico, no algebraico. Asume que la historia se repite en clústeres espaciales medibles mediante la distancia euclidiana.



2. La estandarización no es opcional

Sin escalar los datos (restar media, dividir por desviación estándar), las variables con escalas mayores destruirán la validez del cálculo de distancia.



3. 'k' es una decisión estratégica

Cambiar el radio del vecindario altera el equilibrio entre Sensibilidad y Especificidad. El mejor k no es el que da la mayor exactitud, sino el que mejor responde al costo real del error humano.