





Descodificando Decisiones: Árboles de Clasificación en R

De la impureza de Gini a la predicción de
accidentes de tránsito con la base ATUS.

La Anatomía de una Regla:

Un árbol de decisión clasifica observaciones dividiendo el problema mediante una secuencia de preguntas binarias (reglas si-entonces).




El Reto

Misión: Clasificar cientos de miles de registros de la base ATUS (INEGI).


Variables predictoras disponibles:

- MES
- HORA
- DIA DE LA SEMANA
- TIPO DE ACCIDENTE
- CAUSA DEL ACCIDENTE

El Desbalance Natural de las Clases



¿Cómo elige el árbol la mejor pregunta?



El motor del árbol busca continuamente los cortes que logren la máxima pureza en los grupos resultantes.

$$\text{Gini} = 1 - \sum p_k^2$$

0.5


0.0



Mezcla 50-50.
Incertidumbre total.

Insight Box

El algoritmo de aprendizaje evalúa todas las variables y elige iterativamente el corte que produce la mayor caída en el Índice de Gini general.



Certeza absoluta.
Pureza total.

El Plano Algorítmico

Definición de la Fórmula

```
accidente_con_victimas ~  
  MES + ID_HORA  
  + DIASEMANA  
  + TIPACCID  
  + CAUSAACCI
```

La variable respuesta se modela en función de las condiciones temporales y la cinemática.


Arquitectura del Modelo (rpart)

```
modelo_arbol <- rpart(...,  
  data = entrenamiento,  
  method = 'class')
```

Función rpart (Recursive Partitioning and Regression Trees).

Se entrena sobre el 70% de la base disponible.

Controlando el Crecimiento



Controles de Crecimiento

```
control = rpart.control(cp = 0.005, minsplit = 1000, maxdepth = 5)
```

cp = 0.005

El corte debe mejorar la pureza en al menos este umbral.

minsplit = 1000

Mínimo de accidentes en un nodo para atreverse a dividirlo de nuevo.

maxdepth = 5

Límite estricto de profundidad (capas de preguntas).

Insight: Evitamos el sobreajuste. El modelo debe aprender patrones generales, no memorizar el ruido.

La Revelación

Al calcular todas las reducciones de impureza de Gini en los 273,439 accidentes de entrenamiento, el árbol encontró su respuesta definitiva.



¿El momento del accidente o la física del accidente?


La Revelación



Takeaway Analítico


La dominancia de TIPACCID. En los datos de ATUS, la consecuencia final de un accidente está dictada casi por completo por la cinemática (el TIPO de accidente: volcadura, choque frontal) más que por el día, la hora o la causa reportada.

La Hora de la Verdad



El árbol ahora se enfrenta a más de 117,000 registros nuevos.
La predicción teórica se compara con la realidad documentada.

La Matriz de Confusión: El Plano del Rendimiento



Resultados Finales: La Paradoja de las Métricas



Especificidad: El modelo es absolutamente infalible sabiendo cuándo NO hay víctimas (identifica perfectamente la inmensa mayoría de casos 'Solo daños').




Exactitud: En casi 9 de cada 10 casos globales, el modelo predijo el resultado correcto. Parece un modelo sobresaliente.

El Punto Ciego: Sensibilidad (19.3%)



El modelo falló en detectar a
más de 16,000 accidentes
Con víctimas.

• La Trampa del Desbalance.



Al ser la inmensa mayoría de los accidentes "Solo daños", el árbol aprendió que la forma matemática más segura de maximizar la exactitud general era apostar siempre por la clase mayoritaria. Un modelo conservador.

Resumen Ejecutivo: La Dualidad del Árbol

El Poder del Árbol

- **Intuitivo, interpretable** y altamente visual.
- Capaz de **aislar** señales vitales en el ruido (descubrimiento de TIPACCID).
- **No** requiere transformaciones matemáticas complejas.

El Límite Estructural

- Alta **vulnerabilidad** ante clases minoritarias.
- **Sensibilidad pobre** en datos reales desbalanceados.

¿La Solución? Un bosque es más sabio que un solo árbol.
(Próxima frontera: Random Forest)