


Máquinas de Vectores de Soporte (SVM)

De la intuición geométrica a la clasificación de datos reales.


Class A
(Solo Daños)

Class B
(Con Víctimas)


El Desafío de la Separación: Buscar el Margen Máximo



El intento fallido



El ajuste mediocre



La separación ideal

Cualquier línea puede dividir.

La SVM encuentra la línea que maximiza la distancia entre los grupos.

El objetivo:

Construir una frontera que generalice bien con datos nuevos, no solo memorizar los datos de entrenamiento.

Anatomía Matemática de la Frontera

La Regla de Decisión

$$y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$$

1 El Hiperplano

$$w_1x_1 + w_2x_2 + b = 0$$

2 El Margen

$$2/\|\mathbf{w}\|$$

2 El Margen

$$2/\|\mathbf{w}\|$$

Maximizar el margen equivale a minimizar la magnitud de $\mathbf{w}$. Matemáticamente, forzamos la mayor separación posible.

Los Héroes del Modelo: Vectores de Soporte



El Filtro de Relevancia

Aunque haya miles de observaciones, la SVM solo presta atención a los datos más cercanos a la frontera.



Determinación Absoluta

En nuestro conjunto simulado de 120 observaciones, solo 14 vectores de soporte dictan la posición de la línea. El resto de los puntos son invisibles para la ecuación.



El Parámetro de Costo (C): ¿Flexibilidad o Rigidez?


C = 0.1 (Bajo)

Penalización suave a los errores.
Margen amplio.
Resulta en 30 vectores de soporte.
Favorece la generalización.

C = 10 (Alto)


Penalización estricta.
Margen ajustado.
Resulta en 8 vectores de soporte.
Alto riesgo de sobreajuste
(memorización).

Cuando una Línea Recta Fracasa



- El mundo real rara vez se divide perfectamente con una línea o hiperplano plano.
- Si los datos tienen estructuras complejas o circulares, una SVM lineal tradicional es insuficiente. Necesitamos proyectar los datos a una nueva dimensión.

El Poder de la Topología: El Kernel Radial



Parámetros Clave del Kernel

El kernel calcula similitudes geométricas sin crear explícitamente nuevas variables (**Kernel Trick**).

El **parámetro γ (Gamma)**: Controla el alcance de influencia de cada observación.

- Valores bajos: Fronteras suaves y extendidas.
- Valores altos: Fronteras locales, muy complejas y contorneadas.

El Mundo Real: Datos de Accidentes ATUS (INEGI)

Origen: Estadística de Accidentes de Tránsito Terrestre (ATUS).



MES



ID_HORA



TIPACCID



CAUSAACCI

Solo daños



Con víctimas

Muestra de Trabajo: 6,000 registros estratificados (para optimizar recursos computacionales).

El Objetivo Binario: Predecir si un accidente será de Solo daños frente a Con víctimas.

La Regla de Oro: Estandarización de Variables

⚠ Las SVM miden **distancias geométricas** ($\|w\|$).

Son extremadamente sensibles a las escalas.

scale = TRUE

ⓘ Si no estandarizamos (**scale = TRUE**), la **variable con el rango numérico más amplio** dominará por completo el modelo, cegando a la SVM frente a otras variables cruciales.

(Mean = 0, Variance = 1)

El Problema del Desbalance (82% vs 18%)



18%
(Con víctimas)



class.weights

= 2.77



Si no ponderamos, el algoritmo hará trampa: ignorará a la clase minoritaria (Con víctimas) simplemente para inflar su exactitud general.

La Solución: Asignar un peso matemático de 2.77 a los accidentes Con víctimas y de 0.60 a Solo daños. Ahora, fallar al detectar una víctima le duele más al algoritmo.

Modelo 1: SVM Lineal en Datos ATUS



Parámetros:

kernel = 'linear', cost = 1.

Vectores de Soporte Requeridos: 2,215 (casi un tercio de los datos sostienen la frontera).

Métricas Clave:

Exactitud: 78.1%

Sensibilidad: 72.5% (Detectando accidentes con víctimas)

Especificidad: 79.4%

Takeaway:

Un modelo sólido y balanceado gracias a los pesos asignados.

Modelo 2: SVM con Kernel Radial



Parámetros:

kernel = 'radial', cost = 1, gamma = 0.03.

Vectores de Soporte Requeridos: 2,318 (la frontera curva requiere más soportes).

Métricas Clave:

Exactitud: 78.3%


Sensibilidad: 71.2% (Drop)

Especificidad: 79.9%

Takeaway:

Mayor adaptación curva a los datos, mejorando ligeramente la especificidad pero sacrificando un mínimo de sensibilidad.

El Veredicto: ¿Lineal o Radial?




Sobre Exactitud:
Empate virtual (~78%).
Mirar solo esto es un
espejismo en datos
desbalanceados.

Sobre Sensibilidad:
El modelo Lineal gana
ligeramente en la
métrica más vital
(detectar víctimas
reales).

Conclusión Operativa: El Kernel Radial ofrece flexibilidad matemática, pero en este dataset específico, el costo computacional extra no justifica la ganancia frente a un modelo Lineal ponderado.

Afinación y el Peligro del Sobreajuste



La Búsqueda: Los hiperparámetros no se adivinan. Usamos *tune.svm* con validación cruzada para evitar fugas de información.

La Paradoja de la Optimización: El modelo óptimo logró una Exactitud del 85.3%... pero su Sensibilidad cayó al 18.5%.

Lección Crítica: Si la métrica objetivo en la afinación ciega no respeta el peso de las clases desbalanceadas, el algoritmo sacrificará la detección de víctimas para maximizar aciertos fáciles.

Framework de Decisión para SVM



Ventajas (El Poder)

- ✓ Margen máximo asegura alta generalización.
- ✓ Maneja excelentemente espacios de alta dimensionalidad.
- ✓ Versatilidad geométrica mediante Kernels.



Limitaciones (El Costo)

- ⚠ Lento computacionalmente con millones de datos.
- ⚠ Menor interpretabilidad nativa (vs Árboles).
- ⚠ Requiere sintonización de hiperparámetros fina.



Reglas de Oro (La Práctica)

1.

Siempre **estandarice** numéricas (scale = TRUE).

2.

Asigne **pesos** en escenarios desbalanceados (class.weights).

3.

Valide con Sensibilidad/F1, no solo Exactitud.