


Agrupamiento con k-means


Descubriendo la estructura oculta en los datos

MI Jesús Gilberto Rodríguez Escobedo



Aprendizaje Supervisado

Conocemos la etiqueta (variable de respuesta).
El objetivo del algoritmo es predecir.




Aprendizaje No Supervisado

No existen etiquetas ni respuestas previas.
El objetivo del algoritmo es descubrir la estructura.
Agrupar observaciones similares y separar las diferentes.


La Idea Intuitiva: Encontrar el Centro de Gravedad

Un centroide es simplemente el perfil promedio de las observaciones del grupo.




1. Asignar

Cada observación se vincula al centroide más cercano.



2. Recalcular


El centroide se mueve al promedio exacto del grupo.



3. Iterar

El proceso se repite hasta que las asignaciones dejen de cambiar.

La Función Objetivo: Máxima Cohesión



k-means busca minimizar la suma de cuadrados dentro de los grupos (WSS).

$$WSS = \sum_j \sum_i \|x_i - \mu_j\|^2$$

μ_j : El centroide.

x_i : Cada observación.

El algoritmo busca reducir la tensión elástica (distancia) entre el centro y sus bordes, creando grupos compactos y densos.

El Parámetro Invisible: ¿Por qué usar `nstart`?



Inicialización Deficiente



Inicialización Óptima

El motor de k-means es ciego al inicio. Su éxito depende de dónde caigan los centroides iniciales.


*kmeans(datos, centers = k,
nstart = 25)*

Ejecuta el algoritmo 25 veces desde posiciones aleatorias distintas y conserva únicamente la solución con la menor variación interna (WSS).

La Ilusión de la Escala: El peso de la Estandarización

Si una variable se mide en miles y otra entre 0 y 10, la primera dominará la distancia euclidiana.

Antes



$$Z = \frac{x - \bar{x}}{s}$$

Después: scale() en R



Al estandarizar, todas las variables entran al modelo con el mismo peso geométrico, permitiendo descubrir perfiles reales y no simples artefactos de medición.

Interpretación de Centroides: Leyendo el ADN del Clúster

- Los números de los clústeres no tienen significado inherente.
- Un centroide es un perfil promedio estandarizado.
- El trabajo del analista es bautizar a los grupos basándose en esta topografía.

Clúster 2



- Valores > 0 (Por encima de la media global)
- Valores < 0 (Por debajo de la media global)

El Gran Dilema: Seleccionando el Valor de k



k

k -means requiere que el número de grupos se defina antes de empezar.

¿Cómo evitamos decidir a ciegas?

Necesitamos validación matemática:

1. Visión Macro (Método del Codo)
2. Visión Micro (Coeficiente Silhouette)

Visión Macro: El Método del Codo


- Mide la suma de cuadrados interna (WSS) para distintos valores de k .
- A medida que k aumenta, el error siempre baja.
- Buscamos el punto de inflexión o rendimientos decrecientes: el punto exacto donde añadir más grupos deja de aportar mejoras significativas a la cohesión del modelo.



Visión Micro: El Coeficiente Silhouette

Compara la cohesión interna frente a la separación externa para cada observación individual.



Negativo: Posible asignación incorrecta del algoritmo.





Cerca de 0: Observación fronteriza. Zona de ambigüedad.



Cerca de 1: Agrupamiento claro y denso. Excelente asignación.



Matriz Diagnóstica: Ventajas y Limitaciones

Ventajas 	Limitaciones 
 Sencillo, intuitivo y fácil de visualizar.  Rápido y escalable en conjuntos de datos medianos y grandes.  Excelente motor para segmentación exploratoria inicial.  Disponible de forma nativa en R (<code>kmeans()</code>).	 Exige fijar k arbitrariamente antes de iniciar.  Altamente sensible a la inicialización y a la escala.  Favorece geometrías esféricas; fracasa con grupos de densidades muy diferentes.  Matemáticamente diseñado solo para variables numéricas continuas.

Errores Frecuentes en la Práctica

Checklist de Seguridad



La ilusión de los datos crudos: No estandarizar las variables numéricas antes de modelar.



La ruleta rusa algorítmica: Ejecutar una sola inicialización ($nstart = 1$).





El sesgo de confirmación: Elegir k únicamente porque coincide con una expectativa humana previa.



El espejismo del orden: Interpretar los números de clúster generados como si fueran categorías jerárquicas o absolutas.



La tiranía de los extremos: Ignorar valores atípicos (outliers) que desvían masivamente el centro de gravedad.



El Arte de Agrupar

1. Preparación

Estandarizar el terreno geométrico.

2. Validación

Dirigir el modelo con el Codo y Silhouette.

3. Interpretación

Traducir los centroides en decisiones de negocio.

El algoritmo descubre la estructura; el analista descubre el significado.